DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha técnica del modelo a01 · wine-pest-disease-detection

Especificación técnica para integración en la plataforma DatagIA

Octubre 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Información general del modelo

Nombre del modelo (model_key)	ml1-wine-pest-disease-detection
Versión	1.0.0
Descripción	Sistema experto multimodal (VID-Deep_Ensemble) para diagnóstico fitopatológico de la vid: un detector YOLOv8 localiza y recorta la hoja o el racimo de interés, y un Deep Ensemble de tres backbones (MobileNetV3Small, EfficientNetB0, DenseNet121) clasifica entre 15 plagas/patologías a partir de esa imagen. Una rama tabular paralela, alimentada por 9 sensores IIoT, estima de forma independiente un índice de riesgo epidemiológico continuo (0-1). Variante de producción: modo desacoplado (la clase proviene en exclusiva de la imagen, el riesgo en exclusiva de los sensores) y sin gases (CO2/VOC no son necesarios).
Tipo de tarea (task_type)	classification_regression_multimodal (ensemble de visión + regresión tabular, con fallback de solo-riesgo sin imagen)
Framework	keras3(backend=torch) + ultralytics (YOLOv8) + scikit-learn (RandomForestClassifier/Regressor)
Fichero del artefacto	best.pt (detector YOLOv8) + 3 ensemble_member_<backbone>_no_gases_desacoplado.weights.h5 (Deep Ensemble) + rf_riesgo_expert_no_gases.joblib (experto de riesgo de respaldo, re-serializado con scikit-learn 1.5.2) + class_mapping_no_gases.json — 574 MB en total
Objetivo del modelo	Detección y monitorización fitosanitaria temprana de la vid en Castilla y León mediante visión computacional y datos fisicoquímicos de campo, identificando 15 enfermedades fúngicas y plagas sobre hoja o racimo y cuantificando el riesgo epidemiológico ambiental, para permitir intervenciones fitosanitarias dirigidas en lugar de tratamientos preventivos generalizados.
Caso de uso principal	El cliente envía una imagen de hoja/racimo (base64) junto con la lectura de 9 sensores IIoT de los últimos 5 días; el sistema devuelve la patología diagnosticada (voto por mayoría/soft-voting de los 3 backbones), la confianza del ensemble y el índice de riesgo. Si no se aporta imagen, el sistema cae a un modo de contingencia: un experto RandomForest estima solo el riesgo a partir de los sensores (no clasifica patología — ver limitaciones). En modo batch, el cliente sube un ZIP con un CSV (columna Path_Imagen + 9

	sensores) y las imágenes referenciadas; cada fila se procesa de forma independiente, con la misma lógica de contingencia por fila.

TABLA 1 INFORMACIÓN GENERAL DEL MODELO

2. Campos de entrada (inputs)

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
image_base64	string | null	Imagen de hoja o racimo en base64 (JPG/PNG), recortada automáticamente por YOLOv8 antes de clasificar.	No	sin imagen -> modo de contingencia tabular (solo riesgo)
sensors	dict[string, float]	9 sensores IIoT de los últimos 5 días: Mes, Temp_Max_Media_5d_C, Temp_Min_Media_5d_C, Hum_Rel_Max_5d_Pct, Hum_Rel_Min_5d_Pct, Hum_Suelo_Pct, Lluvia_Acum_5d_mm, Horas_Humedad_Foliar, GDD_Acumulado. CO2_ppm/VOC_ppb se aceptan pero se ignoran (configuración de producción, exclude_gases=true).	Sí (coincidencia exacta con los 9 campos)	N/A
mlflow_run_id	string	Run de MLflow con el RandomForest de riesgo reentrenado por el usuario (solo afecta a las peticiones sin imagen). Si no se puede cargar, la petición falla (422): nunca se usa el modelo base en su lugar.	No	"" (usa el RF de riesgo base)
data_path (modo batch)	string	Ruta local o s3:// a un .zip con un CSV (Path_Imagen + los 9 sensores) y las	Sí, en modo batch	N/A

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
		imágenes referenciadas, en la raíz del ZIP o en una subcarpeta images/ (se buscan en ambos sitios). Las columnas del CSV que no son sensores (ID, etiqueta...) se ignoran.		

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Campos de salida (outputs)

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
enfermedad	string	Una de las 15 clases (ALTICA, BLACK_ROT, BOTRYTIS, EMPOASCA, ERINOSIS, ESCA_HOJA, ESCA_RACIMO, HEALTHY_HOJA, HEALTHY_RACIMO, ISARIOPSIS, LOBESIA, MILDIU, OIDIO, OIDIO_RACIMO, RED_MITE) o IMAGEN_NO_DISPONIBLE si no se aportó foto.	15 clases + 1 etiqueta de contingencia	diagnóstico fitopatológico por voto mayoritario/promedio del ensemble
confianza	float	Probabilidad softmax promedio de la clase ganadora entre los 3 backbones.	[0, 1]; 0.0 si no hay imagen	a mayor valor, mayor acuerdo entre los 3 modelos del ensemble
riesgo	float	Índice de riesgo epidemiológico, estimado por la rama tabular (con imagen) o por el	[0, 1]	potencial de propagación según las condiciones microclimática

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
		experto RandomForest (sin imagen).		s; no depende de la imagen. Orientativo: ver limitaciones (apenas mejora a un valor constante)
metodo	string	Motor que generó la respuesta.	HIBRIDO_ENSAMBLE | RIESGO_TABULAR_EXPERT	HIBRIDO_ENSAMBLE = con imagen (clase + riesgo fiables); RIESGO_TABULAR_EXPERT = sin imagen (solo riesgo, enfermedad=IMAGEN_NO_DISPONIBLE)

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Métricas de evaluación

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
Deep Ensemble — Accuracy (declarado, memoria Tabla 4/6)	0,95 (0,9469 en el CSV auditado)	Test hold-out, 1470 imágenes, configuración Desacoplado + Sin Gases	clasifica correctamente ~95 de cada 100 imágenes del test oficial
Deep Ensemble — F1-Score (declarado)	macro=0,88 / weighted=0,95	Promedio por clase (macro, sin ponderar) y ponderado por	el macro, más bajo que el weighted, refleja que algunas clases minoritarias (LOBESIA,

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
		soporte (weighted), mismo test hold-out	OIDIO_RACIMO, EMPOASCA) rinden peor
Deep Ensemble — métricas verificadas con el plugin real (28/10/2026)	0,9469 / F1 macro 0,8807 / F1 weighted 0,9463	Las 1470 imágenes de data/splits/test_split .csv sobre los recortes del equipo: idéntico a lo auditado. Con la imagen 224 recortada por el plugin (ruta de producción): 0,9483. Con la foto a resolución completa: 0,9401	el plugin reproduce exactamente el modelo auditado; con fotos de cámara a resolución completa cabe esperar ~0,6 puntos menos de acierto
MAE riesgo Deep Ensemble (declarado y verificado)	0,189 (R^2 = 0,076)	Error absoluto medio del índice de riesgo [0,1] sobre las 1470 filas de test; un valor constante (la mediana) obtiene MAE 0,183	el índice de riesgo apenas aporta información sobre la que daría un valor fijo — ver limitaciones
RandomForest tabular (fallback de riesgo) — accuracy/f1 (declarado y verificado EXACTO)	accuracy=0,11593, f1_macro=0,11804, f1_weighted=0,1175 5	Reproducido de forma EXACTA (mismas 5 cifras decimales) ejecutando el training.py real del plugin contra las 500.000 filas reales de SENSORES.csv,	confirma que el RF tabular NO es apto como clasificador aislado (apenas por encima del azar sobre 15 clases) — por eso el plugin nunca lo usa para

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
		con el mismo split 80/20 (seed=42) que generó el test auditado (100.000 filas). El RF de riesgo de respaldo: MAE 0,188, R^2 0,205	clasificar, solo para estimar riesgo
YOLOv8 — detección	mAP50=0,995, mAP50-95=0,868, Recall=1,0	Localización de hoja/racimo, test hold-out (memoria Tabla 7/Figura 9)	detecta prácticamente el 100% de las regiones de interés con alta precisión geométrica

TABLA 4 MÉTRICAS DE EVALUACIÓN

5. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Origen internacional de las imágenes	Ante la falta de datasets públicos de Castilla y León, se usaron colecciones de India, Brasil y EE.UU.; las manifestaciones visuales de las patologías pueden variar por clima, luz o variedad de vid respecto al viñedo español real.
Clases minoritarias con rendimiento más débil	LOBESIA (f1=0,67, recall 0,60), OIDIO_RACIMO (f1=0,59, recall 0,62) y EMPOASCA (f1=0,74, recall 0,59) tienen soporte bajo en el test (15, 13 y 17 imágenes) y un recall muy inferior al resto de clases y al KPI individual de 0,85 — cifras auditadas por el equipo y reproducidas exactamente con el plugin.
Fotos a resolución completa	El modelo se entrenó y evaluó con recortes de imágenes ya reducidas a 224 px; con fotos de cámara a resolución completa la accuracy baja de 0,947 a 0,940 (MobileNetV3 de 0,71 a 0,60). Heredado del diseño del equipo de IA.

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
El fallback sin imagen NO clasifica patología	Cuando no se aporta imagen, el sistema usa un experto RandomForest que solo estima el riesgo (metodo=RIESGO_TABULAR_EXPERT, enfermedad=IMAGEN_NO_DISPONIBLE). El RandomForest clasificador existe como artefacto pero no se invoca para diagnosticar: su accuracy real aislada es del 11,6% sobre 15 clases (ver métricas), casi aleatoria.
El índice de riesgo apenas tiene capacidad predictiva	MAE 0,189 pero R^2 0,076: predecir siempre la mediana da MAE 0,183, mejor que el modelo. Las predicciones medias por clase son casi planas (0,25-0,27) frente a valores reales de 0,06 a 0,60. Causa: el riesgo de entrenamiento se generó con reglas por patología, pero los sensores simulados no dependen de la patología (salvo los grados-día en LOBESIA/ALTICA) y la rama de riesgo solo ve sensores. El RF de respaldo tiene la misma limitación (R^2 0,205). Debe tratarse como orientativo.
Reentrenamiento del Deep Ensemble fuera de alcance (por ahora)	Solo el par RandomForest (riesgo de respaldo) es reentrenable vía /train. El Deep Ensemble CNN requiere ~4h20min de CPU y un pipeline de entrenamiento complejo (tf.data, aumentado, scheduler); aunque el corpus completo ya está disponible y el repositorio soporta entrenamiento asíncrono, portar fielmente ese pipeline es un trabajo dedicado pendiente, no incluido en esta integración.
Índice de riesgo basado en un Digital Twin sintético	Los registros ambientales que alimentan el riesgo (500.000 filas de SENSORES.csv) son generados sintéticamente a partir de modelos epidemiológicos estándar (Broome, Rossi, Caffi), no mediciones directas de campo — requiere validación con telemetría real antes de confiar en el valor absoluto del índice.

TABLA 5 LIMITACIONES CONOCIDAS

6. Observaciones técnicas

Inferencia 100% en CPU (Keras 3 con backend=torch, sin TensorFlow ni GPU); YOLOv8 vía ultralytics también en CPU. ~0,64 s por imagen en CPU. Memoria: 2,3 GB tras cargar, pico de 3,2 GB con 4 peticiones concurrentes — límite de pod recomendado >= 4 GiB. Artefactos: 574 MB (499 MB son el RF de riesgo, solo usado sin imagen). Dependencias con versión fijada: scikit-learn==1.5.2 (compatibilidad de pickle con el servicio de explicabilidad), keras>=3.0.0 (paquete standalone, no tf.keras).

7. Fichero de prueba de referencia

Nombre del fichero	inbox/a01/manifest.yaml::golden_cases (20 casos de data/splits/test_split.csv) + test completo de 1470 imágenes + SENSORES.csv (500.000 filas)
Número de registros / muestras	20 casos con imagen+sensores+etiqueta real; 1470 imágenes del split de test oficial (Deep Ensemble); 500.000 filas reales (RandomForest)
Resultado esperado con este fichero	Deep Ensemble: 0,9469 / 0,8807 / 0,9463 idénticos a lo auditado; golden 18/20 (los 2 fallos son errores del modelo). RandomForest: reproducción EXACTA de accuracy/f1 auditados. predictions.csv del equipo reproducido — ver outputs/a01/verification_report.md

TABLA 6 FICHERO DE PRUEBA DE REFERENCIA