DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha técnica del modelo a06 · meat-poultry-disease-classification

Especificación técnica para integración en la plataforma DatagIA

Octubre 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Información general del modelo

Nombre del modelo (model_key)	ml6-meat-poultry-disease-classification
Versión	1.0.0
Descripción	Dos ensembles independientes de redes convolucionales con votación por mayoría para la detección de enfermedades en aves de galpón. El ensemble 'thermal' (DenseNet-121, EfficientNetV2-S, ResNet-50) clasifica imágenes térmicas del ave en healthy/sick; el ensemble 'rgb' (VGG19-BN, EfficientNet-B7, MobileNetV3-L) clasifica imágenes RGB de heces en healthy/cocci/ncd/salmo. Transfer learning desde ImageNet con backbone congelado y capa final reentrenada.
Tipo de tarea (task_type)	image_classification_ensemble (binaria thermal + multiclase rgb, voto duro 3 modelos)
Framework	PyTorch 2.13 + torchvision 0.28 (DenseNet-121, EfficientNetV2-S, ResNet-50, VGG19-BN, EfficientNet-B7, MobileNetV3-L) · opencv (CLAHE) · scikit-learn (métricas)
Fichero del artefacto	6 state_dict de PyTorch en artifacts/ml6_meat_poultry_disease_classification/: densenet121.pt (28 MB), efficientnet_v2s.pt (82 MB), resnet50.pt (94 MB) para thermal; vgg19_bn.pt (558 MB), efficientnet_b7.pt (257 MB), mobilenet_v3l.pt (17 MB) para rgb. md5 idéntico a la entrega del equipo de IA.
Objetivo del modelo	Detección temprana y no invasiva de enfermedades aviares en dos etapas: cribado sano/enfermo por termografía de todas las aves en los puntos de manejo individual, y diagnóstico de la patología (coccidiosis, Newcastle, salmonelosis) a partir de las heces del ave aislada. Objetivo de negocio declarado: reducir un 10 % los tratamientos veterinarios en galpón (no medido; requiere validación con datos reales antes de despliegue).
Caso de uso principal	POST /predict con model_key='thermal' o 'rgb'. Inline: una imagen (image_base64 o image_path) → clase del ensemble, voto y softmax de cada modelo base. Batch: directorio o .zip de imágenes → una fila por imagen y, si las imágenes están en subcarpetas con el nombre de su clase, métricas por modelo y del ensemble. POST /train con task='thermal'|'rgb' reentrena los 3 modelos de ese ensemble con el procedimiento original (split 70/15/15,

	seed 42) y guarda el resultado solo en el run de MLflow indicado; /predict con ese mlflow_run_id lo usa.

TABLA 1 INFORMACIÓN GENERAL DEL MODELO

2. Campos de entrada (inputs)

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
model_key	string: 'thermal' | 'rgb'	Ensemble a usar. Las dos modalidades no son intercambiables; sin model_key o con otro valor → 422	Sí	-
image_base64 / image_path	string (base64) / ruta	Imagen jpg, jpeg, png, bmp, tif o webp. thermal: frame de la cámara térmica a resolución nativa 240x320 (ancho x alto), sin redimensionar; rgb: foto de heces de cualquier tamaño (se redimensiona a 256x256)	Sí (inline, uno de los dos)	-
data_path	string (ruta local, s3:// o .zip)	Modo batch: directorio o ZIP de imágenes; subcarpetas con nombre de clase (healthy/sick; healthy|pcrhealthy, cocci|pcrcocci, ncd|pcrncd, salmo|pcrsalmo) habilitan la evaluación	Sí (batch)	-
mlflow_run_id	string	Run con un ensemble reentrenado por /train. Si no contiene un ensemble cargable de esa modalidad → 422 (nunca se usa el base en su lugar)	No	"" (modelo base)

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Campos de salida (outputs)

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
prediction	string	Clase del ensemble por votación por mayoría de los 3 modelos base	thermal: healthy | sick; rgb: healthy | cocci | ncd | salmo	En empate a tres (solo rgb) gana el voto de VGG19-BN, igual que el código original
predicted_class_index	int	Índice de la clase predicha	thermal 0-1; rgb 0-3	Orden de config.yaml: thermal 0=healthy 1=sick; rgb 0=healthy 1=cocci 2=ncd 3=salmo
confidence	float	Fracción de modelos base que votan la clase predicha	1/3, 2/3 o 1	No es una probabilidad: 1 = unanimidad; 2/3 = un modelo discrepa; 1/3 = empate a tres
model_predictions	dict[str, str]	Clase votada por cada modelo base	una entrada por modelo base	Permite ver qué arquitectura discrepa
model_probabilities	dict[str, dict[str, float]]	Softmax por clase de cada modelo base (informativo)	[0, 1], suman 1 por modelo	Para monitorización: probabilidades concentradas en 0.4-0.6 de forma sostenida indican pérdida de

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
				discriminación o drift
warnings	list[str]	Avisos no bloqueantes sobre la entrada	vacío o mensajes	p. ej. imagen térmica que no es 240x320: la predicción puede no ser fiable
evaluated_metrics (batch)	dict	accuracy, precision/recall/f1 weighted y macro, y por clase, de cada modelo base y del ensemble	[0, 1]	Solo si todas las imágenes del lote traen su clase real por subcarpeta; mismo cálculo que predictor.py del original

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Métricas de evaluación

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
Accuracy ensemble thermal (test, n=40)	0.8000	Declarada por el equipo de IA (memoria Tabla 4). Por modelo: DenseNet-121 0.6750, EfficientNetV2-S 0.6750, ResNet-50 0.7750	8 de cada 10 aves clasificadas correctamente; el ensemble supera en 2.5 pp al mejor modelo individual. Objetivo > 0.7 cumplido
Recall thermal por clase (test)	sick 0.8846 · healthy 0.6429 · weighted	La memoria reporta 0.8000 (weighted, igual a la accuracy	Detecta ~88 % de las aves enfermas; el objetivo 'Recall >

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
	0.8000 · macro 0.7637	en binario); desglose de data/thermal/predictions/thermal_per_class_metrics.csv	0.65' se cumple en sick y weighted, no en healthy (0.64)
Accuracy / F1 weighted ensemble rgb (test, n=192)	0.8490 / 0.8484	Declaradas por el equipo de IA (memoria Tabla 5). Por modelo: VGG19-BN 0.8490, EfficientNet-B7 0.8125, MobileNetV3-L 0.8490	Objetivos > 0.8 cumplidos; el ensemble iguala al mejor modelo individual
F1 por clase ensemble rgb (test)	healthy 0.7358 · cocci 0.8704 · ncd 0.9667 · salmo 0.8727	Memoria Tabla 6; recall de Newcastle (ncd) = 1.0000 sobre 29 imágenes	La clase sana es la más confundida; la memoria fija recall ncd < 0.85 como umbral crítico de reentrenamiento
Verificación post-integración (golden dataset)	63/63 casos exactos (tolerancia 0 por voto)	40 imágenes thermal + 23 rgb del split de test real (regenerado con ensure_data_splits del equipo y comprobado contra sus CSV), llamando a /predict del servidor real: clase del ensemble y voto de los 3 modelos base idénticos a los registrados por el	El plugin reproduce la inferencia original sin desviación propia, incluido el criterio de desempate

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
		pipeline original — ver outputs/a06/verification_report.md	
Verificación split de test completo (batch)	232/232 imágenes, 0 diferencias de voto; Tablas 4, 5 y 6 reproducidas a 4 decimales	Resultado verificado tras integración (no declarado por el equipo): thermal 0.8000 y rgb 0.8490 de accuracy, idénticas a las declaradas	Las métricas declaradas por el equipo de IA quedan confirmadas con el plugin servido; quedan votos thermal y rgb con margen softmax < 0.01, sensibles a cambios de versión de opencv/torch

TABLA 4 MÉTRICAS DE EVALUACIÓN

5. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Test sets pequeños	thermal: 40 imágenes (14 sanas / 26 enfermas); cada imagen vale 2.5 pp de accuracy. Intervalos de confianza amplios.
Datos públicos de otro contexto	thermal: 254 imágenes de broilers Cobb de una granja experimental en Egipto con una cámara UNI-T UTi165A; rgb: 1 255 imágenes de heces con etiqueta PCR (Zenodo). Sin datos de explotaciones de Castilla y León: requiere validación con datos reales antes de despliegue.
Dependencia de la cámara térmica	El ensemble thermal se entrenó a la resolución nativa 240x320 con los metadatos de esa cámara incrustados; otra cámara, resolución o emisividad introduce un desplazamiento sistemático. Recalibrar/reentrenar con imágenes del equipo de destino.

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Posible ruido de etiquetas	En el dataset térmico público hay imágenes con nombre 'infectado' (árabe) en la carpeta Healthy, una de ellas en test. No se ha corregido; pendiente de revisión por el equipo de IA.
Etapa rgb requiere aislamiento	El diagnóstico por heces solo es válido si se puede asociar la muestra a un ave concreta, lo que exige aislarla. Newcastle y salmonelosis comparten signos en estadios iniciales.
Reentrenamiento síncrono y largo	/train rgb completo dura ~2 h 45 min en GPU (memoria Tabla 3); thermal ~2 min en GPU (860 s medidos en CPU). Parte del checkpoint servido, no de ImageNet como el original, y no repite la búsqueda Optuna.
Sin explicabilidad en línea	Grad-CAM y el análisis de atención sobre metadatos del entregable son fases offline y no se sirven por la API.

TABLA 5 LIMITACIONES CONOCIDAS

6. Observaciones técnicas

Inferencia en CPU viable (x86-64, ≥ 4 vCPU, 8 GB RAM; recomendado 16 GB: los 6 modelos ocupan ~1 GB en memoria). Medido en CPU: mediana 163 ms por imagen thermal y 370 ms por imagen rgb (3 modelos). GPU NVIDIA recomendada para /train. Dependencias ya presentes en el repo; recomendado fijar la versión de opencv-python-headless (el entregable usaba 4.13.0.92, verificado con 5.0.0). Monitorizar: probabilidades concentradas en 0.4-0.6 y recall de ncd < 0.85 (umbral de reentrenamiento de la memoria). Los modelos se cargan con weights=None + state_dict strict (sin descarga de ImageNet).

7. Fichero de prueba de referencia

Nombre del fichero	inbox/a06/manifest.yaml::golden_cases (63 imágenes del split de test: data/thermal/splits/test y data/fecal/splits/test) + los splits de test completos
Número de registros / muestras	63 golden cases (40 thermal, 20 rgb, 3 empates rgb) x 4 decisiones (ensemble + 3 modelos) = 252 valores; split completo 232 imágenes (40 + 192)
Resultado esperado con este fichero	Cada imagen debe devolver la misma clase del ensemble y el mismo voto de cada modelo base que los CSV del entregable (data/*/predictions/*_predictions.csv); p. ej. thermal_test_002 (A1_1_104_6_0.bmp) → healthy con votos densenet121=sick, efficientnet_v2s=healthy, resnet50=healthy. El batch del test completo debe dar accuracy 0.8000 (thermal) y 0.8490 (rgb).

TABLA 6 FICHERO DE PRUEBA DE REFERENCIA