DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha técnica del modelo a07 · cereals-grain-pest-detection

Especificación técnica para integración en la plataforma DatagIA

Julio 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Información general del modelo

Nombre del modelo (model_key)	ml7-cereals-grain-pest-detection
Versión	1.0.0
Descripción	Detector de objetos basado en red neuronal convolucional (YOLO de la librería ultralytics) para la detección temprana de infestaciones en grano de cereal almacenado. A partir de una imagen RGB, localiza los insectos presentes mediante cajas delimitadoras y los clasifica en 5 clases de plaga (cf, sz, rd, tc, os), devolviendo la especie dominante, su confianza, el recuento por especie, el detalle de cada detección y la imagen anotada. Inferencia en GPU si hay una disponible y compatible (detección automática con fallback seguro a CPU); soporta reentrenamiento real (fine-tuning) por usuario vía MLflow.
Tipo de tarea (task_type)	object_detection (detección de objetos multiclase sobre imagen)
Framework	ultralytics (YOLO) sobre PyTorch; artefacto servido best.pt. La memoria describe la arquitectura entrenada como YOLO26n (variante nano, 260 capas, 2.505.750 parámetros, ~5,8 GFLOPs); el plugin la carga como checkpoint YOLO de ultralytics.
Fichero del artefacto	best.pt (~5,3 MB) — checkpoint YOLO de ultralytics con las mejores métricas de validación. Cargado vía ArtifactStore (carpeta ml7_cereals_grain_pest_detection, local o S3). last.pt no se entrega.
Objetivo del modelo	Anticipar la presencia de plagas de insectos en centros de almacenamiento de grano, donde la infestación puede provocar pérdidas del 10-40 % de la producción anual (pérdida de peso, de capacidad germinativa, rancidez y proliferación fúngica). Permite una vigilancia preventiva automatizada mediante análisis periódico de imágenes y la generación de alertas tempranas para intervenir antes de que la infestación se consolide.
Caso de uso principal	Modo predict inline: una imagen individual como ruta de fichero (image_path) o cadena base64 (image_base64); devuelve la especie dominante, confianza, recuento por especie, todas las detecciones y la imagen anotada. Modo predict batch: un directorio o fichero .zip de imágenes dentro del contenedor (data_path); devuelve una predicción por imagen (especie dominante, confianza, nº de

	detecciones y recuento por especie). El umbral de confianza puede sobrescribirse por petición (threshold). Modo train: reentrena (fine-tuning) el detector YOLO a partir de un dataset.yaml de Ultralytics (imágenes + etiquetas ya organizadas en train/val/test), replicando fielmente los hiperparámetros del equipo de IA; requiere obligatoriamente un mlflow_run_id (sin valor por defecto) y el checkpoint reentrenado se guarda solo en ese run de MLflow, nunca sobrescribe el artefacto base servido.

TABLA 1 INFORMACIÓN GENERAL DEL MODELO

2. Campos de entrada (inputs)

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
mode	str	Discriminador de modo de /predict: 'inline' (una imagen) o 'batch' (carpeta/ZIP)	Sí	inline
image_path	str | None	Ruta a una imagen en disco (modo inline); extensiones .jpg/.jpeg/.png/.bmp/.tif/.tiff	Uno de image_path / image_base64	None
image_base64	str | None	Imagen codificada en base64 (modo inline)	Uno de image_path / image_base64	None
threshold	float | None	Umbral de confianza de detección; si no se indica se usa el valor por defecto del modelo (0,28)	No	None (→0,28)
data_path	str	Modo batch: ruta a un directorio o fichero .zip de imágenes dentro del contenedor	Sí (modo batch)	-
mlflow_run_id	str	Identifica el run de MLflow de un modelo reentrenado por el usuario. En predict/batch es opcional (usa el	No en predict; Sí en train	"" (predict) / - (train)

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
		artefacto base si se omite); en train es obligatorio (sin valor por defecto) — el checkpoint reentrenado se guarda solo en ese run, nunca sobrescribe el artefacto base		
data_path (modo train)	str	Ruta a un dataset.yaml de Ultralytics, o a un directorio que contenga uno, con las imágenes y etiquetas YOLO ya organizadas en train/val/test	Sí (modo train)	-

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Campos de salida (outputs)

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
prediction	str	Código de la especie dominante (cf, sz, rd, tc, os) o 'none' si no hay detecciones	cf|sz|rd|tc|os|none	Plaga predominante en la imagen
confidence	float	Confianza máxima de la especie dominante	0-1	Fiabilidad de la detección principal
total_detections	int	Número total de insectos detectados	≥ 0	Magnitud de la presencia de plaga en la imagen
species_counts	dict	Recuento de detecciones por especie	{especie: conteo}	Reparto por tipo de plaga
detections	list	[inline] Lista con class, class_name, confidence y bbox	0..N	Detalle por caja para revisión o anotación

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
		[x1,y1,x2,y2] por detección		
annotated_image	str (base64)	[inline] Imagen JPEG en base64 con las cajas dibujadas	-	Permite validar visualmente las detecciones
predictions	list	[batch] Una entrada por imagen con filename, prediction, confidence, total_detections y species_counts (sin detections ni imagen anotada)	0..N	Resultado agregado del lote

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Métricas de evaluación

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
IDP = mAP@0,5 (global, detección)	0,87	KPI principal declarado en la memoria; media del AP por clase con IoU ≥ 0,5 sobre el conjunto de test (2.700 imágenes, 4.090 instancias). Métrica declarada en la memoria, sin verificación post-integración	supera el criterio de aceptación (> 0,8) y se sitúa en el rango 80-90 % reportado en la literatura
Precision (global, detección)	0,84	Proporción de cajas predichas correctas sobre el conjunto	de cada 100 detecciones, ~84 corresponden a

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
		de test (declarada en la memoria)	insectos reales de la clase indicada
Recall (global, detección)	0,81	Proporción de insectos reales correctamente detectados sobre el conjunto de test (declarada en la memoria)	el modelo localiza ~81 de cada 100 insectos presentes
mAP@0,5 por clase (rango, detección)	0,84 (cf) – 0,95 (os)	cf 0,84 / os 0,95 / rd 0,87 / sz 0,88 / tc 0,88 (memoria, Tabla 7). Métrica declarada, sin verificación post-integración	Cryptolestes ferrugineus es la clase más difícil; Oryzaephilus surinamensis la más fiable
Precision / Recall (global, clasificación)	0,71 / 0,87	Métricas a nivel de clasificación de especie (sin localización), derivadas de la matriz de confusión sobre el test (memoria, Tabla 8)	buena sensibilidad global; la precisión baja por confusiones entre especies morfológicamente similares
Detección real verificada (model.val() sobre 2.700 imágenes reales de test)	mAP50=0,871 / precision=0,876 / recall=0,856	Verificación post-integración (verification_report.md, Ciclo 2) ejecutando el checkpoint real servido sobre el split de test completo ya	confirma que la localización y clasificación de cajas del detector servido es fiel a lo declarado por el equipo de IA

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
		entregado — coherente con el 0,87/0,84/0,81 declarado en la memoria	
Correctitud post-integración (golden dataset, verification_report.md)	23/23 casos reales coinciden exactamente contra el servidor real	23 casos extraídos del split de test real (20 de una sola especie + 3 multiespecie), verificados vía HTTP tras corregir el bug de decodificación de especie (ver limitaciones)	el servicio ya integrado reproduce fielmente el comportamiento del checkpoint real, incluyendo los errores genuinos de detección (falsos positivos/negativos) que mide el recall/precision de arriba

TABLA 4 MÉTRICAS DE EVALUACIÓN

5. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Conjunto cerrado de 5 especies	El modelo solo reconoce las plagas incluidas en el dataset de entrenamiento (cf, sz, rd, tc, os; sz agrupa Sitophilus zeamais y Sitophilus oryzae). Ante una especie no vista, puede no detectarla o asignarla erróneamente a una clase conocida (closed-set classification). Ampliar la cobertura exige nuevas imágenes anotadas y reentrenamiento/fine-tuning.
Objetos de tamaño muy reducido	Aproximadamente la mitad de las instancias miden menos de 42×42 px sobre imágenes de 512×512, con un área media de bounding box ~1.718 px. Ello dificulta la extracción de características y degrada las métricas, de forma más acusada en Cryptolestes ferrugineus y Rhyzopertha dominica.

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Fuente de datos única	Se entrena y valida sobre una única fuente pública (Pestdataset, porción procesada del dataset de Li et al. 2024 vía Tian et al. 2025), con 17.999 imágenes reales de cámaras de almacenamiento tras limpieza. Aunque son datos reales (no sintéticos), la representatividad taxonómica y de condiciones queda acotada a ese conjunto.
Decodificación de especie — bug crítico ya corregido	El código de entrenamiento entregado por el equipo de IA generaba, para el checkpoint base, una inconsistencia entre el orden de clase usado para entrenar y el orden embebido en el propio checkpoint; esto hacía que, antes de esta corrección, el servicio asignara la especie equivocada en ~6 de cada 10 detecciones (verificado: 39,0% de aciertos de especie sobre 500 imágenes reales). Corregido en la integración (sin reentrenar el modelo): tras el fix, el acierto de especie sube a 94,4% sobre la misma muestra. El detector (localización de cajas) nunca se vio afectado — mAP50 real 0,871, coherente con la memoria.
Device de inferencia — detección automática con fallback	La inferencia usa GPU (CUDA) automáticamente si hay una disponible y compatible, probándolo con una operación real antes de confiar en ella; si no, cae a CPU de forma segura. Es adecuada para imágenes individuales o lotes pequeños en CPU, y para lotes grandes se recomienda una GPU compatible.
Nombre de clase 'sz' simplificado	El plugin muestra la clase sz como 'Sitophilus spp.', mientras que la memoria la define como 'Sitophilus zeamais / Sitophilus oryzae' agrupadas por similitud morfológica; ambas referencias designan la misma clase.

TABLA 5 LIMITACIONES CONOCIDAS

6. Observaciones técnicas

Inferencia en CUDA si hay GPU compatible disponible (fallback automático y seguro a CPU); ultralytics importado de forma perezosa. Artefacto best.pt (~5,3 MB) cargado vía ArtifactStore (local artifacts/ o S3), nunca commiteado a git. Entrada RGB reescalada internamente por ultralytics (resolución de inferencia 512×512, imgsz explícito en cada llamada); imagen anotada limitada a 640 px y JPEG calidad 70. El umbral por defecto CONF_THRESHOLD=0,28 se calibró para minimizar falsos positivos sin comprometer recall; es sobrescribible por petición. train() soporta fine-tuning real (300 épocas, mismos hiperparámetros que el equipo de IA,

mlflow_run_id obligatorio); el checkpoint reentrenado se sube solo a MLflow, nunca sobrescribe el artefacto base.

7. Fichero de prueba de referencia

Nombre del fichero	23 casos reales extraídos de data/splits/images/test/ + data/splits/labels/test/ del dataset entregado (ground truth real), con verificación de correctitud ya ejecutada (ver verification_report.md).
Número de registros / muestras	Conjunto de test real: 2.700 imágenes, 4.095 instancias etiquetadas (partición 70/15/15, semilla 42). Golden dataset de verificación: 23 imágenes (20 de una sola especie + 3 multiespecie).
Resultado esperado con este fichero	model.val() real sobre las 2.700 imágenes de test: mAP50=0,871/precision=0,876/recall=0,856, coherente con el 0,87/0,84/0,81 de la memoria. Los 23 casos del golden dataset coinciden exactamente (23/23) contra el servidor real tras corregir el bug de decodificación de especie — ver verification_report.md, Ciclo 2.

TABLA 6 FICHERO DE PRUEBA DE REFERENCIA