DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha funcional del modelo a08 · cereals-img-anomaly-detector

Descripción de negocio para usuarios de la plataforma DatagIA

Julio 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Qué hace el modelo

Descripción	Sistema de análisis de imágenes que, a partir de una foto de grano u hoja de cereal, determina a la vez dos cosas: su estado sanitario (sano, con hongos, con insectos u otros defectos) y el tipo de cereal (trigo, maíz, arroz o sorgo).
Objetivo del modelo	Automatizar la detección y clasificación temprana de anomalías en cereal (enfermedades fúngicas, daños por insectos y otros defectos) para reducir las pérdidas por afecciones sanitarias, que la memoria estima en hasta un 30% de la producción anual del sector. El sistema convierte una imagen en dos predicciones accionables (estado sanitario + especie), sustituyendo la inspección manual subjetiva por un análisis rápido y consistente (< 40 ms/imagen declarados) que alimenta decisiones de tratamiento, almacenamiento o descarte de lotes.
Caso de uso principal	Le das una fotografía del cereal y el sistema devuelve su estado sanitario y de qué cereal se trata, con el grado de seguridad de cada una de las dos conclusiones. Puedes analizar una imagen suelta para una respuesta inmediata o un lote de fotos de una vez. A diferencia de otros modelos, este sí admite reentrenarse con nuevas imágenes etiquetadas para adaptarlo a un caso concreto.

TABLA 1 DESCRIPCIÓN GENERAL DEL MODELO

No dice si un grano concreto es apto o no para consumo ni emite un dictamen fitosanitario oficial: te indica, para cada imagen, qué tipo de cereal ve y en qué estado sanitario lo clasifica, como apoyo a tu decisión.

2. Qué necesito darle (entradas)

Le das una fotografía del cereal (grano u hoja): una imagen suelta cuando quieres una respuesta inmediata, o un archivo comprimido con muchas fotos cuando quieres analizar un lote entero de golpe. Las imágenes proceden de cámaras de inspección en silos, big bags o campo.

Nombre del campo	Descripción
Fotografía del cereal	Una imagen de grano u hoja de cereal (JPG, PNG, etc.), procedente de cámaras de inspección en silo, big bag o campo.
Lote de imágenes	Un archivo comprimido con muchas fotos para analizar un lote entero de golpe.

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Qué me devuelve (salidas)

Nombre del campo	Descripción	Cómo interpretar el resultado
Estado sanitario	Sano, con hongos, con insectos u otros defectos.	Indica si el cereal presenta una anomalía y de qué tipo.
Tipo de cereal	Trigo, maíz, arroz o sorgo.	Identificación de la especie, útil para trazabilidad del lote.
Confianza del estado sanitario	Cuán seguro está de la conclusión sanitaria, de 0 a 1.	Cuanto más alta, más fiable el diagnóstico de estado.
Confianza del tipo de cereal	Cuán seguro está de la especie, de 0 a 1.	Confianza baja sugiere especies visualmente parecidas.

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Cómo leo el resultado

Ejemplo: subes la foto de un grano de trigo y el sistema responde "cereal: trigo (confianza 0,99), categoría: hongos (confianza 0,93)". Se lee como: casi con seguridad es trigo, y muy probablemente presenta una afección fúngica, por lo que ese lote es candidato a revisión o tratamiento antes de almacenarlo.

En la práctica el sistema acierta el estado sanitario en algo más de 9 de cada 10 imágenes y el tipo de cereal en casi todas. Acierta menos en las anomalías poco frecuentes (daños por insectos u "otros" defectos), donde a veces marca anomalía sin que la haya: conviene tratar esas alertas como aviso para mirar la muestra, no como veredicto definitivo.

5. Cuándo debo revisar manualmente

• Cuando la confianza que da el sistema es baja o las dos clases más probables están muy igualadas.

• Siempre que la imagen sea de sorgo: el modelo solo ha aprendido sorgo con hongos, así que cualquier otro estado sanitario en sorgo es poco fiable.

• Cuando la predicción sea 'insectos' u 'otros': son las categorías donde el sistema más se equivoca al marcar anomalías que no lo son.

• Si la foto está borrosa, mal iluminada, tomada desde un ángulo raro o con un fondo muy distinto al habitual.

• Ante un cereal, variedad o tipo de defecto que no estaba en los datos de entrenamiento (solo conoce trigo, maíz, arroz y sorgo).

6. Qué no hace el modelo

• No decide por ti si tratar, almacenar o descartar el lote: es una ayuda a la inspección, no un sistema de control automático.

• No detecta cereales distintos de trigo, maíz, arroz y sorgo.

• No identifica la enfermedad o plaga concreta: solo agrupa en sano, hongos, insectos u otros.

• No garantiza la reducción del 10% de anomalías: ese objetivo de negocio aún no se ha medido en operación real.

• No sustituye los análisis de laboratorio ni los controles fitosanitarios reglamentarios.

7. Puede equivocarse

Sí. Aunque en las pruebas acertó el estado sanitario en el 92,6% de las imágenes y el tipo de cereal en el 99%, esos números se midieron sobre un conjunto de imágenes públicas y no se han vuelto a comprobar tras integrar el modelo en el sistema. Se equivoca más con las anomalías poco frecuentes y con imágenes distintas a las que aprendió. Además, la mejora del 10% en detección de anomalías

es un objetivo, no un resultado confirmado. Trátalo como una segunda opinión rápida que agiliza la inspección, no como una garantía.

8. KPIs del modelo

KPI	Valor objetivo / umbral	Descripción comprensible
Reducción de objetos anómalos en el cereal	Objetivo: -10% frente a inspección manual (no medido en operación real todavía)	Cuántas menos anomalías (hongos, insectos, defectos) quedan sin detectar o mal clasificadas respecto a la inspección humana tradicional. Es el indicador de negocio principal.
Acierto del estado sanitario	Umbral ~90% — resultado declarado: 92,58%	Con qué frecuencia clasifica bien si el cereal está sano o afectado. Base de las decisiones de tratamiento o descarte.
Acierto del tipo de cereal	Umbral ~95% — resultado declarado: 98,98%	Con qué frecuencia identifica bien la especie. Evita mezclas de lotes y problemas de trazabilidad.
Acierto conjunto (estado + cereal)	Umbral ~85% — resultado declarado: 91,82%	Porcentaje de imágenes en que acierta las dos cosas a la vez, es decir, da información completa y fiable.
Tiempo de análisis por imagen	< 40 ms — resultado declarado: 8 ms (GPU) / 34,5 ms (CPU)	Rapidez de respuesta por foto, para poder analizar grandes volúmenes sin cuellos de botella.

TABLA 4 KPIS DEL MODELO

9. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Sorgo solo con clase hongos	El dataset no contiene muestras de sorgo en categorías distintas de hongos, por lo que el modelo no puede clasificar de forma fiable el estado sanitario real del sorgo (sano, insectos, otros).

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Desbalance de clases	La categoría hongos representa ~72% de las imágenes; sano, insectos y otros ~15%, ~6% y ~5%. Las clases minoritarias tienen precision más baja (insectos 0,62; otros 0,68 en test), con riesgo de sesgo hacia la clase mayoritaria.
Resolución de entrada fija 224x224	Todas las imágenes se redimensionan a 224x224, con pérdida de detalle en imágenes de alta resolución (mediana del dataset 300x300, percentil 95 ~1600x1391).
Dominio acotado a 4 cereales	Solo clasifica trigo, maíz, arroz y sorgo; no generaliza a otros cultivos sin reentrenamiento.
Heterogeneidad de fuentes / domain shift	El dataset integra múltiples fuentes públicas (Kaggle, Mendeley) con condiciones de captura, iluminación y resolución dispares. Datos con distribución distinta a la de entrenamiento (nuevas variedades, imágenes borrosas o con ruido) degradan el rendimiento.
Balanceo de clases no replicado en el /train integrado	La memoria describe class_weights, WeightedRandomSampler y submuestreo de hongos (max_samples_hongos); el /train integrado usa CrossEntropyLoss sin pesos y muestreo uniforme (shuffle), por lo que un reentrenamiento por usuario no reproduce la estrategia de balanceo original.
KPI de negocio no medido empíricamente	La reducción del 10% de objetos anómalos es un objetivo frente al baseline de inspección manual, no un resultado medido; requiere validación operativa con datos reales antes de reclamarlo.

TABLA 5 LIMITACIONES CONOCIDAS