DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha técnica del modelo a08 · cereals-img-anomaly-detector

Especificación técnica para integración en la plataforma DatagIA

Julio 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Información general del modelo

Nombre del modelo (model_key)	ml8-cereals-img-anomaly-detector
Versión	1.0.0
Descripción	Clasificador de imágenes multitarea basado en MobileNetV3-Large. A partir de una imagen RGB de grano/hoja de cereal predice simultáneamente la categoría sanitaria (sano, hongos, insectos, otros) y el tipo de cereal (trigo, maíz, arroz, sorgo) mediante dos cabezas de clasificación independientes que comparten un extractor de características preentrenado en ImageNet. Diseñado para apoyar el control de calidad y la detección temprana de anomalías en entornos de almacenamiento (silos, big bags) y cultivo cerealista.
Tipo de tarea (task_type)	image-classification (clasificación multitarea multi-clase: categoría sanitaria x tipo de cereal)
Framework	PyTorch + torchvision (MobileNetV3-Large multitarea con dos cabezas lineales; alternativas soportadas en carga: EfficientNet-B0, ResNet18)
Fichero del artefacto	mobilenet_v3_large_cereales_multitask.pth (checkpoint con model_state_dict, class_to_idx, cereal_to_idx, idx_to_class, idx_to_cereal); servido desde artifacts/ml8_cereals_img_anomaly_detector/ (local) o S3 (ARTIFACT_FOLDER_NAME=ml8_cereals_img_anomaly_detector)
Objetivo del modelo	Automatizar la detección y clasificación temprana de anomalías en cereal (enfermedades fúngicas, daños por insectos y otros defectos) para reducir las pérdidas por afecciones sanitarias, que la memoria estima en hasta un 30% de la producción anual del sector. El sistema convierte una imagen en dos predicciones accionables (estado sanitario + especie), sustituyendo la inspección manual subjetiva por un análisis rápido y consistente (< 40 ms/imagen declarados) que alimenta decisiones de tratamiento, almacenamiento o descarte de lotes.
Caso de uso principal	Se expone como plugin HTTP en /models/ml8-cereals-img-anomaly-detector con tres operaciones. Modo inline (POST /predict, mode=inline): recibe una imagen en base64 y devuelve categoría, cereal, sus confianzas y las probabilidades completas por clase. Modo batch (POST /predict, mode=batch): recibe la ruta a un ZIP de imágenes

	(local o s3://), infiere sobre cada fichero de imagen y devuelve la lista de predicciones (con error por imagen individual si alguna falla). Modo /train: reentrena el modelo desde un ZIP con estructura {cereal}/train/{categoria}/*.jpg mediante transfer learning en dos fases; opcionalmente registra parámetros, métricas y el checkpoint en MLflow (mlflow_run_id) para servir modelos entrenados por el usuario. Dispone además de /stats.

TABLA 1 INFORMACIÓN GENERAL DEL MODELO

2. Campos de entrada (inputs)

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
image_base64	str (base64)	Imagen RGB de cereal codificada en base64 (modo inline). Formatos aceptados: JPG, JPEG, PNG, BMP, TIF/TIFF, WEBP. Se redimensiona internamente a 224x224 y se normaliza con estadísticas ImageNet	Sí (modo inline)	-
data_path	str (ruta ZIP)	Ruta a un fichero ZIP con imágenes dentro del contenedor o en s3:// (modo batch e inferencia por lotes). Se recorren recursivamente todas las imágenes con extensión soportada	Sí (modo batch)	-
data_path (train)	str (ruta ZIP)	Ruta a un ZIP con estructura {cereal}/train/{categoria}/*.jpg (y opcionalmente {cereal}/validation|val/...). Si no hay partición de validación, se hace auto-split 80/20 sobre train	Sí (modo /train)	-
mlflow_run_id	str	Identificador de run MLflow. En predict permite cargar un modelo entrenado por el usuario;	No (predict) / Sí	"" (vacío)

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
		en train activa el logging de parámetros, métricas y artefactos	(train_dto)	

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Campos de salida (outputs)

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
categoria	str	Categoría sanitaria predicha (clase ganadora de la cabeza de categoría)	{sano, hongos, insectos, otros}	Estado sanitario del grano; hongos/insectos/otros marcan anomalía frente a sano
cereal	str	Tipo de cereal predicho (clase ganadora de la cabeza de cereal)	{trigo, maiz, arroz, sorgo}	Especie identificada por morfología; útil para trazabilidad de lote
confianza_categoria	float	Probabilidad softmax de la categoría ganadora	[0, 1]	Cuanto más próxima a 1, mayor certeza del estado sanitario predicho
confianza_cereal	float	Probabilidad softmax del cereal ganador	[0, 1]	Cuanto más próxima a 1, mayor certeza de la especie predicha
probabilidades_categoria	dict[str, float]	Distribución softmax completa sobre las 4 categorías sanitarias	cada valor en [0, 1], suman ~1	Permite ver clases próximas y aplicar umbrales de

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
				decisión propios
probabilidades_cereal	dict[str, float]	Distribución softmax completa sobre los 4 tipos de cereal	cada valor en [0, 1], suman ~1	Permite detectar confusiones entre especies visualmente similares
predictions (batch)	list[dict]	Lista con un objeto por imagen del ZIP (mismos campos que inline más filename); las imágenes ilegibles se devuelven con campo error	-	Salida agregada del modo batch; no se genera CSV, la respuesta es JSON

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Métricas de evaluación

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
Accuracy Categoría (test)	92,58%	Accuracy de la categoría sanitaria sobre el conjunto de test hold-out (15%), MobileNetV3-Large. Métrica declarada por el equipo de IA en la memoria (Tabla 12); no se ejecutó verificación post-integración	Supera el umbral operativo declarado (~90%) para el estado sanitario
Accuracy Cereal (test)	98,98%	Accuracy del tipo de cereal sobre el test	Muy por encima del umbral (~95%); la

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
		hold-out. Declarada en la memoria (Tabla 12)	especie tiene alta separabilidad morfológica
Accuracy Combinada (test)	91,82%	Porcentaje de imágenes con ambas predicciones (categoría y cereal) correctas simultáneamente. Declarada en la memoria (Tabla 12)	Supera el umbral (~85%); en ~92% de casos el sistema da información completa y fiable
Macro-F1 categoría (test)	0,87	F1 macro sobre las 4 categorías sanitarias (Tabla 10). Declarada en la memoria	Refleja equilibrio interclase pese al desbalance; penaliza el peor recall/precision por clase
Weighted-F1 categoría (test)	0,93	F1 ponderado por frecuencia de clase en categoría sanitaria (Tabla 10). Declarada en la memoria	Alto por el peso de la clase mayoritaria (hongos, ~72% del dataset)
Latencia por imagen	8 ms (GPU L40) / 34,5 ms (CPU 16 threads)	Tiempo de inferencia por imagen medido por el equipo de IA (Tablas 7 y 12)	Compatible con escenarios de alta carga; muy por debajo del objetivo declarado de 40 ms
Verificación post-integración	No ejecutada	No existe verification_report. md para a08; no se ha corrido un	Pendiente de verificación de correctitud contra el

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
		golden dataset contra el plugin integrado. Las métricas anteriores son las declaradas por el equipo de IA, no verificadas tras la integración	dataset real antes de PR

TABLA 4 MÉTRICAS DE EVALUACIÓN

5. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Sorgo solo con clase hongos	El dataset no contiene muestras de sorgo en categorías distintas de hongos, por lo que el modelo no puede clasificar de forma fiable el estado sanitario real del sorgo (sano, insectos, otros).
Desbalance de clases	La categoría hongos representa ~72% de las imágenes; sano, insectos y otros ~15%, ~6% y ~5%. Las clases minoritarias tienen precision más baja (insectos 0,62; otros 0,68 en test), con riesgo de sesgo hacia la clase mayoritaria.
Resolución de entrada fija 224x224	Todas las imágenes se redimensionan a 224x224, con pérdida de detalle en imágenes de alta resolución (mediana del dataset 300x300, percentil 95 ~1600x1391).
Dominio acotado a 4 cereales	Solo clasifica trigo, maíz, arroz y sorgo; no generaliza a otros cultivos sin reentrenamiento.
Heterogeneidad de fuentes / domain shift	El dataset integra múltiples fuentes públicas (Kaggle, Mendeley) con condiciones de captura, iluminación y resolución dispares. Datos con distribución distinta a la de entrenamiento (nuevas variedades, imágenes borrosas o con ruido) degradan el rendimiento.
Balanceo de clases no replicado en el /train integrado	La memoria describe class_weights, WeightedRandomSampler y submuestreo de hongos (max_samples_hongos); el /train integrado usa

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
	CrossEntropyLoss sin pesos y muestreo uniforme (shuffle), por lo que un reentrenamiento por usuario no reproduce la estrategia de balanceo original.
KPI de negocio no medido empíricamente	La reducción del 10% de objetos anómalos es un objetivo frente al baseline de inspección manual, no un resultado medido; requiere validación operativa con datos reales antes de reclamarlo.

TABLA 5 LIMITACIONES CONOCIDAS

6. Observaciones técnicas

Entorno de referencia Python 3.10 sobre Linux. Hardware declarado: CPU x86-64 (mín. 4 cores), >=16 GB RAM, GPU opcional (referencia GPU L40), 30-35 GB de almacenamiento para datasets y artefactos. Inferencia funciona en CPU (selección automática de dispositivo con fallback CPU si CUDA no es funcional). Librerías núcleo declaradas: torch 2.5.1, torchvision 0.20.1, Pillow, numpy, pandas, scikit-learn, matplotlib, seaborn. Backbone preentrenado IMAGENET1K_V2. Reentrenamiento /train en dos fases (Fase 1: extractor congelado, solo neck+cabezas, Adam lr=1e-3, hasta 10 epochs; Fase 2: fine-tuning completo, Adam lr=1e-5, hasta 5 epochs; early stopping patience=3, batch_size=16, imagen 224x224). Monitorización recomendada por la memoria: alerta si cae >5% la Accuracy de categoría o >0,03 el F1 macro durante 2 evaluaciones consecutivas, revisión cada 10.000 inferencias o mensual.

7. Fichero de prueba de referencia

Nombre del fichero	Conjunto de test hold-out (15% del dataset, partición 70/15/15) descrito en la memoria; no se entregó un fichero de golden dataset para verificación post-integración

Número de registros / muestras	~7.936 imágenes de test (Trigo 2.737, Maíz 3.043, Arroz 1.080, Sorgo 1.076); dataset total 52.600 imágenes RGB
Resultado esperado con este fichero	No documentado en la entrega a nivel de caso individual: la memoria reporta las métricas agregadas de test (Accuracy Categoría 92,58%, Cereal 98,98%, Combinada 91,82%) en output/test_metrics.json y las predicciones fila a fila en output/test_predictions.csv, pero no se ejecutó verificación post-integración contra el plugin (verification_report.md no disponible).

TABLA 6 FICHERO DE PRUEBA DE REFERENCIA