DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha técnica del modelo a10 · dairy-disease-vector-detection

Especificación técnica para integración en la plataforma DatagIA

Julio 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Información general del modelo

Nombre del modelo (model_key)	ml10-dairy-disease-vector-detection
Versión	1.0.0
Descripción	Pipeline de visión artificial de dos etapas para la detección y clasificación de vectores de enfermedades (mosca, mosquito y garrapata) en imágenes de ganado vacuno lechero. La primera etapa localiza cualquier organismo anómalo mediante un detector YOLOv8n (anchor-free, una sola pasada); la segunda recorta cada detección y la clasifica por especie con una red MobileNetV3-Large ajustada por transfer learning. Cada detección solo se acepta si supera de forma independiente los umbrales de confianza de detección y de clasificación.
Tipo de tarea (task_type)	object-detection + image-classification (pipeline secuencial de dos etapas)
Framework	PyTorch (MobileNetV3-Large) + Ultralytics YOLOv8n (torchvision, pillow, opencv, numpy)
Fichero del artefacto	detector_best.pt (pesos YOLOv8n) + best_classifier.pth (state_dict MobileNetV3-Large) + class_names.json (mapeo de clases fly/mos/tick)
Objetivo del modelo	Anticipar la presencia de vectores biológicos (moscas, mosquitos y garrapatas) sobre el ganado a partir de imágenes, para permitir una intervención sanitaria temprana antes de que se produzca una infestación en el establo. El objetivo de negocio declarado es reducir en un 10% los costes de tratamiento asociados a estos vectores, cifra que la memoria condiciona a una validación in situ posterior.
Caso de uso principal	Modo predict inline: una imagen individual (base64 o ruta en disco) con umbrales de detección y clasificación configurables; devuelve las detecciones con especie, confianzas y bounding box, más la especie dominante del frame. Modo predict batch: CSV con rutas, ZIP o directorio de imágenes; procesa cada imagen y devuelve una fila por fichero. Modo train: reentrena únicamente el clasificador MobileNetV3 (backbone congelado, cabeza entrenable) a partir de un ZIP de crops etiquetados por especie, guardando el nuevo clasificador como artifact; el detector YOLO no se reentrena en línea.

TABLA 1 INFORMACIÓN GENERAL DEL MODELO

2. Campos de entrada (inputs)

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
image_base64	str (base64)	Imagen JPG/PNG codificada en base64 (modo inline)	Uno de image_base64 / image_path	-
image_path	str	Ruta a la imagen en disco compartido (modo inline); extensiones .jpg/.jpeg/.png/.bmp/.tif/.tiff	Uno de image_base64 / image_path	-
det_conf_thresh	float	Confianza mínima del detector YOLO para conservar una caja	No	0.2
cls_conf_thresh	float	Confianza mínima del clasificador MobileNetV3 para aceptar la especie	No	0.5
data_path	str	Modo batch: ruta a CSV (columna image_path), ZIP o directorio de imágenes; admite prefijo s3://	Sí (modo batch)	-
mlflow_run_id	str	Si se indica, carga un clasificador MobileNetV3 reentrenado por el usuario desde MLflow en lugar del clasificador fijo	No	""

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Campos de salida (outputs)

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
prediction	str	Especie dominante del frame (mayor confianza de clasificación)	fly | mos | tick | no_vectors	no_vectors indica que no se aceptó ninguna detección por encima de los umbrales

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
confidence	float	Confianza de clasificación de la detección dominante	0-1	confianza de la especie asignada al vector dominante; 0.0 si no hay detecciones
vectors_count	int	Número total de vectores detectados y clasificados que superan ambos umbrales	≥ 0	0 significa imagen sin vectores aceptados
detections	list	Lista por detección con species, det_conf, cls_conf y bbox (x1,y1,x2,y2)	0..N objetos	detalle por caja para revisión o anotación de la imagen
species_summary	dict	Recuento de detecciones agrupadas por especie	{especie: conteo}	reparto de vectores por tipo en la imagen

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Métricas de evaluación

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
mAP50 (detección, YOLOv8n)	0.790	Precisión media promedio a IoU 0.5 sobre el conjunto de test de detección (objetivo declarado > 0.7)	el detector localiza correctamente la mayoría de los vectores presentes en la imagen
Recall (detección, YOLOv8n)	0.710	Sensibilidad de localización sobre el test de detección	se detecta ~71% de los vectores; ~29% se omiten,

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
		(objetivo declarado > 0.65)	especialmente los que ocupan menos del 10% de la imagen
Accuracy (clasificación, MobileNetV3)	0.981	Exactitud del clasificador de especie sobre su conjunto de test de crops (objetivo declarado > 0.8)	una vez recortado el vector, el modelo acierta la especie en ~98 de cada 100 casos

TABLA 4 MÉTRICAS DE EVALUACIÓN

5. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Sin evaluación end-to-end	No existían imágenes públicas de vectores etiquetadas sobre ganado real, por lo que el detector y el clasificador se evaluaron por separado en sus propios splits de test. El pipeline completo detección+clasificación no se validó de forma exhaustiva; no hay golden dataset ni informe de verificación de integración para este modelo.
Brecha de dominio	Los modelos se entrenaron con datasets de fondos controlados (neutros o vegetación), no sobre la piel/pelaje del ganado. Texturas del pelaje y variaciones cromáticas del animal pueden interpretarse como detecciones espurias al desplegar en campo.
Escala y resolución del vector	El recall de 0.710 se degrada con vectores pequeños: el sistema omite ~29% de los vectores cuando ocupan menos del 10% de la superficie de la imagen; la distancia variable cámara-animal agrava el efecto.
Desbalance de clases	El dataset de clasificación tenía las garrapatas sobrerrepresentadas (triplicaban a moscas y mosquitos); pese al re-muestreo, la generalización sobre las especies menos representadas es más frágil.

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Variabilidad ambiental	Iluminación fluctuante, sombras del propio animal, incidencia solar directa y desenfoque por movimiento (motion blur) del ganado pueden reducir puntualmente detección y precisión frente a las condiciones de laboratorio.
KPI de negocio no validado	La reducción del 10% en costes de tratamiento es un objetivo de negocio que, según la propia memoria, solo puede confirmarse tras la validación in situ del modelo en condiciones reales de despliegue.

TABLA 5 LIMITACIONES CONOCIDAS

6. Observaciones técnicas

Ejecutable en CPU x86-64 (mín. 4 vCPU) con RAM ≥ 8 GB (recomendado 16 GB); GPU NVIDIA/CUDA recomendada para entrenamiento y tuning, pero la inferencia del pipeline completo corre en CPU con latencia aceptable. Almacenamiento 5-15 GB. Entorno de referencia Python 3.10.11. Dependencias clave: torch, torchvision, ultralytics (YOLO), opencv-python, pillow, numpy, pandas, scikit-learn (métricas), optuna (tuning), PyYAML. Hiperparámetros óptimos (Optuna): detección lr0=2.66e-3, momentum=0.8724, mosaic=0.266, mixup=0.0571, batch=32; clasificación lr=7.98e-3, optimizer=Adam, weight_decay=3.4e-4, batch=64. Entrenamiento con early stopping (paciencia 15 épocas, máx. 100). El reentrenamiento en línea (modo train) solo afecta al clasificador MobileNetV3 y no sobrescribe el detector; se recomienda un ciclo de ajuste por transfer learning cuando la tasa de error validada manualmente en la explotación supere el 5%.

7. Fichero de prueba de referencia

Nombre del fichero	No se entregó fichero de prueba de referencia ni manifest con golden_cases para este modelo. La evaluación declarada se realizó sobre los splits de test independientes de detección y clasificación (notebooks/evaluation).
Número de registros / muestras	Detección: ~4.300 imágenes tras deduplicación, split 70/15/15. Clasificación: ~2.700 crops (224x224), split 70/15/15, reequilibrado a ~25/25/50 mosquito/mosca/garrapata.
Resultado esperado con este fichero	Métricas declaradas en test: mAP50=0.790 y Recall=0.710 (detección YOLOv8n); Accuracy=0.981 (clasificación MobileNetV3). Pendiente de verificación de correctitud contra golden dataset tras la integración.

TABLA 6 FICHERO DE PRUEBA DE REFERENCIA