DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

# Ficha técnica del modelo a13 · wine-price-fluctuation-prediction

## Especificación técnica para integración en la plataforma DatagIA

Octubre 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

# 1. Información general del modelo

| | |
|---|---|
| **Nombre del modelo (model_key)** | ml13-wine-price-fluctuation-prediction |
| **Versión** | 1.0.0 |
| **Descripción** | Clasificador binario de alerta temprana sobre la serie semanal de precios del vino tinto a granel (boletines MAPA). Una Regresión Logística sobre 6 indicadores técnicos (retorno logarítmico, distancia a SMA-12, RSI-14, posición en Bandas de Bollinger-20 y codificación seno/coseno de la semana) estima la probabilidad de que la media del precio de las 4 semanas siguientes supere en más de un 2,5% el precio de la semana actual. Aunque el proyecto se titula 'redes neuronales recurrentes', la rama GRU quedó como experimental: el modelo servido es la Regresión Logística. |
| **Tipo de tarea (task_type)** | Clasificación binaria sobre serie temporal semanal (tabular, horizonte 4 semanas, umbral de subida 2,5%) |
| **Framework** | scikit-learn (LogisticRegression C=1.0, L2, class_weight=balanced + StandardScaler); pandas/numpy/joblib. El reentrenamiento compite LogReg frente a XGBoost por Smart Score |
| **Fichero del artefacto** | ml_model.pkl (LogisticRegression) + scaler.pkl (StandardScaler) + feature_schema.json + model_config.json (model_type=logreg) |
| **Objetivo del modelo** | Dar una señal anticipada, con 4 semanas de margen, de subidas relevantes (>2,5% sobre el precio de la semana de referencia, medido sobre la media de las 4 semanas siguientes) del vino tinto a granel, para apoyar decisiones de inventario, compra y negociación de bodegas y cooperativas. El objetivo cuantitativo que fija la memoria es AUC-ROC >= 0,70, F1 >= 0,50 y Recall >= 0,65. |
| **Caso de uso principal** | Modo inline: se envía la serie semanal (campaign+week o bulletin, y price_red) con al menos 20 semanas y se obtiene la probabilidad y la alerta de la semana más reciente. Modo batch: un CSV con el mismo esquema devuelve una fila por semana de entrada con features y pred_proba_up (null en las ~19 semanas de warm-up). Modo train: reentrena desde cero con el procedimiento original (walk-forward 5 folds con gap de 4 semanas, selección LogReg/XGBoost por Smart Score y hold-out de las últimas 24 semanas) y guarda el resultado como artefacto de usuario (MLflow), sin sobrescribir el fijo. |

TABLA 1 INFORMACIÓN GENERAL DEL MODELO

# 2. Campos de entrada (inputs)

| Nombre del campo | Tipo | Descripción | Obligatorio | Valor por defecto |
|---|---|---|---|---|
| campaign | str ('AAAA/AAAA') | Campaña vitivinícola agosto-julio. Semana >= 31 corresponde al primer año y semana < 31 al segundo | Sí (o bulletin) | - |
| week | int (1-53) | Semana ISO; la fecha de referencia es el lunes de esa semana | Sí (o bulletin) | - |
| bulletin | str | Alternativa a campaign+week: 'SEMANA {semana}/{año_fin}', donde año_fin es el SEGUNDO año de la campaña (SEMANA 46/2026 = semana 46 de 2025). No es el año impreso en el PDF del MAPA | No | Si vienen campaign+week, tienen prioridad |
| price_red | float (EUR/hl) | Precio medio nacional semanal del vino tinto a granel. Se aceptan también preciotinto, precio_blanco o price_white (se usa la primera presente, por ese orden) | Sí | - |
| historial | serie semanal | Mínimo 20 semanas válidas (ventana de Bollinger-20); por debajo se devuelve 422. Los 6 indicadores se calculan internamente y nunca se aceptan como entrada | Sí | - |

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

# 3. Campos de salida (outputs)

| Nombre del campo | Tipo | Descripción | Rango de valores posibles | Cómo interpretar el resultado |
|---|---|---|---|---|
| pred_proba_up | float | Probabilidad de que mean(precio t+1..t+4) > precio_t x 1,025 | 0-1 | Cuanto más alta, más probable una subida relevante en el próximo mes |
| alerta_subida | int (0/1) | 1 si pred_proba_up >= umbral de decisión | 0 / 1 (umbral 0,5 por defecto, el del código original; configurable en inline) | 1 = alerta de subida; en test, el 58% de las alertas fueron falsas |
| fecha / campaign / week / price | date / str / int / float | Semana de referencia t de la predicción (no t+4) y su precio | - | La alerta se refiere a las 4 semanas siguientes a esta fecha |
| xai_feature_values | dict | Los 6 indicadores técnicos sin escalar usados en la predicción | - | Entrada para el servicio de explicabilidad |

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

# 4. Métricas de evaluación

| Métrica | Valor | Descripción | Interpretación (qué significa para el usuario) |
|---|---|---|---|
| Test hold-out — declarado por el equipo de IA (memoria v1.10, Tabla 6) | AUC-ROC 0,8438; F1 0,593; Precision 0,421; Recall 1,000; Accuracy 0,542 | Últimas 24 semanas (19/05/2025-27/10/2025), 8 subidas reales | Cumple los objetivos de la memoria (AUC >= 0,70; F1 >= 0,50; Recall >= 0,65), pero la memoria lo califica de límite superior en un |

| Métrica | Valor | Descripción | Interpretación (qué significa para el usuario) |
|---|---|---|---|
| | | | periodo favorable (33% de positivos frente al 20% en CV) |
| Validación cruzada walk-forward — declarado (memoria v1.10, Tablas 4-5) | AUC-ROC 0,656 ± 0,270; F1 0,171; Precision 0,321; Recall 0,290; Accuracy 0,659 (recalculada: 0,660) | 5 folds sobre las 126 semanas de desarrollo | NO cumple ninguno de los tres criterios de éxito; alta variabilidad entre folds (AUC 0,27-0,90) |
| Resultado verificado tras integración (golden dataset, 24 casos vía API) | AUC 0,8438; F1 0,5926; Precision 0,4211; Recall 1,0; Accuracy 0,5417 — 5/5 métricas dentro de tolerancia (±0,0005) | /predict real sobre cada semana del hold-out; matriz de confusión TP 8 · FP 11 · TN 5 · FN 0 | El plugin reproduce exactamente la Tabla 6; probabilidades idénticas al código original (diferencia <= 1e-16) en 24/24 casos |
| Golden dataset — etiqueta por caso frente al target real | 13/24 aciertos; 11/24 falsos positivos; 0 falsos negativos | Los 11 fallos son los falsos positivos ya declarados en la Tabla 6, no errores de integración | Detecta todas las subidas, pero 11 de 19 alertas fueron falsas en el periodo de test |
| Reproducibilidad del entrenamiento (verificado) | Coeficientes idénticos al artefacto entregado; /train del plugin: mismas métricas de CV y hold-out | Reentrenamiento con el código original (sklearn 1.3.2) y con el plugin (sklearn 1.5.2) | El artefacto es reproducible a partir de los datos y el código entregados |

TABLA 4 MÉTRICAS DE EVALUACIÓN

# 5. Limitaciones conocidas

| Tipo de limitación | Descripción (cuándo no usar / qué puede fallar) |
|---|---|
| Rendimiento dependiente del régimen de mercado | En validación cruzada no se alcanzan los criterios de éxito (AUC 0,656, F1 0,171). Solo se cumplen en el hold-out de 2025, con volatilidad doble y más subidas que el histórico. La propia memoria espera en operación AUC 0,72-0,89 y F1 0,19-0,33. |
| Muchas falsas alarmas | Con el umbral 0,5 del código original, el modelo alertó en 19 de 24 semanas de test y 11 de esas alertas fueron falsas (Precision 0,42). Recall 1,0 no implica precisión. |
| Dataset corto y sin variables exógenas | 173 semanas (ago-2022 a nov-2025), 150 observaciones con target y solo el propio precio como señal. No hay clima, demanda internacional ni costes de insumos. |
| Título RNN frente a modelo servido | El modelo en producción es una Regresión Logística. GRU y ensemble GRU+LogReg son experimentales, no tienen artefacto y no están integrados. |
| Convención del campo bulletin | El año de 'SEMANA n/AAAA' es el segundo año de la campaña, no el del boletín oficial. Copiar el año del PDF del MAPA desplaza las fechas un año sin error visible. |
| Sin validación de huecos ni duplicados | Los indicadores se calculan por filas: una serie con semanas ausentes produce features erróneas sin aviso (comportamiento heredado del código original). |
| Solo vino tinto en el artefacto | El pipeline acepta series de vino blanco, pero el artefacto servido se entrenó solo con price_red. Para blanco hay que reentrenar. |
| Versiones de librerías | Artefactos serializados con scikit-learn 1.3.2 y servidos con 1.5.2: aviso de versión al cargar, sin impacto numérico (verificado). |

TABLA 5 LIMITACIONES CONOCIDAS

# 6. Observaciones técnicas

Solo CPU; inferencia en milisegundos y reentrenamiento completo en < 1 s (memoria: 6,4 s de entrenamiento y 1,4 s de evaluación en un i7-13700H). Artefactos < 5 KB. Requiere scikit-learn (pin del repo 1.5.2), pandas, numpy y joblib; xgboost solo para /train. Requisito operativo: al menos 20 semanas de histórico continuo. La memoria recomienda monitorizar con métricas rolling y revisar return_threshold (analyze_threshold) antes de cada reentrenamiento. Verificación: flake8 0, pylint 10/10, pytest 547/547.

# 7. Fichero de prueba de referencia

| | |
|---|---|
| **Nombre del fichero** | inbox/a13/codigo/.../data/raw/mapa_wine_prices_raw.csv (+ data/processed/wine_prices_test_processed.csv como golden) |
| **Número de registros / muestras** | 174 semanas (01/08/2022-24/11/2025; 173 con precio). Golden: 24 semanas de hold-out (19/05/2025-27/10/2025), 8 subidas reales |
| **Resultado esperado con este fichero** | Batch: 174 filas, 154 con pred_proba_up; última semana (24/11/2025) = 0,4621, sin alerta. Golden vía /predict: Tabla 6 reproducida (AUC 0,8438, F1 0,593, P 0,421, R 1,0, Acc 0,542) y probabilidades idénticas al código original en los 24 casos |

TABLA 6 FICHERO DE PRUEBA DE REFERENCIA