DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha funcional del modelo a14 · wine-phyto-price-forecast

Descripción de negocio para usuarios de la plataforma DatagIA

Septiembre 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Qué hace el modelo

Descripción	Modelo de predicción semanal del índice MAPA de precios de protección fitosanitaria (sector vitivinícola, base 2020=100) a 16 semanas vista, mediante una red GRU (PyTorch, 2 capas, 64 unidades ocultas) que predice un residual sobre un baseline lineal de drift y reconstruye el precio en escala original. Es el artefacto y la evaluación oficialmente aprobados por el equipo de IA: en el test reportado, el GRU supera al baseline lineal de Drift.
Objetivo del modelo	Anticipar con 16 semanas de antelación la evolución del índice nacional de precios de protección fitosanitaria, para dar soporte a la planificación de compras y a la evaluación de riesgo de coste del sector vitivinícola. En la evaluación de test reportada por el equipo de IA, el modelo GRU mejora de forma clara sobre el baseline de tendencia simple (Drift) y sobre no hacer ningún cambio (Naive).
Caso de uso principal	Modo predict inline y predict batch (idéntico cálculo, solo cambia el transporte del histórico — JSON o CSV): se aporta un histórico semanal continuo (frecuencia domingo, sin huecos ni duplicados) de al menos 24 semanas con 6 variables base (índice de protección fitosanitaria, carburantes, cobre, gas, petróleo Brent, tipo de cambio EUR/USD); el servicio deriva automáticamente las 39 features (estacionalidad, retardos de 4/8/12 semanas, medias móviles de 4/8 semanas, diferencia mensual) y devuelve el precio predicho a 16 semanas, el precio actual y el baseline de drift de referencia. También admite reentrenamiento por usuario (/train): con un histórico semanal propio repite el procedimiento del equipo de IA para la GRU y guarda el modelo resultante en MLflow, sin sustituir nunca el modelo base.

TABLA 1 DESCRIPCIÓN GENERAL DEL MODELO

El modelo no predice precios por Comunidad Autónoma ni por explotación individual, solo el índice nacional. No explica por sí mismo la causa de la subida o bajada prevista, ni incorpora eventos futuros conocidos (cambios regulatorios, roturas de stock) que no estén ya reflejados en la tendencia histórica.

2. Qué necesito darle (entradas)

Los datos de entrada son índices y precios ya procesados de fuentes oficiales (MAPA para el índice de protección fitosanitaria y carburantes; FRED/IMF/EIA para cobre, gas, petróleo y tipo de cambio), agregados a frecuencia semanal — no son mediciones directas de sensor ni formularios rellenados por el usuario final.

Nombre del campo	Descripción
rows (histórico semanal, mínimo 24 filas)	Cada fila: date (YYYY-MM-DD, domingo), PROTECCION_FITO, CARBURANTES, COPPER_EUR_TON, GAS_EUR_MMBTU, COIL_EUR_BARRIL, DEXUSEU — todas índices/precios base 2020=100 o unidad de mercado (EUR/tonelada, EUR/MMBtu, EUR/barril, USD/EUR)
MONTH, MONTH_SIN, MONTH_COS, *_LAG_{4,8,12}, *_MA_{4,8}, *_DIFF_MONTH (39 features totales)	Variables derivadas automáticamente del histórico aportado (estacionalidad, retardos autorregresivos, medias móviles, diferencia mensual) — nunca se piden al cliente

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Qué me devuelve (salidas)

Nombre del campo	Descripción	Cómo interpretar el resultado
predicted_price	PROTECCION_FITO predicho a 16 semanas vista	valor esperado del índice nacional dentro de 16 semanas; comparar con current_price y drift_baseline
current_price	PROTECCION_FITO de la última fila del histórico aportado	ancla de referencia inmediata
drift_baseline	Baseline lineal simple (extrapolación de la tendencia mensual reciente) — la referencia frente a la que el	la diferencia entre predicted_price y drift_baseline es la corrección que aporta el modelo aprendido

Nombre del campo	Descripción	Cómo interpretar el resultado
	GRU sí mejora en el test reportado	sobre la simple extrapolación de tendencia
horizon_weeks / last_observed_date / prediction_date	Horizonte (siempre 16), última fecha del histórico y fecha objetivo de la predicción (last_observed_date + 16 semanas)	prediction_date es la fecha a la que se refiere predicted_price, no la fecha de ejecución
gap_warning	Aviso si el histórico aportado está desactualizado respecto a la fecha de ejecución	si no es null, la predicción se basa en datos que ya no reflejan la semana actual

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Cómo leo el resultado

Si el sistema recibe un histórico cuya última semana tiene un índice de 125,0 y predice 121,4 para 16 semanas después, mientras que el baseline de tendencia simple (drift_baseline) apuntaba a 117,7, la diferencia entre predicted_price y drift_baseline (3,7 puntos) es la corrección que aporta el modelo aprendido sobre limitarse a extrapolar la tendencia — una corrección que, según la evaluación de test, mejora la precisión frente a esa tendencia simple.

En la evaluación de test reportada (211 semanas), el modelo se equivoca de media unos 1,70 puntos de índice — menos que extrapolar simplemente la tendencia reciente sin ningún modelo aprendido (esa alternativa se equivoca de media 1,94 puntos). Es decir: el modelo aprendido sí aporta una mejora de precisión medible frente a la regla simple, con una exactitud direccional (acertar si sube o baja) del 77,7%.

5. Cuándo debo revisar manualmente

• Predicciones emitidas en periodos de shock de mercado, cambio regulatorio o geopolítico repentino en insumos agroquímicos — el modelo aprende de la dinámica histórica y no anticipa rupturas de esa dinámica.

• Cualquier histórico aportado con gap_warning distinto de null — indica que los datos de entrada ya están desactualizados respecto a la fecha de ejecución.

• Predicciones fuera del rango histórico de entrenamiento (2005-2025) — son extrapolaciones no validadas.

6. Qué no hace el modelo

• No sustituye el criterio experto de compras, y menos aún ante episodios de mercado extraordinarios.

• No predice precios oficiales por Comunidad Autónoma ni por explotación — solo el índice nacional.

• No sustituye automáticamente el modelo base al reentrenar: el modelo reentrenado solo se usa si se indica su run de MLflow.

• No garantiza que el precio real coincida con la predicción; es una estimación con margen de error medido, no un compromiso.

7. Puede equivocarse

Sí. En la evaluación de test reportada se equivoca de media unos 1,70 puntos de índice (MAPE 1,39%), una mejora clara frente a extrapolar simplemente la tendencia reciente, con un 77,7% de acierto direccional. Debe usarse como apoyo a la planificación de compras y a la evaluación de riesgo, nunca como sustituto del criterio experto ante cambios bruscos del mercado, shocks regulatorios o fallos en la actualización de las fuentes de datos.

8. KPIs del modelo

KPI	Valor objetivo / umbral	Descripción comprensible
Criterio de aceptación del proyecto: RMSE del modelo seleccionado < RMSE del baseline de Drift, en test	RMSE_GRU < RMSE_Drift	CUMPLE. RMSE GRU=2,2873 frente a RMSE Drift=2,5406 -- una mejora del 10,0%.

KPI	Valor objetivo / umbral	Descripción comprensible
Selección de mejor arquitectura entre GRU/LSTM/XGBoost	El modelo servido debe tener el menor RMSE de test entre las arquitecturas comparadas	CUMPLE. El GRU obtuvo el menor RMSE de test (2,2873 frente a 2,2983 LSTM y 3,3076 XGBoost).
Acierto direccional (sube/baja) en test	Sin umbral contractual explícito -- referencia de calidad complementaria	77,7% para el GRU frente a 72,0% del baseline de Drift -- también mejor en esta métrica secundaria.

TABLA 4 KPIS DEL MODELO

9. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Evaluación con un único split temporal (sin partición de validación separada)	Esta entrega evalúa arquitecturas y reporta el resultado final sobre el mismo split de test (80/20), sin una fase de validación previa aislada del test. Existe una copia distinta y no oficial de este mismo código (no confirmada como aprobada por el equipo de IA) que identificaba esto como una posible fuga de datos entre selección de arquitectura y evaluación, y que, con un protocolo corregido, obtenía un resultado distinto (un modelo que no superaba a Drift). Esa auditoría no se ha podido contrastar con el equipo de IA y no forma parte de la entrega aprobada -- se deja constancia de su existencia por transparencia, sin que determine el estado de aceptación de este modelo.
Reentrenamiento: requisitos y alcance	El reentrenamiento por usuario repite el procedimiento del equipo de IA para la GRU (split temporal 80/20, 3 semillas, se guarda la de la semilla 42) con un histórico semanal en el formato del dataset de modelado o con las series en bruto. Como en el original, la parada temprana se decide sobre el propio periodo de test, así que sus métricas de test son optimistas. El modelo reentrenado solo se guarda en MLflow y se usa indicando su run; el modelo base no cambia.
Reajuste de escaladores en caliente, no un artefacto congelado	Esta entrega no incluye ningún escalador serializado -- el propio código original reajusta (fit) los escaladores de entrada/objetivo desde el dataset de entrenamiento bundled en cada predicción. Este servicio replica exactamente ese comportamiento, empaquetando el mismo dataset de referencia junto al modelo.

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Dependencia de fuentes de datos externas y su continuidad	Las variables de entrada dependen de la publicación continuada de los índices MAPA (protección fitosanitaria, carburantes) y de las series FRED/IMF/EIA (cobre, gas, petróleo, tipo de cambio). Un cambio de metodología o una interrupción en cualquiera de esas fuentes no está contemplado por el modelo.

TABLA 5 LIMITACIONES CONOCIDAS