DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha técnica del modelo a14 · wine-phyto-price-forecast

Especificación técnica para integración en la plataforma DatagIA

Septiembre 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Información general del modelo

Nombre del modelo (model_key)	ml14-wine-phyto-price-forecast
Versión	1.0.0
Descripción	Modelo de predicción semanal del índice MAPA de precios de protección fitosanitaria (sector vitivinícola, base 2020=100) a 16 semanas vista, mediante una red GRU (PyTorch, 2 capas, 64 unidades ocultas) que predice un residual sobre un baseline lineal de drift y reconstruye el precio en escala original. Es el artefacto y la evaluación oficialmente aprobados por el equipo de IA: en el test reportado, el GRU supera al baseline lineal de Drift.
Tipo de tarea (task_type)	Regresión de serie temporal, horizonte fijo t+16 semanas (direct forecasting sobre residual de drift)
Framework	PyTorch (nn.GRU, 2 capas, hidden_size=64, dropout=0.3); scikit-learn (StandardScaler, reajustado desde el dataset de entrenamiento en cada predicción); pandas / numpy
Fichero del artefacto	gru_model.pt (state_dict PyTorch, 45.185 parámetros) + final_dataset_for_modeling.csv (dataset de referencia bundled, usado para reajustar los escaladores de entrada/objetivo en cada predicción, igual que hace el código original)
Objetivo del modelo	Anticipar con 16 semanas de antelación la evolución del índice nacional de precios de protección fitosanitaria, para dar soporte a la planificación de compras y a la evaluación de riesgo de coste del sector vitivinícola. En la evaluación de test reportada por el equipo de IA, el modelo GRU mejora de forma clara sobre el baseline de tendencia simple (Drift) y sobre no hacer ningún cambio (Naive).
Caso de uso principal	Modo predict inline y predict batch (idéntico cálculo, solo cambia el transporte del histórico — JSON o CSV): se aporta un histórico semanal continuo (frecuencia domingo, sin huecos ni duplicados) de al menos 24 semanas con 6 variables base (índice de protección fitosanitaria, carburantes, cobre, gas, petróleo Brent, tipo de cambio EUR/USD); el servicio deriva automáticamente las 39 features (estacionalidad, retardos de 4/8/12 semanas, medias móviles de 4/8 semanas, diferencia mensual) y devuelve el precio predicho a 16 semanas, el precio actual y el baseline de drift de referencia. También admite reentrenamiento por usuario (/train): con un histórico

	semanal propio repite el procedimiento del equipo de IA para la GRU y guarda el modelo resultante en MLflow, sin sustituir nunca el modelo base.

TABLA 1 INFORMACIÓN GENERAL DEL MODELO

2. Campos de entrada (inputs)

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
rows (histórico semanal, mínimo 24 filas)	list[dict]	Cada fila: date (YYYY-MM-DD, domingo), PROTECCION_FITO, CARBURANTES, COPPER_EUR_TON, GAS_EUR_MMBTU, COIL_EUR_BARRIL, DEXUSEU — todas índices/precios base 2020=100 o unidad de mercado (EUR/tonelada, EUR/MMBtu, EUR/barril, USD/EUR)	Sí — mínimo 24 filas semanales consecutivas sin huecos ni duplicados	-
MONTH, MONTH_SIN, MONTH_COS, *_LAG_{4,8,12}, *_MA_{4,8}, *_DIFF_MONTH (39 features totales)	float	Variables derivadas automáticamente del histórico aportado (estacionalidad, retardos autorregresivos, medias móviles, diferencia mensual) — nunca se piden al cliente	No — siempre calculadas por el servicio	derivadas del histórico

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Campos de salida (outputs)

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
predicted_price	float (índice base 2020=100)	PROTECCION_FITO predicho a 16 semanas vista	continuo, típicamente 80-135 (rango histórico del índice, 2005-2025)	valor esperado del índice nacional dentro de 16 semanas; comparar con current_price

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
				y drift_baseline
current_price	float	PROTECCION_FITO de la última fila del histórico aportado	igual rango que predicted_price	ancla de referencia inmediata
drift_baseline	float	Baseline lineal simple (extrapolación de la tendencia mensual reciente) — la referencia frente a la que el GRU sí mejora en el test reportado	igual rango que predicted_price	la diferencia entre predicted_price y drift_baseline es la corrección que aporta el modelo aprendido sobre la simple extrapolación de tendencia
horizon_weeks / last_observed_date / prediction_date	int / date / date	Horizonte (siempre 16), última fecha del histórico y fecha objetivo de la predicción (last_observed_date + 16 semanas)	-	prediction_date es la fecha a la que se refiere predicted_price, no la fecha de ejecución
gap_warning	string | null	Aviso si el histórico aportado está desactualizado respecto a la fecha de ejecución	-	si no es null, la predicción se basa en datos que ya no reflejan la semana actual

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Métricas de evaluación

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
Test reportado (models/metrics/model_comparison.json, split temporal único 80/20)	GRU: RMSE=2,2873; MAE=1,699; MAPE=1,3933%; R^2=0,7108; acierto direccional=77,7%	211 observaciones de test, arquitectura seleccionada automáticamente por menor RMSE entre GRU/LSTM/XGBoost (media de 3 semillas)	el modelo se equivoca de media 1,70 puntos de índice en el periodo evaluado
Drift (baseline lineal, mismo test)	RMSE=2,5406; MAE=1,9403; MAPE=1,58%; R^2=0,6432; acierto direccional=72,0%	Extrapolar la tendencia mensual reciente, sin ningún modelo aprendido	el GRU se equivoca MENOS que el baseline simple en las 4 métricas evaluadas — el criterio de aceptación del proyecto (RMSE_GRU < RMSE_Drift) SÍ se cumple.
Naive y XGBoost (mismo test, referencia adicional)	Naive: RMSE=3,8856; XGBoost: RMSE=3,3076	Ambos peores que Drift y que el GRU en esta evaluación	confirma que el GRU es la mejor opción disponible entre todas las evaluadas, no solo frente al baseline más simple
Verificación golden dataset (post-integración)	5/5 casos, coincidencia exacta (diferencia 0,0) contra el endpoint HTTP real	4 ventanas históricas reales + 1 caso de rechazo controlado, re-ejecutados contra	el servicio integrado reproduce exactamente el comportamiento del artefacto GRU

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
		/predict del plugin integrado, incluida una verificación cruzada contra la salida literal del CLI original (`--model auto`) — ver outputs/a14/verification_report.md	entregado, incluida la selección automática de arquitectura del código original.

TABLA 4 MÉTRICAS DE EVALUACIÓN

5. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Evaluación con un único split temporal (sin partición de validación separada)	Esta entrega evalúa arquitecturas y reporta el resultado final sobre el mismo split de test (80/20), sin una fase de validación previa aislada del test. Existe una copia distinta y no oficial de este mismo código (no confirmada como aprobada por el equipo de IA) que identificaba esto como una posible fuga de datos entre selección de arquitectura y evaluación, y que, con un protocolo corregido, obtenía un resultado distinto (un modelo que no superaba a Drift). Esa auditoría no se ha podido contrastar con el equipo de IA y no forma parte de la entrega aprobada -- se deja constancia de su existencia por transparencia, sin que determine el estado de aceptación de este modelo.
Reentrenamiento: requisitos y alcance	El reentrenamiento por usuario repite el procedimiento del equipo de IA para la GRU (split temporal 80/20, 3 semillas, se guarda la de la semilla 42) con un histórico semanal en el formato del dataset de modelado o con las series en bruto. Como en el original, la parada temprana se decide sobre el propio periodo de test, así que sus métricas de test son optimistas. El modelo reentrenado solo se guarda en MLflow y se usa indicando su run; el modelo base no cambia.

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Reajuste de escaladores en caliente, no un artefacto congelado	Esta entrega no incluye ningún escalador serializado -- el propio código original reajusta (fit) los escaladores de entrada/objetivo desde el dataset de entrenamiento bundled en cada predicción. Este servicio replica exactamente ese comportamiento, empaquetando el mismo dataset de referencia junto al modelo.
Dependencia de fuentes de datos externas y su continuidad	Las variables de entrada dependen de la publicación continuada de los índices MAPA (protección fitosanitaria, carburantes) y de las series FRED/IMF/EIA (cobre, gas, petróleo, tipo de cambio). Un cambio de metodología o una interrupción en cualquiera de esas fuentes no está contemplado por el modelo.

TABLA 5 LIMITACIONES CONOCIDAS

6. Observaciones técnicas

Solo CPU, sin GPU (GRU pequeño, 45.185 parámetros, ~185 KB el artefacto). requirements.txt fija torch==2.10.0 sin distinguir variante CPU/CUDA — se recomienda fijar explícitamente la rueda CPU en el entorno de despliegue de este servicio para no arrastrar dependencias CUDA innecesarias. No requiere conexión a red en inferencia (el dataset de referencia va bundled).

7. Fichero de prueba de referencia

Nombre del fichero	Ventanas de 24 filas extraídas de data/processed/final_dataset_for_modeling.csv (mismo dataset bundled con el que se reajustan los escaladores)
Número de registros / muestras	5 casos: 4 ventanas históricas reales (24-30 filas cada una) + 1 caso de rechazo controlado con 23 filas (por debajo del mínimo operativo)

Resultado esperado con este fichero	predict inline sobre los 5 casos reproduce exactamente (diferencia 0,0, o HTTP 422 en el caso de rechazo) los golden_cases del manifest, ejecutado contra el endpoint HTTP real del plugin integrado con el artefacto PyTorch real cargado; un caso se verificó además contra la salida literal del CLI original del equipo de IA

TABLA 6 FICHERO DE PRUEBA DE REFERENCIA