DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha funcional del modelo a15 · wine-ipi-price-forecast

Descripción de negocio para usuarios de la plataforma DatagIA

Septiembre 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Qué hace el modelo

Descripción	Modelo de predicción del Índice de Precios Fitosanitarios (IPI) nacional español para el sector vitivinícola, a seis meses vista (t+6), mediante una regresión Ridge (scikit-learn) sobre 16 variables autorregresivas, exógenas internacionales/financieras y estacionales, todas ya retardadas respecto al mes de origen. Es el único horizonte (de los cuatro evaluados: t+1, t+2, t+3, t+6) que supera de forma consistente el baseline de persistencia tanto en validación como en test hold-out.
Objetivo del modelo	Anticipar con seis meses de antelación la evolución del IPI fitosanitario nacional (precios de medios de protección fitopatológica en viticultura), para dar soporte a la planificación de compras, la evaluación de riesgos de coste y la toma de decisiones de aprovisionamiento del sector vitivinícola bajo incertidumbre de mercado.
Caso de uso principal	Modo predict inline: se aportan las 16 variables del contrato del artefacto, o solo un subconjunto (incluso solo 'date') — el resto se deriva automáticamente desde 'date'/'origin_date' y un histórico de referencia bundled (retardos autorregresivos y exógenos, más las 4 variables de calendario) — y se obtiene la predicción del IPI nacional a 6 meses vista. Modo predict batch: acepta un CSV con el panel completo (una fila = una predicción ya calculada) o un histórico simple mensual (date/year+month + ipi_national_current, igual que data/input/ipi_history.csv del equipo de IA), fusionando todas sus filas en el histórico de referencia para derivar cada predicción. Cada predicción indica el valor real ya observado a 6 meses (si existe) y avisa (feature_status/feature_notes) cuando alguna variable exógena se ha completado con su último dato publicado. Modo train: reentrena desde cero un Pipeline StandardScaler+Ridge(alpha=25.0) con el procedimiento original del equipo de IA — test = últimos 13 meses del panel, validación = los 12 anteriores, entrenamiento con las filas cuyo objetivo cae antes de la validación — y evalúa en test frente a la persistencia; sobre el panel entregado reproduce exactamente el artefacto y sus métricas. El artefacto fijo servido en producción nunca se sobrescribe.

TABLA 1 DESCRIPCIÓN GENERAL DEL MODELO

El modelo no predice precios oficiales por Comunidad Autónoma ni a nivel de explotación individual — solo el índice nacional. Tampoco predice otros

horizontes distintos de t+6 (t+1/t+2/t+3 quedaron descartados por no mejorar de forma fiable al baseline de persistencia), ni explica por sí mismo la causa de la subida o bajada prevista.

2. Qué necesito darle (entradas)

Los datos de entrada son índices y precios ya procesados (IPI nacional histórico, cotizaciones internacionales de materias primas y divisa), no mediciones directas de sensor ni formularios del usuario final — provienen de fuentes oficiales (MAPA, DEFRA, FRED, Yahoo Finance) ya agregadas a frecuencia mensual.

Nombre del campo	Descripción
ipi_national_current	Último IPI fitosanitario nacional observado en el mes de origen — ancla de la predicción
ipi_national_lag_1 … ipi_national_lag_6	IPI nacional observado entre 1 y 6 meses antes del mes de origen (6 retardos autorregresivos)
chem_sector_lag_11, copper_lag_14, eur_usd_lag_17, oil_brent_lag_12, usa_lag_1	Cinco variables exógenas retardadas: indicador sectorial químico, cobre, tipo de cambio EUR/USD, petróleo Brent y precios de pesticidas de EE. UU. — cada una con el retardo (en meses) que mostró mayor correlación anticipatoria en el análisis lead-lag del equipo de IA
month_sin, month_cos, quarter, is_spring_risk	Codificación estacional del mes de origen (ciclo anual, trimestre natural, riesgo fúngico primaveral abril-junio)
date / origin_date	Fecha de origen de la predicción — necesaria solo para derivar automáticamente las 4 variables de calendario si no se aportan ya calculadas

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Qué me devuelve (salidas)

Nombre del campo	Descripción	Cómo interpretar el resultado
y_pred	IPI fitosanitario nacional predicho a horizonte t+6	valor esperado del índice nacional dentro de 6 meses
y_anchor	ipi_national_current usado como ancla de referencia	compárese con y_pred para estimar la variación porcentual esperada
origin_date / target_date / horizon	Mes de origen, mes objetivo (origin_date + 6 meses) y horizonte en meses (siempre 6)	target_date es el mes al que se refiere y_pred, no el mes de los datos de entrada
xai_feature_values	Valores de las 16 features efectivamente usadas en la predicción	consumido por el servicio de explicabilidad para justificar la predicción

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Cómo leo el resultado

Si en enero de 2025 el sistema recibe un IPI nacional actual de 123,85 y predice y_pred=125,48 para julio de 2025, se interpreta como una subida esperada de aproximadamente el 1,3% en seis meses — una señal para revisar el calendario de compras de productos fitosanitarios antes de esa fecha, no una cifra de coste definitiva.

En las 8 predicciones de test con valor real disponible, el modelo se equivoca de media en torno a 0,94 puntos de índice (sobre un rango histórico habitual de 80 a 135), es decir, un error relativo medio del 0,74%, y acierta siempre la dirección del cambio (sube/baja) respecto al último valor conocido. Es una mejora clara sobre asumir simplemente que el precio no cambiará, pero la muestra de comparación es pequeña (8 meses), así que estas cifras deben leerse como una foto orientativa, no como una garantía estadística sólida.

5. Cuándo debo revisar manualmente

• Predicciones emitidas en periodos de shock de mercado, cambio regulatorio o geopolítico repentino en insumos agroquímicos — el modelo aprende de la dinámica histórica y no anticipa rupturas de esa dinámica.

• Cualquier predicción cuyo origin_date esté fuera del rango 2016-2026 usado en el entrenamiento — es una extrapolación no validada.

• Resultados del reentrenamiento (endpoint /train) sobre un histórico muy corto o con huecos — la calidad del modelo reentrenado depende directamente de la cantidad y continuidad de los datos aportados.

6. Qué no hace el modelo

• No sustituye el criterio experto de compras ante episodios de mercado extraordinarios.

• No predice precios oficiales por Comunidad Autónoma ni por explotación — solo el índice nacional.

• No garantiza que el precio real coincida con la predicción; es una estimación con margen de error, no un compromiso.

• No genera automáticamente la capa contextual regional documentada en la memoria original — esa funcionalidad no está incluida en este servicio.

7. Puede equivocarse

Sí. Sobre las 8 observaciones de test disponibles se equivoca de media unos 0,94 puntos de índice (0,74% de error relativo), una mejora clara frente a asumir que el precio no cambia, pero la muestra es pequeña y la propia memoria advierte de la limitada profundidad histórica del dataset (unos 10 años). Debe usarse como apoyo a la planificación de compras y a la evaluación de riesgo, nunca como sustituto del criterio experto ante cambios bruscos del mercado, shocks regulatorios o fallos en la actualización de las fuentes de datos.

8. KPIs del modelo

KPI	Valor objetivo / umbral	Descripción comprensible
KPI contractual de exactitud	>= 80% de exactitud (equivalente a MAPE <= 20%)	Resultado en test: MAPE=0,74% (exactitud del 99,26%) — cumplido con amplísimo margen.
Mejora frente al baseline de persistencia	El modelo debe mejorar al baseline tanto en validación como en test, sin usar el test para seleccionar la arquitectura	Cumplido: -5,90% de RMSE en validación y -54,04% en test — único horizonte (de 4 evaluados) que lo consigue de forma consistente.
Acierto direccional (MDA)	Sin umbral contractual explícito; referencia de calidad complementaria	100% en las 8 observaciones de test — el modelo acertó siempre si el índice subiría o bajaría respecto al último valor conocido.

TABLA 4 KPIS DEL MODELO

9. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Nombre de directorio potencialmente engañoso	La carpeta original entregada se llama 'a15-rnn-vitivinicola-...' y el glosario de la memoria incluye LSTM/GRU, pero el modelo productivo desplegado es una regresión Ridge lineal, no una red neuronal recurrente. No se ha podido confirmar si hubo una fase experimental con RNN descartada y no documentada.
Histórico de referencia bundled, no auto-actualizable	El servicio reconstruye los retardos automáticamente (igual que el pipeline original) a partir de dos CSV de referencia empaquetados junto al modelo (snapshot hasta feb-2026/jun-2026). Para fechas posteriores al snapshot hace falta aportar 'ipi_national_current' explícitamente (o, en modo batch, que el propio CSV de entrada incluya esos meses). El snapshot no se refresca solo — requiere que el equipo de IA regenere y resuba los ficheros de referencia periódicamente.
Capa regional contextual no incluida	La memoria documenta una 'capa regional contextual' por Comunidad Autónoma (cruce con RECAN/IPC/clima) como salida informativa adicional a la predicción nacional. No está implementada en este plugin — solo se

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
	sirve la predicción nacional a t+6. Queda como decisión de alcance para una futura iteración.
Bloque de evaluación reducido	Solo 8 de los 13 meses del test hold-out tienen valor real observado (los 5 restantes tienen fecha objetivo posterior al último dato disponible en la serie histórica, feb-2026). Las métricas de exactitud se apoyan en esas 8 observaciones — una muestra pequeña, como advierte la propia memoria.
R^2 modesto en test	El R^2 de test (0,175) es bajo en términos absolutos, aunque coherente con una serie muy persistente donde el baseline de persistencia obtiene R^2 negativo (-2,91). El MAPE (0,74%) y la mejora relativa frente al baseline son las métricas más informativas para este caso, no el R^2.
Reentrenamiento restringido al esquema fijo de 16 columnas	El código original del equipo de IA seleccionaba automáticamente cualquier columna numérica no excluida como feature al reentrenar. Este plugin restringe deliberadamente el reentrenamiento a las 16 columnas exactas del artefacto entregado, para evitar que un CSV de reentrenamiento introduzca columnas nuevas sin control. Por lo demás sigue el procedimiento original (splits por fecha, relleno de valores ausentes con 0 y evaluación en test frente a la persistencia); sobre el panel entregado el reentrenamiento reproduce el artefacto y las métricas de test de forma exacta.

TABLA 5 LIMITACIONES CONOCIDAS