DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha técnica del modelo a15 · wine-ipi-price-forecast

Especificación técnica para integración en la plataforma DatagIA

Septiembre 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Información general del modelo

Nombre del modelo (model_key)	ml15-wine-ipi-price-forecast
Versión	1.0.0
Descripción	Modelo de predicción del Índice de Precios Fitosanitarios (IPI) nacional español para el sector vitivinícola, a seis meses vista (t+6), mediante una regresión Ridge (scikit-learn) sobre 16 variables autorregresivas, exógenas internacionales/financieras y estacionales, todas ya retardadas respecto al mes de origen. Es el único horizonte (de los cuatro evaluados: t+1, t+2, t+3, t+6) que supera de forma consistente el baseline de persistencia tanto en validación como en test hold-out.
Tipo de tarea (task_type)	Regresión de serie temporal, horizonte fijo t+6 (direct multi-step forecasting)
Framework	scikit-learn (Pipeline: StandardScaler + Ridge, alpha=25.0); pandas / numpy / joblib
Fichero del artefacto	horizon_6_ridge.pkl (payload joblib: modelo + contrato de 16 feature_columns + metadatos de entrenamiento)
Objetivo del modelo	Anticipar con seis meses de antelación la evolución del IPI fitosanitario nacional (precios de medios de protección fitopatológica en viticultura), para dar soporte a la planificación de compras, la evaluación de riesgos de coste y la toma de decisiones de aprovisionamiento del sector vitivinícola bajo incertidumbre de mercado.
Caso de uso principal	Modo predict inline: se aportan las 16 variables del contrato del artefacto, o solo un subconjunto (incluso solo 'date') — el resto se deriva automáticamente desde 'date'/'origin_date' y un histórico de referencia bundled (retardos autorregresivos y exógenos, más las 4 variables de calendario) — y se obtiene la predicción del IPI nacional a 6 meses vista. Modo predict batch: acepta un CSV con el panel completo (una fila = una predicción ya calculada) o un histórico simple mensual (date/year+month + ipi_national_current, igual que data/input/ipi_history.csv del equipo de IA), fusionando todas sus filas en el histórico de referencia para derivar cada predicción. Cada predicción indica el valor real ya observado a 6 meses (si existe) y avisa (feature_status/feature_notes) cuando alguna variable exógena se ha completado con su último dato publicado. Modo train: reentrena desde cero un Pipeline

	StandardScaler+Ridge(alpha=25.0) con el procedimiento original del equipo de IA — test = últimos 13 meses del panel, validación = los 12 anteriores, entrenamiento con las filas cuyo objetivo cae antes de la validación — y evalúa en test frente a la persistencia; sobre el panel entregado reproduce exactamente el artefacto y sus métricas. El artefacto fijo servido en producción nunca se sobrescribe.

TABLA 1 INFORMACIÓN GENERAL DEL MODELO

2. Campos de entrada (inputs)

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
ipi_national_current	float (índice base 2020=100)	Último IPI fitosanitario nacional observado en el mes de origen — ancla de la predicción	No — se deriva del histórico de referencia bundled en 'date' si se omite; si se aporta, además sobrescribe ese histórico en esa fecha	derivado del histórico de referencia
ipi_national_lag_1 … ipi_national_lag_6	float (índice base 2020=100)	IPI nacional observado entre 1 y 6 meses antes del mes de origen (6 retardos autorregresivos)	No — se derivan del histórico de referencia bundled a partir de 'date' si se omiten	derivados del histórico de referencia
chem_sector_lag_11, copper_lag_14, eur_usd_lag_17,	float (índice base	Cinco variables exógenas retardadas: indicador sectorial químico, cobre, tipo de cambio EUR/USD,	No — se derivan del histórico	derivados del histórico

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
oil_brent_lag_12, usa_lag_1	2020=100)	petróleo Brent y precios de pesticidas de EE. UU. — cada una con el retardo (en meses) que mostró mayor correlación anticipatoria en el análisis lead-lag del equipo de IA	de referencia bundled a partir de 'date' si se omiten	de referencia
month_sin, month_cos, quarter, is_spring_risk	float / float / int / int(0-1)	Codificación estacional del mes de origen (ciclo anual, trimestre natural, riesgo fúngico primaveral abril-junio)	No — se derivan automáticamente si se aporta 'date'/'origin_date'	derivadas de date/origin_date
date / origin_date	string (YYYY-MM-DD)	Fecha de origen de la predicción — necesaria solo para derivar automáticamente las 4 variables de calendario si no se aportan ya calculadas	No (si ya se aportan las 4 variables de calendario)	-

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Campos de salida (outputs)

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
y_pred	float (índice base 2020=100)	IPI fitosanitario nacional predicho a horizonte t+6	continuo, típicamente 80-135 (rango histórico observado del índice)	valor esperado del índice nacional dentro de 6 meses
y_anchor	float	ipi_national_current usado como ancla de referencia	igual rango que y_pred	compárese con y_pred para estimar la variación porcentual esperada

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
origin_date / target_date / horizon	date / date / int	Mes de origen, mes objetivo (origin_date + 6 meses) y horizonte en meses (siempre 6)	-	target_date es el mes al que se refiere y_pred, no el mes de los datos de entrada
xai_feature_values	dict[str, float]	Valores de las 16 features efectivamente usadas en la predicción	-	consumido por el servicio de explicabilidad para justificar la predicción

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Métricas de evaluación

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
Test hold-out (memoria, Tabla 4 — Ridge_alpha_25.0, t+6)	RMSE=1,0396; MAE=0,9440; MAPE=0,7377%; R^2=0,1751; MDA=100%	8 observaciones evaluables de enero a agosto 2025 (origin_date), único bloque con y_true ya disponible en la serie IPI nacional	el modelo se equivoca de media 0,94 puntos de índice; acierta el 100% de las veces la dirección del cambio respecto al último valor observado
Mejora frente a baseline de persistencia (test)	RMSE -54,04%; MAPE -54,88% (baseline RMSE=2,2619, MAPE=1,6350%)	models/metrics/final_evaluation.json — comparación frente a predecir simplemente el último valor observado	la mejora es sustancial y se mantiene tanto en validación (-5,90%) como en test, criterio central de selección del horizonte t+6

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
Validación fija (memoria, Tabla 3 — criterio real de selección de modelo)	RMSE=1,2584; MAE=1,0595; MAPE=0,8495%; mejora RMSE vs. naive=-5,90%	12 observaciones, enero-diciembre 2024 — único horizonte (de t+1/t+2/t+3/t+6) donde un modelo aprendido mejora al baseline de persistencia en esta fase	el test nunca se usó para elegir la arquitectura; esta es la evidencia que motivó restringir el despliegue a t+6
Verificación golden dataset (post-integración)	13/13 casos, coincidencia exacta (diferencia 0,0) contra el endpoint HTTP real	Los 13 meses del split de test (data/splits/test/panel_test.csv) re-ejecutados contra /predict del plugin integrado — ver outputs/a15/verification_report.md	el servicio integrado reproduce exactamente el comportamiento del artefacto entregado; es fidelidad del wiring, no acierto adicional del modelo
Verificación histórico simple de IPI (corrección post-review)	15/15 filas de data/input/ipi_history.csv, 0 errores, 13/13 coinciden con el golden dataset	El histórico mensual simple del equipo de IA (solo date+ipi_national_current, sin las 15 features restantes) ejecutado contra /predict batch real tras añadir la derivación automática desde el histórico de referencia bundled	confirma que el modo de entrada más simple para el usuario final (solo el valor actual del índice) funciona igual de bien que el panel técnico completo

TABLA 4 MÉTRICAS DE EVALUACIÓN

5. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Nombre de directorio potencialmente engañoso	La carpeta original entregada se llama 'a15-rnn-vitivinicola-...' y el glosario de la memoria incluye LSTM/GRU, pero el modelo productivo desplegado es una regresión Ridge lineal, no una red neuronal recurrente. No se ha podido confirmar si hubo una fase experimental con RNN descartada y no documentada.
Histórico de referencia bundled, no auto-actualizable	El servicio reconstruye los retardos automáticamente (igual que el pipeline original) a partir de dos CSV de referencia empaquetados junto al modelo (snapshot hasta feb-2026/jun-2026). Para fechas posteriores al snapshot hace falta aportar 'ipi_national_current' explícitamente (o, en modo batch, que el propio CSV de entrada incluya esos meses). El snapshot no se refresca solo — requiere que el equipo de IA regenere y resuba los ficheros de referencia periódicamente.
Capa regional contextual no incluida	La memoria documenta una 'capa regional contextual' por Comunidad Autónoma (cruce con RECAN/IPC/clima) como salida informativa adicional a la predicción nacional. No está implementada en este plugin — solo se sirve la predicción nacional a t+6. Queda como decisión de alcance para una futura iteración.
Bloque de evaluación reducido	Solo 8 de los 13 meses del test hold-out tienen valor real observado (los 5 restantes tienen fecha objetivo posterior al último dato disponible en la serie histórica, feb-2026). Las métricas de exactitud se apoyan en esas 8 observaciones — una muestra pequeña, como advierte la propia memoria.
R^2 modesto en test	El R^2 de test (0,175) es bajo en términos absolutos, aunque coherente con una serie muy persistente donde el baseline de persistencia obtiene R^2 negativo (-2,91). El MAPE (0,74%) y la mejora relativa frente al baseline son las métricas más informativas para este caso, no el R^2.
Reentrenamiento restringido al esquema fijo de 16 columnas	El código original del equipo de IA seleccionaba automáticamente cualquier columna numérica no excluida como feature al reentrenar. Este plugin restringe deliberadamente el reentrenamiento a las 16 columnas exactas del artefacto entregado, para evitar que un CSV de reentrenamiento introduzca columnas nuevas sin control. Por lo demás sigue el procedimiento original (splits por fecha, relleno de valores ausentes con

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
	0 y evaluación en test frente a la persistencia); sobre el panel entregado el reentrenamiento reproduce el artefacto y las métricas de test de forma exacta.

TABLA 5 LIMITACIONES CONOCIDAS

6. Observaciones técnicas

Solo CPU, sin GPU (regresión lineal regularizada sobre 16 features tabulares). Artefacto muy ligero (~3 KB). El artefacto se serializó con scikit-learn==1.8.0; cargarlo con otra versión genera avisos de compatibilidad (InconsistentVersionWarning) sin alterar el resultado numérico: con la versión desplegada en la plataforma (1.5.2) los 13 casos de test y las métricas oficiales se reproducen exactamente. No requiere conexión a red ni GPU en inferencia.

7. Fichero de prueba de referencia

Nombre del fichero	data/splits/test/panel_test.csv (13 filas, enero 2025 - enero 2026)
Número de registros / muestras	13 predicciones — 8 con valor real disponible (ene-ago 2025), 5 sin valor real aún (sep 2025-ene 2026, fecha objetivo posterior al último dato de la serie)
Resultado esperado con este fichero	predict inline sobre las 13 filas reproduce exactamente (diferencia 0,0) los 13 golden_cases del manifest, ejecutado contra el endpoint HTTP real del plugin integrado, no solo contra una llamada directa en Python

TABLA 6 FICHERO DE PRUEBA DE REFERENCIA