DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha funcional del modelo a18 · meat-spatial-price-forecast

Descripción de negocio para usuarios de la plataforma DatagIA

Octubre 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Qué hace el modelo

Descripción	Modelo de predicción espacio-temporal del precio medio por kg de productos cárnicos en España, a un mes vista, por combinación Comunidad Autónoma (CCAA) - Producto, mediante una red GRU (Keras/TensorFlow) que incorpora lags espaciales de las CCAA vecinas además de variables socioeconómicas (población, renta) y de consumo (MAPA/INE).
Objetivo del modelo	Anticipar con un mes de antelación la evolución del precio medio por kg de productos cárnicos en cada Comunidad Autónoma, incorporando la influencia de los mercados de regiones vecinas, para dar soporte a la planificación de compras y a la evaluación de riesgo de coste en la cadena de suministro cárnica. El caso de uso de negocio (CU06) define el objetivo central y validado como la predicción espacio-temporal del precio -- la lectura adicional de 'modas y gustos' del título original se ofrece como interpretación exploratoria, no como resultado cuantificado de forma independiente.
Caso de uso principal	Modo predict inline y predict batch (idéntico cálculo, solo cambia el transporte del panel -- JSON o CSV): se aporta un panel mensual de al menos 12 meses consecutivos por cada combinación CCAA-Producto que se quiera predecir (Fecha, CCAA, Producto, Poblacion, RentaHogar, CONSUMO X CAPITA, PENETRACION (%), PRECIO MEDIO KG). Opcionalmente se puede aportar también el histórico de las CCAA vecinas para que el lag espacial use su valor real; si no se aporta, el servicio usa el propio valor de la CCAA como alternativa razonable (mismo comportamiento que el código original, documentado explícitamente en la memoria). El servicio genera automáticamente la fila del mes siguiente a predecir -- no hace falta aportarla. También admite reentrenamiento por usuario (/train): con un CSV en el mismo formato que el dataset de modelado del equipo de IA, repite su procedimiento completo (GRU desde cero, split temporal 70/15/15, parada temprana) y guarda el modelo resultante en MLflow, sin sustituir nunca el modelo base.

TABLA 1 DESCRIPCIÓN GENERAL DEL MODELO

El modelo no explica por sí mismo la causa de la subida o bajada de precio prevista. No incorpora eventos futuros conocidos (cambios regulatorios, crisis sanitarias, roturas de stock) que no estén ya reflejados en la tendencia histórica. La

interpretación de 'modas y gustos de consumo' es exploratoria, no una medida validada de forma independiente -- el resultado cuantificado y aceptado es la predicción de precio.

2. Qué necesito darle (entradas)

Los datos de entrada son indicadores ya procesados de fuentes oficiales (MAPA para consumo/precio/penetración por CCAA y producto cárnico; INE para población y renta por hogar), agregados a frecuencia mensual -- no son mediciones directas de sensor ni formularios rellenados por el usuario final.

Nombre del campo	Descripción
rows (panel mensual, mínimo 12 filas por combinación CCAA-Producto)	Cada fila: Fecha (YYYY-MM-01), CCAA, Producto, Poblacion, RentaHogar, CONSUMO X CAPITA, PENETRACION (%), PRECIO MEDIO KG (opcional solo en la última fila conocida)
month_sin, month_cos, PRECIO_MEDIO_KG_PROPIO, LAG_CONSUMO_VECINOS, LAG_PRECIO_VECINOS	Variables derivadas automáticamente (estacionalidad, precio propio rezagado, lags espaciales de CCAA vecinas) -- nunca se piden al cliente

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Qué me devuelve (salidas)

Nombre del campo	Descripción	Cómo interpretar el resultado
predictions[].predicted_price	Precio medio por kg predicho para el mes siguiente al histórico aportado	valor esperado del precio dentro de un mes para esa combinación CCAA-Producto
predictions[].CCAA / Producto / Fecha	Identificación de la combinación predicha y el mes al que se refiere la predicción	una entrada por cada combinación CCAA-Producto del payload con histórico suficiente

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Cómo leo el resultado

Si el sistema recibe el histórico de los últimos 12 meses de CARNE POLLO en ANDALUCIA (incluyendo, si está disponible, el de sus CCAA vecinas EXTREMADURA, CASTILLA LA MANCHA y MURCIA) y predice un precio de 4,54 €/kg para el mes siguiente, esa cifra puede compararse con el precio del último mes conocido para estimar la variación esperada -- útil para anticipar el presupuesto de compra del mes próximo.

En la evaluación de test (11.600 observaciones, 2021-2023), el modelo se equivoca de media un 9,93% del precio real (MAPE), muy por debajo del umbral de aceptación del 20% definido en la memoria -- equivalente a ±1,37 €/kg de desviación sobre el precio medio del dataset (6,84 €/kg). Es una mejora clara frente a los baselines simples evaluados (14,12% y 20,29% de error).

5. Cuándo debo revisar manualmente

- Predicciones en periodos de shock de mercado, crisis sanitaria animal o cambio regulatorio repentino -- el modelo aprende de la dinámica histórica y no anticipa rupturas de esa dinámica.
- Predicciones para Baleares o Canarias -- al no tener CCAA vecina definida, el componente espacial del modelo no aporta señal adicional para estas dos regiones.
- Si el MAPE operativo observado supera el 15% durante 3 ejecuciones consecutivas, o aumenta 2 puntos porcentuales frente al baseline de producción -- la propia memoria recomienda reentrenamiento en ese caso.

6. Qué no hace el modelo

- No sustituye el criterio experto de compras ante episodios de mercado extraordinarios.
- No predice precios a nivel de explotación individual -- solo el promedio por CCAA y producto.
- No sustituye automáticamente el modelo base al reentrenar: el modelo reentrenado solo se usa si se indica su run de MLflow.

• No cuantifica ni valida de forma independiente la interpretación de 'modas y gustos de consumo' -- solo el precio medio predicho.

7. Puede equivocarse

Sí. En la evaluación de test se equivoca de media un 9,93% del precio real -- una mejora clara frente a los baselines simples (14-20% de error), pero no una garantía exacta. Debe usarse como apoyo a la planificación de compras y a la evaluación de riesgo, nunca como sustituto del criterio experto ante cambios bruscos del mercado o fallos en la actualización de las fuentes de datos oficiales (MAPA/INE).

8. KPIs del modelo

KPI	Valor objetivo / umbral	Descripción comprensible
Criterio de aceptación del proyecto: MAPE de test	MAPE <= 20% (memoria, sección 'Validación temporal y calibración de umbrales')	CUMPLE con amplio margen: MAPE test = 9,93% (exactitud del 90,07%).
Consistencia validación -> test (ausencia de sobreajuste)	El MAPE de test no debe degradarse sustancialmente frente al de validación	CUMPLE: val_MAPE=9,97% frente a test_MAPE=9,93% -- de hecho mejora ligeramente.
Aportación de los lags espaciales	El modelo con lags espaciales debe mejorar frente al mismo modelo sin ellos	CUMPLE (memoria, impacto de la matriz de vecindad): val_MAPE pasa de 27,26% (sin vecindad) a 10,76% (con vecindad) en la fase de ablación específica de este componente.

TABLA 4 KPIS DEL MODELO

9. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Frecuencia mensual	El modelo opera con granularidad mensual. Aunque esto aporta estabilidad y reduce el ruido, no captura fluctuaciones de precio intramensuales que podrían ser relevantes para decisiones de inventario de muy corto

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
	plazo en productos perecederos (advertencia explícita de la memoria).
Deriva de datos entre validación y test	La memoria documenta un descenso del R^2 de 0,843 en validación a 0,811 en test, y recomienda una alerta operativa si el MAPE de inferencia supera el 15% durante 3 ejecuciones consecutivas, o un reentrenamiento programado trimestral.
Fallback a valor propio en CCAA sin vecindad geográfica (Baleares, Canarias)	El lag espacial de estas dos comunidades insulares usa su propio valor como aproximación (no hay CCAA vecina definida en la matriz de vecindad). Es un comportamiento documentado y verificado (ver golden_cases caso Baleares), no un error -- pero implica que la señal espacial no aporta información adicional para estas dos regiones.
Reentrenamiento: requisitos y coste	El reentrenamiento por usuario repite el procedimiento del equipo de IA desde cero (no ajuste fino) y necesita un histórico mensual en el formato del dataset de modelado con suficientes fechas para el split temporal 70/15/15 y más de 12 meses por combinación CCAA-Producto. Con el dataset completo tarda unos 2,5 minutos en CPU dentro de la petición. El modelo reentrenado solo se guarda en MLflow y se usa indicando su run; el modelo base no cambia.
Dependencia de fuentes de datos externas (MAPA/INE)	El dataset depende de la publicación anual del panel de consumo MAPA y de los indicadores de población/renta del INE (este último con hasta 12 meses de retraso). Si una fuente no se actualiza, el modelo en producción sigue siendo válido para el periodo anterior, pero no debe reentrenarse hasta restablecer los datos (protocolo explícito en el README).

TABLA 5 LIMITACIONES CONOCIDAS