DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha técnica del modelo a18 · meat-spatial-price-forecast

Especificación técnica para integración en la plataforma DatagIA

Octubre 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Información general del modelo

Nombre del modelo (model_key)	ml18-meat-spatial-price-forecast
Versión	1.0.0
Descripción	Modelo de predicción espacio-temporal del precio medio por kg de productos cárnicos en España, a un mes vista, por combinación Comunidad Autónoma (CCAA) - Producto, mediante una red GRU (Keras/TensorFlow) que incorpora lags espaciales de las CCAA vecinas además de variables socioeconómicas (población, renta) y de consumo (MAPA/INE).
Tipo de tarea (task_type)	Regresión de serie temporal espacial (panel CCAA x Producto), horizonte fijo t+1 mes
Framework	TensorFlow/Keras (GRU, 96 unidades, Dropout 0.2, Dense 32 + Dense 1); scikit-learn (StandardScaler, serializado como JSON); pandas / numpy
Fichero del artefacto	model.joblib (bundle {model_json, weights} de un modelo Keras Sequential) + x_scaler.json + y_scaler.json
Objetivo del modelo	Anticipar con un mes de antelación la evolución del precio medio por kg de productos cárnicos en cada Comunidad Autónoma, incorporando la influencia de los mercados de regiones vecinas, para dar soporte a la planificación de compras y a la evaluación de riesgo de coste en la cadena de suministro cárnica. El caso de uso de negocio (CU06) define el objetivo central y validado como la predicción espacio-temporal del precio -- la lectura adicional de 'modas y gustos' del título original se ofrece como interpretación exploratoria, no como resultado cuantificado de forma independiente.
Caso de uso principal	Modo predict inline y predict batch (idéntico cálculo, solo cambia el transporte del panel -- JSON o CSV): se aporta un panel mensual de al menos 12 meses consecutivos por cada combinación CCAA-Producto que se quiera predecir (Fecha, CCAA, Producto, Poblacion, RentaHogar, CONSUMO X CAPITA, PENETRACION (%), PRECIO MEDIO KG). Opcionalmente se puede aportar también el histórico de las CCAA vecinas para que el lag espacial use su valor real; si no se aporta, el servicio usa el propio valor de la CCAA como alternativa razonable (mismo comportamiento que el código original, documentado explícitamente en la memoria). El servicio genera automáticamente la fila del

	mes siguiente a predecir -- no hace falta aportarla. También admite reentrenamiento por usuario (/train): con un CSV en el mismo formato que el dataset de modelado del equipo de IA, repite su procedimiento completo (GRU desde cero, split temporal 70/15/15, parada temprana) y guarda el modelo resultante en MLflow, sin sustituir nunca el modelo base.

TABLA 1 INFORMACIÓN GENERAL DEL MODELO

2. Campos de entrada (inputs)

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
rows (panel mensual, mínimo 12 filas por combinación CCAA-Producto)	list[dict]	Cada fila: Fecha (YYYY-MM-01), CCAA, Producto, Poblacion, RentaHogar, CONSUMO X CAPITA, PENETRACION (%), PRECIO MEDIO KG (opcional solo en la última fila conocida)	Sí -- mínimo 12 meses consecutivos por cada combinación CCAA-Producto a predecir	-
month_sin, month_cos, PRECIO_MEDIO_KG_PROPIO, LAG_CONSUMO_VECINOS, LAG_PRECIO_VECINOS	float	Variables derivadas automáticamente (estacionalidad, precio propio rezagado, lags espaciales de CCAA vecinas) -- nunca se piden al cliente	No -- siempre calculadas por el servicio	derivadas del histórico

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Campos de salida (outputs)

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
predictions[].predicted_price	float (€/kg)	Precio medio por kg predicho para el mes siguiente al histórico aportado	continuo, positivo, típicamente 2-15 €/kg según producto	valor esperado del precio dentro de un mes para esa combinación CCAA-Producto

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
predictions[].CCAA / Producto / Fecha	str / str / date	Identificación de la combinación predicha y el mes al que se refiere la predicción	-	una entrada por cada combinación CCAA-Producto del payload con histórico suficiente

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Métricas de evaluación

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
Test holdout (split cronológico 70/15/15, 11.600 observaciones)	MAE=1,0041; RMSE=2,2113; MAPE=9,93%; R^2=0,811	models/metrics/inference_metrics.json y models/artifacts/best_gru_df_2008_con_renta/metrics.json -- ambos reproducidos de forma independiente en este proceso de extracción	el modelo se equivoca de media un 9,93% en precio, muy por debajo del umbral de aceptación del 20% definido en la memoria
Baselines de comparación (mismo test)	Naive estacional (lag-12): MAPE=14,12%, R^2=0,673; Media histórica: MAPE=20,29%, R^2=0,616	Referencias mínimas evaluadas antes de consolidar el GRU	el GRU mejora sustancialmente sobre ambos baselines, confirmando que el modelo aprendido aporta valor real
Estudio de ablación (impacto del precio	Sin ninguna señal de precio: MAPE=31,03%; con	4 variantes comparadas: sin propio/con vecino	alguna señal de precio (propio o espacial) es

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
propio y los lags espaciales)	precio propio y vecino (configuración final): MAPE=9,93%	(12,15%), con propio/sin vecino (10,12%), con propio y vecino (9,93%, final), sin ninguno (31,03%)	indispensable; las variables de demanda/renta por sí solas no bastan
Verificación golden dataset (post-integración)	5/5 casos, coincidencia exacta o sub-0,001% (diferencia de float32) contra el endpoint HTTP real	4 combinaciones CCAA-Producto reales + 1 caso de rechazo controlado, re-ejecutados contra /predict del plugin integrado, cruzados además contra la salida literal del CLI original (--forecast y --backtest) -- ver outputs/a18/verification_report.md	el servicio integrado reproduce exactamente el comportamiento del artefacto GRU entregado, incluido el caso de una CCAA insular sin vecinas (Baleares)

TABLA 4 MÉTRICAS DE EVALUACIÓN

5. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Frecuencia mensual	El modelo opera con granularidad mensual. Aunque esto aporta estabilidad y reduce el ruido, no captura fluctuaciones de precio intramensuales que podrían ser relevantes para decisiones de inventario de muy corto plazo en productos perecederos (advertencia explícita de la memoria).
Deriva de datos entre validación y test	La memoria documenta un descenso del R^2 de 0,843 en validación a 0,811 en test, y recomienda una alerta operativa si el MAPE de inferencia supera el 15% durante 3 ejecuciones consecutivas, o un reentrenamiento programado trimestral.

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Fallback a valor propio en CCAA sin vecindad geográfica (Baleares, Canarias)	El lag espacial de estas dos comunidades insulares usa su propio valor como aproximación (no hay CCAA vecina definida en la matriz de vecindad). Es un comportamiento documentado y verificado (ver golden_cases caso Baleares), no un error -- pero implica que la señal espacial no aporta información adicional para estas dos regiones.
Reentrenamiento: requisitos y coste	El reentrenamiento por usuario repite el procedimiento del equipo de IA desde cero (no ajuste fino) y necesita un histórico mensual en el formato del dataset de modelado con suficientes fechas para el split temporal 70/15/15 y más de 12 meses por combinación CCAA-Producto. Con el dataset completo tarda unos 2,5 minutos en CPU dentro de la petición. El modelo reentrenado solo se guarda en MLflow y se usa indicando su run; el modelo base no cambia.
Dependencia de fuentes de datos externas (MAPA/INE)	El dataset depende de la publicación anual del panel de consumo MAPA y de los indicadores de población/renta del INE (este último con hasta 12 meses de retraso). Si una fuente no se actualiza, el modelo en producción sigue siendo válido para el periodo anterior, pero no debe reentrenarse hasta restablecer los datos (protocolo explícito en el README).

TABLA 5 LIMITACIONES CONOCIDAS

6. Observaciones técnicas

Solo CPU, sin GPU (GRU pequeño, arquitectura 96 unidades). El modelo se serializa como bundle joblib {model_json, weights}, no en formato nativo .keras/.h5 -- la reconstrucción usa tf.keras.models.model_from_json + set_weights, igual que el código original. requirements.txt del entregable fija tensorflow==2.20.0; el repo ya tiene tensorflow>=2.15.0 como dependencia para otro plugin (ml3), sin conflicto de versión.

7. Fichero de prueba de referencia

Nombre del fichero	Ventanas reales de 12 meses (+ histórico de CCAA vecinas cuando existen) extraídas de data/processed/model_ready/dataset_modelado_desde_2008.csv
Número de registros / muestras	5 casos: 4 combinaciones CCAA-Producto reales (incluida una CCAA insular sin vecinas) + 1 caso de rechazo controlado con 11 filas (por debajo del mínimo de 12)
Resultado esperado con este fichero	predict inline sobre los 5 casos reproduce exactamente (o con diferencia de float32 irrelevante) los golden_cases del manifest, ejecutado contra el endpoint HTTP real del plugin integrado con el artefacto TensorFlow/Keras real cargado, cruzado además contra la salida literal del CLI original del equipo de IA en modo --forecast y --backtest

TABLA 6 FICHERO DE PRUEBA DE REFERENCIA