DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha técnica del modelo a21 · cereals-price-spatial

Especificación técnica para integración en la plataforma DatagIA

Octubre 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Información general del modelo

Nombre del modelo (model_key)	ml21-cereals-price-spatial
Versión	1.0
Descripción	Sistema de predicción de precios cerealísticos a nivel provincial español que combina regresión de retorno porcentual y clasificación direccional calibrada en una arquitectura de ensambles de árboles multi-horizonte (H1=30d, H2=60d, H3=90d). Integra una capa espacial y logística con variables de distancia a puertos, presión de combustible y análisis de vecindad provincial para identificar oportunidades de arbitraje geográfico.
Tipo de tarea (task_type)	regresión + clasificación (multi-horizonte)
Framework	scikit-learn (ExtraTreesRegressor, LogisticRegression), XGBoost (XGBRegressor)
Fichero del artefacto	6 modelos .joblib (datagia_best_h{1,2,3}_{reg,clf}.joblib) + model_metadata.json
Objetivo del modelo	Proporcionar una señal mensual de dirección (compra/venta/espera) y magnitud del retorno porcentual del precio de trigo, cebada y maíz a nivel provincial en España, a horizontes de 30, 60 y 90 días, integrando fundamentales macroeconómicos, variables climáticas y una capa de análisis espacial-logístico que capture la fricción de costes de transporte y la eficiencia en la transmisión de precios entre mercados regionales.
Caso de uso principal	Se utiliza como herramienta de soporte a la decisión en mesas de compras cerealistas: ante la necesidad de planificar inventarios o negociar suministros, el operador selecciona una provincia, cereal y mes de interés, y el sistema devuelve una recomendación táctica (COMPRAR/ESPERAR/VENDER) con nivel de confianza por horizonte temporal, además de rankings provinciales de arbitraje en modo batch para comparar oportunidades geográficas.

TABLA 1 INFORMACIÓN GENERAL DEL MODELO

2. Campos de entrada (inputs)

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
provincia	str	Provincia española productora (Burgos, Zamora, Córdoba, etc.). Se codifica como one-hot.	Sí	-
cereal_predominante	str	Tipo de cereal predominante: trigo, cebada o maíz. Se codifica como one-hot.	Sí	-
date	str (YYYY-MM)	Mes de predicción. Determina fase fenológica, lags temporales y ventana de features.	Sí	-
corn_intl_eur_*	float	Cotizaciones internacionales de maíz (MATIF/CBOT) con lags 1-3 meses, media móvil 3 meses y volatilidad 3 meses, convertidos a EUR.	Sí (derivado del pipeline ETL)	-
wheat_intl_eur_*	float	Cotizaciones internacionales de trigo con lags 1-3, MA3 y vol3 en EUR.	Sí (derivado del pipeline ETL)	-
eur_usd_lag_1/2	float	Paridad EUR/USD con 1 y 2 meses de retardo.	Sí (derivado del pipeline ETL)	-
idx_*_lag_3/4	float	Índices MAPA de costes: fertilizantes, fitosanitarios, semillas, energía, con lags 3-4 meses.	Sí (derivado del pipeline ETL)	-
prepag1/2_*_lag_3/4	float	Costes prepagados: urea, DAP, paja cereales, torta girasol, con lags 3-4 meses.	Sí (derivado del	-

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
			pipeline ETL)	
precip_provincial_lag_1/2	float (mm)	Precipitación provincial con lags 1-2 meses, incluyendo desviación estándar y shock relativo.	Sí (derivado del pipeline ETL)	-
temp_provincial_*	float (°C)	Variables de temperatura provincial (media, máxima, mínima) y anomalía.	Sí (derivado del pipeline ETL)	-
z_clima_adverso_*	float	Z-scores de anomalía climática para identificar eventos extremos.	Sí (derivado del pipeline ETL)	-
sup_cereal_predominante_lag_1	float (ha)	Superficie sembrada del cereal predominante con 1 mes de retardo.	Sí (derivado del pipeline ETL)	-
dist_puerto_min_km	float (km)	Distancia mínima geodésica (Haversine) al puerto de referencia más cercano.	Sí (derivado del pipeline ETL)	-
presion_combustible_puerto	float	Índice de presión de costes de combustible vinculado a la distancia al nodo logístico.	Sí (derivado del pipeline ETL)	-
provincia_*	float (one-hot)	Codificación one-hot de 23 provincias productoras.	Sí (derivado del pipeline ETL)	-

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
fase_siembra/crecimiento/cosecha	float	Marcadores binarios de fase fenológica del cereal según el mes.	Sí (derivado del pipeline ETL)	-
month_sin/month_cos	float	Codificación cíclica trigonométrica del mes del año.	Sí (derivado del pipeline ETL)	-

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Campos de salida (outputs)

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
signal_h1/h2/h3	str (ALCISTA/BAJISTA/NEUTRAL)	Señal de tendencia por horizonte temporal según umbrales de retorno y probabilidad calibrados.	ALCISTA, BAJISTA o NEUTRAL	ALCISTA indica oportunidad de compra con retorno esperado positivo y alta probabilidad; BAJISTA indica venta o espera; NEUTRAL indica zona de baja confianza.
confidence_h1/h2/h3	float (%)	Nivel de confianza de la señal, basado en la probabilidad calibrada del clasificador.	0-100%	Valores >60% indican alta fiabilidad de la señal; 40-60% zona de cautela; <40% señal no operativa.
expected_return_h1/h2/h3	float (fracción)	Retorno porcentual esperado estimado	Continuo (típicamente -0.05 a +0.05)	Valor positivo indica retorno esperado

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
		por el regresor para cada horizonte.		alcista; negativo bajista. Se interpreta como fracción del precio actual.
prob_up_h1/h2/h3	float	Probabilidad calibrada de movimiento alcista según el clasificador.	0-1	Probabilidad de que el precio suba en el horizonte indicado. Umbral de referencia: 0.65 para señal alcista.
timing_label	str	Etiqueta de recomendación táctica consolidada.	COMPRA YA / VENDE YA / ESPERA / SEGUIMIENTO ACTIVO	Resumen ejecutivo de la acción recomendada según la alineación de horizontes y umbrales.
geo_risk	bool	Indicador de riesgo geográfico alto basado en distancia a puertos y presión de combustible.	True/False	True indica que la provincia tiene alta fricción logística, lo que puede degradar la rentabilidad del arbitraje.
causal_drivers	list[str]	Top 3 factores causales con dirección e intensidad que explican la señal.	Lista de hasta 3 elementos	Permite al usuario entender qué fundamentales están impulsando la recomendación.

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
card_text	str	Ficha de decisión completa en texto plano con resumen ejecutivo.	Texto libre	Documento legible para el operador que consolida la información de los 3 horizontes.

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Métricas de evaluación

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
MAE H1 (regresión)	0.0508	Error absoluto medio en retorno porcentual para el horizonte de 30 días en test.	El modelo se equivoca de media 5.08 puntos porcentuales en la estimación del retorno a 30 días.
Pearson R H1	0.3785	Correlación de Pearson entre retorno predicho y real en test (H1).	Correlación moderada positiva: el modelo captura la tendencia directionally en el corto plazo.
DA H1 (Direction Accuracy)	55.91%	Porcentaje de aciertos directionales en el horizonte de 30 días.	El modelo acierta la dirección del movimiento en más de la mitad de los casos en H1.
AUC H1 (clasificación)	0.7116	Área bajo la curva ROC del clasificador calibrado para H1.	Capacidad discriminativa buena: separa señales alcistas

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
			reales de ruido con 71.2% de capacidad.
MAE H2 (regresión)	0.0674	Error absoluto medio en retorno porcentual para el horizonte de 60 días en test.	El modelo se equivoca de media 6.74 puntos porcentuales en la estimación del retorno a 60 días.
Pearson R H2	0.2653	Correlación de Pearson entre retorno predicho y real en test (H2).	Correlación moderada: el modelo mantiene capacidad predictiva en el medio plazo.
DA H2 (Direction Accuracy)	56.56%	Porcentaje de aciertos directionales en el horizonte de 60 días.	H2 alcanza la mayor exactitud global (67.3%) y cobertura (54.7%) entre los horizontes.
AUC H2 (clasificación)	0.7441	Área bajo la curva ROC del clasificador calibrado para H2.	Mejor capacidad discriminativa que H1: el horizonte medio es el más equilibrado.
MAE H3 (regresión)	0.1012	Error absoluto medio en retorno porcentual para el horizonte de 90 días en test.	El error crece con el horizonte, esperado por la mayor incertidumbre a largo plazo.
Pearson R H3	0.2093	Correlación de Pearson entre	Correlación menor pero aún

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
		retorno predicho y real en test (H3).	significativa dado el protocolo de Blacklist Nuclear (sin lags de precio).
DA H3 (Direction Accuracy)	62.50%	Porcentaje de aciertos directionales en el horizonte de 90 días.	H3 tiene la mayor DA, coherente con su rol en planificación estratégica de largo plazo.
AUC H3 (clasificación)	0.7523	Área bajo la curva ROC del clasificador calibrado para H3.	Mejor AUC del sistema: el horizonte largo discrimina mejor las señales alcistas reales.
Verificación golden dataset (18 casos, dataset_entrenamiento_final.csv, date>=2021-01)	17/18 (94%) dentro de tolerancia de magnitud (2x MAE); 32/54 (59.3%) aciertos de dirección	Tras integrar el plugin, se compararon 18 predicciones reales del servicio (vía /predict) contra el retorno realmente observado en el dataset histórico, con tolerancia = 2x el MAE reportado por horizonte.	Confirma que el pipeline integrado reproduce el comportamiento declarado por el equipo de IA (magnitud consistente, dirección en línea con la DA reportada de 56-63%). El único caso fuera de tolerancia corresponde a un movimiento extremo real (+17-35%, shock de precios de 2022)

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
			que el modelo subestima sistemáticamente — limitación conocida del modelo, no un defecto de integración. Ver outputs/a21/verification_report.md.

TABLA 4 MÉTRICAS DE EVALUACIÓN

5. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Sesgo de agregación institucional	El modelo aprende el precio medio provincial a partir de fuentes MAPA, ignorando dispersiones intraprovinciales. La predicción refleja una tendencia macro, no precios puntuales de mercado.
Blacklist Nuclear — ceguera técnica	La exclusión de lags de precio impide capturar rebotes técnicos de corto plazo. El modelo es resiliente pero menos reactivo a movimientos de inercia del mercado.
Sesgo geográfico	Optimizado para provincias con mayor peso histórico en el dataset. En regiones con baja liquidez o dinámicas no representadas, la precisión se degrada por extrapolación.
Dependencia energética	Asume que costes de insumos (Urea, Gas) y futuros internacionales son los motores primarios. Una ruptura estructural en esta jerarquía podría generar drift silencioso.
Disrupciones intrapublicación	Eventos de impacto inmediato (cisnes negros) ocurridos entre dos cortes mensuales de datos no serán capturados hasta el siguiente ciclo ETL.
Intervencionismo político	No anticipa decisiones gubernamentales discretas (precios máximos, aranceles, prohibiciones de exportación) que rompan la dinámica de oferta-demandada aprendida.

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Requiere reentrenamiento ante cambio de régimen	Si las correlaciones históricas se invalidan permanentemente, el modelo deja de ser fiable hasta un reentrenamiento con datos actualizados.
Mercados sin contrapartida	En meses de inactividad física del mercado, la salida teórica puede ser coherente pero la ejecución real imposible por falta de liquidez.

TABLA 5 LIMITACIONES CONOCIDAS

6. Observaciones técnicas

CPU 4 núcleos (x86-64), 8 GB RAM mín. (16 GB recomendados). Sin GPU necesaria. Inferencia <1s individual, <5s batch nacional. Entrenamiento completo 5-15 min. Artefactos totales ~19.5 MB (6 .joblib + metadata.json). Librerías: scikit-learn>=1.3, xgboost>=2.0, pandas>=2.0, numpy>=1.24, joblib>=1.3. Los modelos H1/H2 usan ExtraTrees (reg) + LogisticRegression (clf); H3 usa XGBoost (reg) + LogisticRegression (clf). Training sube artefactos a MLflow (no S3). El artefacto dataset_entrenamiento_final.csv (~7.1 MB, ~7.6k filas) se añadió como dependencia obligatoria tras esta auditoría: predict_inline solo recibe provincia/cereal/mes del caller y necesita este panel para resolver el resto de columnas de ingeniería (antes se rellenaban con 0, corrompiendo la predicción).

7. Fichero de prueba de referencia

Nombre del fichero	test_predict_batch.csv (360 registros: 3 provincias × 2 cereales × 60 meses)
Número de registros / muestras	360

Resultado esperado con este fichero	Predicciones batch con 6 columnas de retorno y señal por horizonte (ret_h1-3, signal_h1-3, risk_geo_alto) para cada combinación provincia-cereal-mes.

TABLA 6 FICHERO DE PRUEBA DE REFERENCIA