DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha técnica del modelo a23 · lactic-market-price-forecast

Especificación técnica para integración en la plataforma DatagIA

Julio 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Información general del modelo

Nombre del modelo (model_key)	ml23-lactic-market-price-forecast
Versión	1.0.0
Descripción	Red neuronal recurrente GRU (PyTorch) para forecasting de series temporales del precio medio mensual de leche líquida a un horizonte fijo de 6 meses, expresado en EUR/litro. Opera sobre 16 series producto × canal usando ventanas de seq_len=6 meses y hasta 32 variables numéricas: retardos de precio, medias móviles, variables de calendario/estacionalidad e indicadores exógenos macroeconómicos y agrarios (inflación, índices agrarios del MAPA y precios percibidos por los ganaderos). Fue seleccionado como modelo de producción frente a LSTM, XGBoost y los baselines Naive/Drift por obtener el menor RMSE medio en validación cruzada temporal walk-forward.
Tipo de tarea (task_type)	time_series_regression (forecasting multiserie, horizonte de 6 meses)
Framework	PyTorch (GRU: 2 capas, hidden_size=64, dropout=0.3, ~43.841 parámetros) + numpy, pandas
Fichero del artefacto	Bundle de 3 ficheros: gru_model.pt (state_dict del GRU, ~174 KB) + rnn_scaler.npz (media y escala congeladas del estandarizado) + manifest.json (feature_cols, seq_len, hidden_size, horizon, selected_model). Cargados desde el artifact store (local o s3://<bucket>/artifacts/fixed/ml23_lactic_market_price_forecast/).
Objetivo del modelo	Estimar con antelación la evolución del precio medio mensual de la leche líquida en el mercado español para apoyar la planificación de la producción, la gestión de inventarios y las políticas comerciales de productores, industrias transformadoras y canales de distribución. El sistema modela 16 series (4 productos × 4 canales) a 6 meses vista para anticipar señales de subida, estabilidad o caída del precio.
Caso de uso principal	Modo predict inline: se envía un diccionario con las variables de un mes de referencia; el plugin lo replica seq_len=6 veces para construir la secuencia y devuelve el precio estimado a 6 meses. Modo predict batch: se pasa un CSV histórico con columnas producto/canal/fecha y las variables de entrada; el plugin ordena por fecha, desliza una

	ventana de longitud seq_len por cada grupo (producto, canal) y emite una predicción (y_pred) por ventana válida. Modo train: reentrena (refit) la arquitectura GRU ya seleccionada sobre un CSV con el mismo contrato que el dataset de entrenamiento original (fecha, producto, canal, target_precio_medio + variables exógenas); requiere obligatoriamente un mlflow_run_id (sin valor por defecto) y el bundle reentrenado se guarda solo en ese run de MLflow, nunca sobrescribe el artefacto base servido.

TABLA 1 INFORMACIÓN GENERAL DEL MODELO

2. Campos de entrada (inputs)

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
data_path	str (ruta CSV)	Modo batch: CSV histórico con columnas producto, canal, fecha y las variables de entrada; admite prefijo s3://. Se desliza una ventana temporal de seq_len=6 por cada grupo (producto, canal).	Sí (modo batch)	-
producto	str (columna CSV)	Metadato de serie: tipo de leche líquida (leche_entera, leche_desnatada, leche_semidesnatada, total_leche_liquida). Agrupa las ventanas en modo batch, no es una feature numérica de la red.	Recomendado en batch	-
canal	str (columna CSV)	Metadato de serie: canal de distribución (DISCOUNTS, HIPERMERCADOS, SUPER+AUTOS, T.ESPAÑA). Agrupa las ventanas en modo batch.	Recomendado en batch	-

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
fecha	date (columna CSV)	Mes de referencia de la observación; se usa para ordenar cronológicamente la ventana temporal.	Recomendado en batch	-
current_price	float	Precio medio observado (EUR/L) en el instante de predicción t; forma parte de las 32 variables efectivas de la red.	No	0.0
Variables de calendario	float x5	year, mes, trimestre, es_verano, es_navidad — indicadores de estacionalidad y patrones anuales.	No	0.0
Variables autoregresivas y de tendencia	float x6	precio_lag_1, precio_lag_3, precio_lag_12 (retardos del precio) y variacion_mensual, media_movil_3, media_movil_12 (medias móviles) — persistencia a corto, medio y largo plazo.	No	0.0
Indicadores de inflación	float x6	hicp_all_es_lag1, hicp_dairy_es_lag1, hicp_energy_es_lag1 (índices armonizados FRED) e ipc_alimentos_lag1, ipc_general_lag1, ipc_vivienda_energia_lag1 (IPC del INE), todos retardados un mes.	No	0.0
Índices agrarios del MAPA	float x10	Índices de precios percibidos y medias móviles (..._lag1) de leche, cereales, cultivos forrajeros, leguminosas de pienso, ganado y vacuno para abasto — costes productivos de la cadena láctea.	No	0.0

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
Precios percibidos por los ganaderos	float x4	mapa_preper5 leche de vaca/oveja/cabra (EUR/100 L) y mapa_preper6 vacas paridas (EUR/100 kg vivo), retardados un mes — presión de costes en explotación.	No	0.0
model_key / threshold	str / float	Aceptados por la firma del endpoint pero ignorados por este plugin: no hay selección de umbral.	No	None
mlflow_run_id	str	En predict/batch: si se indica, carga un bundle GRU reentrenado por el usuario desde MLflow en vez del artefacto fijo. En train: obligatorio, identifica el run donde se persiste el GRU reentrenado.	No en predict; Sí en train	"" (predict) / - (train)
data_path (modo train)	str	CSV con el mismo contrato que dataset_forecast_ready.csv: fecha, producto, canal, target_precio_medio y las columnas exógenas (lags, medias móviles, HICP/IPC/MAPA)	Sí (modo train)	-

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Campos de salida (outputs)

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
prediction (inline) / y_pred (batch)	float (EUR/L)	Precio medio mensual estimado de leche líquida a 6 meses vista, redondeado a 4 decimales.	Continuo positivo; el histórico observado se sitúa en 0,65–1,12 EUR/L	Se compara con el precio actual (current_price) para inferir subida,

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
				estabilidad o caída esperada del precio a medio plazo.
horizon	int (meses)	Horizonte de la predicción, fijado por el manifest.	6	Todas las predicciones se refieren a 6 meses después del instante de predicción.
features_used	list[str]	Lista de las variables efectivas empleadas, según feature_cols del manifest.json del artefacto.	hasta 32 nombres de variable	Documenta qué conjunto exacto de variables activó el modelo cargado; consumido también por el servicio XAI.
model_version	str	Versión del artefacto de modelo.	1.0.0	Trazabilidad del artefacto usado en la inferencia.
confidence	float | None	Nivel de confianza de la predicción.	Siempre None	El modelo no expone una medida de incertidumbre por predicción.
xai_feature_values	dict | None	Valores numéricos de las features usadas en la predicción.	{feature: valor}	Insumo para el servicio de explicabilidad (XAI); no altera la predicción.

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Métricas de evaluación

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
RMSE (test hold-out, media 3 semillas)	0,0226 ± 0,0086 EUR/L	Raíz del error cuadrático medio, media multi-semilla (3 semillas) en el test hold-out (último 10% de fechas) — bloque "GRU" de final_test_metrics.json. NO es el artefacto realmente servido (ver entrada 'artefacto servido' mas abajo).	El error cuadrático típico del precio predicho es de poco más de 2 céntimos por litro
MAE (test hold-out, media 3 semillas)	0,0177 ± 0,0067 EUR/L	Error absoluto medio en el test hold-out — bloque "GRU" de final_test_metrics.json. NO es el artefacto realmente servido (ver entrada 'artefacto servido' mas abajo).	De media, la predicción se desvía menos de 2 céntimos por litro del precio real
MAPE (test hold-out, media 3 semillas)	1,78% ± 0,69%	Error porcentual absoluto medio en el test hold-out — bloque "GRU" de final_test_metrics.json. NO es el artefacto realmente servido (ver entrada 'artefacto servido' mas abajo).	Exactitud efectiva media ~98,22%, por encima del KPI del 85%

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
R^2 (test hold-out, media 3 semillas)	0,7957 ± 0,1535	Proporción de varianza explicada en el test hold-out — bloque "GRU" de final_test_metrics.json. NO es el artefacto realmente servido (ver entrada 'artefacto servido' mas abajo).	El modelo explica de media el ~79,6% de la varianza del precio, con variabilidad entre semillas
Direction Accuracy (test hold-out, media 3 semillas)	93,2% ± 2,0%	Acierto en la dirección del cambio de precio en test (objetivo declarado > 60%) — bloque "GRU" de final_test_metrics.json. NO es el artefacto realmente servido (ver entrada 'artefacto servido' mas abajo).	Acierta si el precio subirá o bajará en más de 9 de cada 10 casos
MAE (artefacto servido, gru_model.pt seed=42)	0,0135 EUR/L	Bloque "GRU_artifact_metrics" de final_test_metrics.json — metrica real del unico artefacto desplegado (seleccionado por best_seed_by_validation_rmse), no la media de las 3 semillas evaluadas.	El artefacto que de verdad responde en produccion es mejor que la media reportada: error medio de 1,35 centimos/L, no 1,77.

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
RMSE (artefacto servido, gru_model.pt seed=42)	0,0170 EUR/L	Bloque "GRU_artifact_metrics" de final_test_metrics.json.	Consistente con el MAE: el artefacto servido tiene menor error que la media multi-semilla.
R^2 (artefacto servido, gru_model.pt seed=42)	0,899	Bloque "GRU_artifact_metrics" de final_test_metrics.json.	El artefacto servido explica ~89,9% de la varianza del precio, notablemente por encima del 79,6% de la media multi-semilla.
RMSE baseline Naive (test)	0,0295 EUR/L	Referencia de persistencia (precio futuro = precio actual) en test	El GRU mejora ~23,3% el RMSE del baseline, confirmando capacidad predictiva real más allá de la persistencia
RMSE (validación cruzada temporal)	0,0263 ± 0,0074 EUR/L	RMSE medio en validación cruzada walk-forward de 5 folds (métrica de selección del modelo, frente a Naive CV 0,0492)	Métrica prioritaria que seleccionó GRU frente a LSTM (0,0288) y XGBoost (0,0453)
Direction Accuracy (validación cruzada)	82,56% ± 10,29%	Acierto direccional medio en validación cruzada temporal	La mayor de las arquitecturas evaluadas; mayor variabilidad entre folds por la heterogeneidad

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
			temporal (shock de precios de 2022)
Correctitud post-integración de train() (verification_report.md, Ciclo 2)	mae=0,0135 rmse=0,017 r2=0,8994 direction_acc=90,6% (dataset real completo, 1.440 filas)	Refit real ejecutado end-to-end sobre el dataset de entrenamiento completo — coincide a 4+ decimales con las métricas del artefacto servido (fila 'artefacto servido' de arriba)	Confirma que el procedimiento de reentrenamiento portado al plugin reproduce exactamente el original, no una aproximación

TABLA 4 MÉTRICAS DE EVALUACIÓN

5. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Histórico corto y pocas series	El dataset final tiene 1.440 observaciones (16 series producto × canal, junio 2018 – noviembre 2025, ~7,5 años mensuales). Es suficiente para ciclos estacionales anuales, pero limitado para observar varios ciclos económicos completos y no permite escalar a arquitecturas más profundas sin riesgo de sobreajuste.
Sensibilidad a la inicialización	Las métricas oficiales se reportan como media de 3 semillas por la variabilidad de inicialización. Una de las semillas obtuvo en test RMSE=0,0348 EUR/L, superior al baseline Naive, lo que evidencia sensibilidad a la semilla y refuerza la necesidad de monitorización en producción.
Rendimiento ligado al régimen de mercado	El test hold-out corresponde a un tramo temporal reciente y estable (2024-10 a 2025-05). No garantiza el mismo nivel de precisión en regímenes volátiles no observados; los folds de validación que cubren el shock de precios de 2022 son sensiblemente más difíciles de predecir.

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Precio objetivo estimado, no transaccional	El precio medio se estima a partir de histogramas de distribución publicados por el MAPA, no de transacciones directas; introduce agregación y suavizado. Los informes del MAPA desde enero de 2024 usan el censo de población 2021 del INE, lo que puede introducir ligeras discontinuidades metodológicas.
Frecuencia mensual y dependencia de exógenas completas	La resolución mensual impide capturar shocks intramensuales. La inferencia requiere que las exógenas (INE/FRED/MAPA) del último mes estén publicadas y completas; no deben imputarse silenciosamente datos futuros, y si se arrastra el último valor la salida debe marcarse como estimación provisional.
Sin señales comerciales micro	No incorpora promociones, cambios de estrategia de precios de las cadenas, variaciones de demanda por segmento ni tendencias de sustitución (intolerancia a la lactosa, alternativas vegetales), lo que limita la precisión en periodos de cambio estructural del consumo.
Cobertura geográfica España	El modelo se limita al mercado español agregado a nivel nacional; los resultados no son directamente extrapolables a otros mercados.
Reentrenamiento: solo refit de la arquitectura ya seleccionada	train() reentrena (refit) la red GRU ya elegida como mejor modelo, pero no repite la búsqueda completa que comparó GRU frente a LSTM/XGBoost/baselines — si los datos nuevos cambiaran sustancialmente qué arquitectura es la óptima, eso requiere un ciclo de comparación completo fuera de este endpoint. Se recomienda reentrenar mensual o trimestralmente con datos oficiales actualizados.

TABLA 5 LIMITACIONES CONOCIDAS

6. Observaciones técnicas

Arquitectura GRU (PyTorch): input_size=32, hidden_size=64, num_layers=2, dropout=0,3, capa lineal escalar final, ~43.841 parámetros; seq_len=6, horizon=6. El estandarizado usa media/escala congeladas del entrenamiento (rnn_scaler.npz) y el conjunto efectivo de variables lo fija feature_cols del manifest.json del artefacto. Ejecutable en CPU x86-64 (mínimo 2 vCPU), RAM ≥ 4 GB, sin GPU; almacenamiento < 500 MB (artefacto GRU ~174 KB). Entorno de desarrollo Python 3.12; runtime compatible con Python 3.10+. Dependencias clave: torch, numpy, pandas. train() soporta reentrenamiento real (refit de la arquitectura GRU ya seleccionada, 3 seeds, ~48s sobre el dataset completo); mlflow_run_id obligatorio en train, el bundle

reentrenado se sube solo a MLflow, nunca sobrescribe el artefacto base. Monitorización recomendada: reentrenar mensual/trimestral con nuevos datos oficiales completos y alertar si el RMSE observado supera en más del 25% al RMSE de test durante tres meses consecutivos, si la Direction Accuracy acumulada cae por debajo del 60%, si aparecen errores sistemáticos por producto/canal o si cambia la metodología de alguna fuente pública.

7. Fichero de prueba de referencia

Nombre del fichero	No se entregó golden dataset ejecutable para verificar la correctitud tras la integración: los tests unitarios del plugin usan mocks. La evaluación oficial de la memoria se realizó sobre el test hold-out del entregable (data/splits/test_h6.csv).
Número de registros / muestras	Test hold-out = último 10% de fechas únicas (2024-10 a 2025-05) sobre las 16 series producto × canal. La inferencia GRU sobre el dataset procesado completo (dataset_forecast_ready.csv, 1.440 observaciones) genera 1.360 filas: 16 series × 85 ventanas de longitud seq_len=6.
Resultado esperado con este fichero	Métricas oficiales multi-semilla en test hold-out: RMSE=0,0226±0,0086 EUR/L, MAE=0,0177±0,0067, MAPE=1,78%±0,69%, R^2=0,7957±0,1535, Direction Accuracy=93,2%±2,0%; mejora ~23,3% en RMSE frente al baseline Naive (0,0295 EUR/L). La semilla persistida como artefacto de inferencia obtiene en test RMSE=0,0170, MAE=0,0135, MAPE=1,33%, R^2=0,8994 y Direction Accuracy=90,6% — reproducido de forma independiente ejecutando train() end-to-end sobre el dataset completo (ver verification_report.md, Ciclo 2).

TABLA 6 FICHERO DE PRUEBA DE REFERENCIA