DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha técnica del modelo a25 · wine-sulphites

Especificación técnica para integración en la plataforma DatagIA

Octubre 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Información general del modelo

Nombre del modelo (model_key)	ml25-wine-sulphites
Versión	3.2
Descripción	Sistema dual de simulación prescriptiva para la dosificación de sulfitos (SO2) durante la elaboración de vino blanco. Dos regresores Random Forest independientes (RandomForestRegressor, n_estimators=300, random_state=42) predicen, respectivamente, la calidad sensorial (escala 0-10) y el SO2 ligado resultante (transformación log1p/expm1) a partir de los 11 parámetros fisicoquímicos de la muestra. Un optimizador explora un barrido de dosis candidatas de SO2 libre, aplica restricciones duras de negocio y recomienda la dosis que maximiza la calidad esperada dentro del tramo válido.
Tipo de tarea (task_type)	regression_prescriptive (dos regresores Random Forest + simulación/optimización de dosis sobre su salida)
Framework	scikit-learn (RandomForestRegressor ×2); xgboost solo en artefactos legacy de comparativa, no usados en producción
Fichero del artefacto	quality_rf.pkl (modelo de calidad), bound_rf.pkl (modelo de SO2 ligado, escala log1p), metadata.json (métricas, hiperparámetros, percentiles de simulación)
Objetivo del modelo	Asistir al enólogo en la decisión de cuánta dosis de SO2 libre añadir a un vino durante la vinificación, maximizando la calidad sensorial esperada del producto final dentro de las restricciones químicas (SO2 molecular mínimo) y legales (SO2 total máximo) aplicables. El modelo de calidad captura la relación entre los 11 parámetros fisicoquímicos y la puntuación sensorial; el modelo de SO2 ligado, un problema químicamente más determinista, estima cómo evolucionará el equilibrio libre/ligado ante una dosis candidata, sirviendo de paso intermedio para la simulación.
Caso de uso principal	Modo predict inline: se envían los 11 parámetros fisicoquímicos de una muestra de vino (y opcionalmente los parámetros de control min_molecular/max_total/delta_max); el sistema simula un barrido de dosis de SO2 libre, descarta las que violan restricciones duras y devuelve la dosis recomendada, la calidad predicha en ese punto, la calidad baseline (sin intervención) y la trayectoria completa simulada. Modo predict batch: mismo cálculo fila a fila sobre un CSV. Modo

	train: reentrena ambos Random Forest sobre un CSV de usuario con el protocolo oficial (CV 5-fold + ajuste final sobre el 100% de los datos limpios), opcionalmente registrando el resultado en un run de MLflow (mlflow_run_id) sin sobrescribir nunca el artefacto base.

TABLA 1 INFORMACIÓN GENERAL DEL MODELO

2. Campos de entrada (inputs)

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
Parámetros fisicoquímicos (11 numéricas)	float	fixed acidity, volatile acidity, citric acid, residual sugar, chlorides, density, pH, sulphates, alcohol, free sulfur dioxide, total sulfur dioxide — análisis de laboratorio de la muestra de vino	Sí	-
min_molecular	float	SO2 molecular mínimo exigido por protección microbiológica (restricción dura)	No	0.6 mg/L
max_total	float	SO2 total máximo permitido por normativa (restricción dura)	No	200.0 mg/L
delta_max	float	Incremento máximo de SO2 libre a explorar sobre el valor actual; el rango simulado real también se acota por el percentil 99 de SO2 libre del dataset de entrenamiento, para no extrapolar nunca fuera de la distribución con la que se entrenó el modelo	No	40.0 mg/L
mlflow_run_id	str	Si se indica, carga un par de modelos reentrenados por el usuario desde MLflow en lugar de los artefactos fijos	No	""

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Campos de salida (outputs)

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
recommended_free_so2	float (mg/L)	Dosis de SO2 libre recomendada	positivo continuo, acotado por delta_max y el percentil 99 de entrenamiento	dosis a añadir sobre el valor actual de SO2 libre de la muestra
recommended_bound_so2 / recommended_total_so2 / recommended_molecular_so2	float (mg/L)	SO2 ligado, total y molecular estimados en el punto recomendado	positivo continuo	permiten comprobar que la recomendación respeta las restricciones químicas y legales
predicted_quality / baseline_predicted_quality	float	Calidad sensorial predicha en el punto recomendado y en la dosis actual (sin intervención)	0-10	la diferencia entre ambas es la mejora de calidad que justifica (o no) la intervención
intervention_recommended	bool	True si la mejora esperada supera 1x el MAE de calidad (umbral de intervención)	true | false	false no significa que la dosis actual sea perfecta, sino que la mejora esperada es demasiado pequeña para justificar el cambio
recommendation_reason	string	Explicación textual de la decisión (mejora significativa vs. mínima intervención segura)	texto libre	contexto legible de por qué se recomienda esa dosis concreta

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
simulation_trajectory	list	Trayectoria completa simulada: free/bound/total/molecular SO2 y calidad predicha para cada dosis candidata del barrido	lista de puntos	base de la gráfica de optimización que se muestra al enólogo

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Métricas de evaluación

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
MAE calidad (CV 5-fold)	0.427 ± 0.015	Error absoluto medio del modelo de calidad en validación cruzada 5-fold sobre las 4.898 muestras (memoria, Tabla 7)	el modelo se equivoca en media menos de medio punto en la escala de cata 0-10; mejora del 36.4% sobre el baseline DummyMean (0.671)
R^2 calidad (CV 5-fold)	0.539 ± 0.024	Varianza de la calidad explicada por los 11 parámetros fisicoquímicos	el modelo explica algo más de la mitad de la varianza; el resto depende de compuestos aromáticos no parametrizados en el dataset
MAE SO2 ligado (CV 5-fold)	14.511 ± 0.498 mg/L	Error absoluto medio del modelo de SO2 ligado en	mejora del 47.7% sobre el baseline DummyMean

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
		validación cruzada 5-fold	(27.760 mg/L); el error residual se atribuye a precursores químicos no desglosados en el dataset
R^2 SO2 ligado (CV 5-fold)	0.622 ± 0.028	Varianza del SO2 ligado explicada por los parámetros disponibles	confirma que la reacción de combinación del SO2 es un problema químico más determinista que la calidad sensorial
Correctitud post-integración (golden dataset, verification_report.md)	10/14 calidad, 14/14 SO2 ligado, dentro de tolerancia (2×MAE)	14 filas reales del dataset de entrenamiento, comparadas contra la salida real del servidor integrado	los 4 fallos de calidad corresponden a vinos de calidad extrema (3-4 y 8-9), donde el propio artefacto .pkl (sin pasar por el plugin) es igual de conservador — confirmado como límite real del modelo, no un defecto de integración

TABLA 4 MÉTRICAS DE EVALUACIÓN

5. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Sesgo de centralidad del dataset	El 92.59% de las 4.898 muestras tiene calidad 5-7; los extremos (3-4 y 8-9) suman apenas el 7.4% de los datos. El modelo es muy preciso en vinos estándar pero conservador (subestima excelentes, sobreestima defectuosos) en vinos de calidad extrema — confirmado en la verificación post-integración: 4/14 casos de calidad extrema fuera de tolerancia, reproducido también llamando al artefacto .pkl directamente.
Subjetividad sensorial y variables no observadas	La variable 'calidad' proviene de catas humanas y el modelo solo dispone del equilibrio macroquímico (acidez, alcohol, azúcar, pH); no capta matices aromáticos no parametrizados en el dataset.
Origen geográfico específico del dataset	Entrenado sobre Vinho Verde (Minho, Portugal); representativo del noroeste de la Península Ibérica por similitud geoclimática, pero puede perder precisión en vinos de zonas con equilibrios de acidez/alcohol estructuralmente distintos (p. ej. La Mancha, zonas mediterráneas).
Sin held-out test independiente	El protocolo oficial es CV 5-fold sobre el dataset completo (no existe una partición de test separada en la entrega); el modelo final se ajusta sobre el 100% de los datos limpios. Las métricas reportadas son de validación cruzada, no de un conjunto nunca visto por el modelo final.
Solo vino blanco	Entrenado exclusivamente sobre white_wine.csv; la química de sulfitos en vino tinto varía drásticamente por los antocianos y taninos presentes, por lo que el modelo no es aplicable a tinto.

TABLA 5 LIMITACIONES CONOCIDAS

6. Observaciones técnicas

Ejecutable en CPU estándar, sin necesidad de GPU/CUDA — modelos tabulares Random Forest sobre ~5.000 registros. RAM de uso general suficiente. Artefactos ligeros (~22 MB en total según la memoria). Librerías: pandas, numpy, scikit-learn (RandomForest, CV, métricas), joblib (serialización). Python 3.8+. Nota de integración: los .pkl entregados se serializaron con scikit-learn 1.8.0; el entorno de despliegue usa 1.5.2 — joblib.load() los carga correctamente (atributos y feature_names_in_ verificados) con un aviso cosmético

(InconsistentVersionWarning), sin impacto en la inferencia. El plugin incluye mlflow_utils.py y soporta reentrenamiento por usuario con seguimiento MLflow opcional, sin sobrescribir nunca el artefacto base servido por defecto.

7. Fichero de prueba de referencia

Nombre del fichero	14 filas reales de white_wine.csv (el mismo CSV usado para entrenar y evaluar los artefactos), seleccionadas para cubrir todo el rango de calidad (3-9)
Número de registros / muestras	14 muestras (golden dataset de verificación); dataset de entrenamiento completo: 4.898 registros de vino blanco
Resultado esperado con este fichero	10/14 casos dentro de tolerancia (2×MAE=0.854) en calidad, 14/14 dentro de tolerancia (2×MAE=29.02 mg/L) en SO2 ligado — ver verification_report.md para el detalle caso a caso y la investigación de los 4 fallos

TABLA 6 FICHERO DE PRUEBA DE REFERENCIA