DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha técnica del modelo a41 · meat-curing-machinery-acoustic-anomaly

Especificación técnica para integración en la plataforma DatagIA

Octubre 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Información general del modelo

Nombre del modelo (model_key)	ml41-meat-curing-machinery-acoustic-anomaly
Versión	1.0.0 (memoria v1.4)
Descripción	Detección no supervisada de anomalías acústicas en maquinaria del secadero de curado (ventilador, bomba, corredera y válvula) con un Audio Masked Autoencoder ViT-Tiny. Hay un modelo por combinación de máquina, unidad y nivel de ruido (48 en total). La decisión se toma con la distancia de Mahalanobis del token CLS respecto a la distribución de audios normales y un umbral calibrado para FNR ≤ 10 %.
Tipo de tarea (task_type)	Detección de anomalías no supervisada sobre audio (entrenamiento solo con muestras normales)
Framework	PyTorch (AudioMAE: ViT-Tiny, embed_dim 192, profundidad y cabezas por máquina: fan 9/6, pump 7/4, slider 4/4, valve 5/8; decoder 4 capas de 128); librosa para el espectrograma log-Mel; numpy para Mahalanobis con PCA (30-90 componentes según la máquina)
Fichero del artefacto	48 directorios vit_tiny_{machine}/{machine}/{machine_id}/{snr}/ con best.pth (pesos, media y desviación de normalización) y maha_stats.npz (media, covarianza inversa y PCA de los embeddings normales). Umbral audit_fnr por combinación tomado de reports/table_auc_por_caso.csv
Objetivo del modelo	Detectar a tiempo averías en los equipos que regulan temperatura y humedad del secadero de embutidos, donde un fallo no detectado puede arruinar lotes enteros. Por esa asimetría de costes, el criterio de éxito prioriza la sensibilidad: tasa de falsos negativos (FNR) ≤ 10 % por combinación, aceptando un número elevado de falsas alarmas. El modelo se entrena solo con funcionamiento normal, porque en planta es muy difícil reunir grabaciones de fallos.
Caso de uso principal	Modo inline: se envía una grabación WAV (base64; cualquier frecuencia y número de canales, se convierte a mono 16 kHz) y se elige la máquina, la unidad y el nivel de ruido de la combinación entrenada más parecida a la instalación. El servicio calcula el espectrograma log-Mel (128 × 1024, unos 10,24 s; recorta o rellena por reflexión), lo normaliza con las estadísticas de esa combinación y

	devuelve el error de reconstrucción (informativo), la distancia de Mahalanobis y la etiqueta normal/anómalo según el umbral calibrado. Modo batch: ZIP con un manifest.csv (filename, machine, machine_id, snr) y los WAV. Reentrenamiento (/train): ZIP con {snr}_{machine}/{machine_id}/normal/*.wav (y opcionalmente abnormal/ para calcular AUC y el umbral); repite el entrenamiento original desde cero y guarda el resultado solo en MLflow.

TABLA 1 INFORMACIÓN GENERAL DEL MODELO

2. Campos de entrada (inputs)

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
audio_base64	string (WAV en base64)	Grabación de la máquina; se recomiendan 10 s a 16 kHz. Se convierte a mono y a log-Mel de 128 bandas × 1024 tramas (n_fft 1024, win 400, hop 160)	Sí	-
machine	categórica (fan, pump, slider, valve)	Tipo de máquina; selecciona la arquitectura y el modelo	Sí	-
machine_id	categórica (id_00, id_02, id_04, id_06)	Unidad física concreta; cada una tiene su propio modelo entrenado	Sí	-
snr	categórica (-6_dB, 0_dB, 6_dB)	Nivel de ruido de fondo de la combinación de entrenamiento MIMII más parecida a la instalación; no es una medida en tiempo real	Sí	-
threshold	float	Umbral de Mahalanobis alternativo al calibrado (uso avanzado, p. ej. tras validar en planta)	No	umbral audit_fnr de la combinación

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
mlflow_run_id	string	Run de MLflow de un modelo reentrenado; sin él se usa el modelo base	No	modelo base

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Campos de salida (outputs)

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
maha_score	float	Distancia de Mahalanobis del token CLS (proyectado con PCA) a la distribución de audios normales de entrenamiento. Señal de decisión	≥ 0; los umbrales calibrados van de 2,6 a 14,9 según la combinación	cuanto mayor, más se aleja del funcionamiento normal
predicted_label	int (0/1)	1 si maha_score ≥ threshold_used	0 = normal, 1 = anómalo	1 = revisar la máquina
threshold_used	float	Umbral aplicado: el audit_fnr de la combinación (FNR ≤ 10 % en test), el del modelo reentrenado o el indicado en la petición	según la combinación	punto de corte de la decisión
mse_score	float	Error de reconstrucción del autoencoder con el 75 % de parches enmascarados al azar	≥ 0	solo informativo: varía un 5-6 % entre ejecuciones por el enmascaramiento aleatorio

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Métricas de evaluación

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
AUC Mahalanobis medio (48 combinaciones, test MIMII)	0,772 (fan 0,856; pump 0,875; slider 0,826; valve 0,531)	reports/table_auc_por_caso.csv y metrics.json de cada checkpoint	buena separación en fan, pump y slider; en valve apenas mejor que el azar
Criterio de éxito FNR ≤ 10 %	48/48 combinaciones; FNR medio 0,091	Umbral audit_fnr: el más alto que garantiza TPR ≥ 90 % en el test de cada combinación	se detectan al menos 9 de cada 10 anomalías en todas las combinaciones
Falsas alarmas al umbral de FNR ≤ 10 %	FPR medio 0,468 (valve 0,842, rango 0,74-0,93)	Coste operativo de priorizar la sensibilidad	aproximadamente una de cada dos grabaciones normales genera alerta: sirve como triaje, no como sistema autónomo
Referencia no desplegada: baseline (autoencoder FC)	AUC medio 0,800	Memoria v1.4: mejor media global; Audio-MAE se mantiene como modelo final por su ventaja en pump (0,875 frente a 0,811) y su escalabilidad	para combinaciones de AUC bajo la memoria recomienda el baseline como alternativa
Verificación tras la integración (2026-10-10)	22/22 golden cases; métricas de las 48 combinaciones recalculadas con el servicio sobre el test	outputs/a41/verification_report.md, con el dataset MIMII completo y contra el endpoint HTTP real	el servicio reproduce el código entregado

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
	real (AUC medio 0,7720 idéntico, 48/48 con FNR ≤ 10 %); reentrenamiento real igual al original a 4 decimales		

TABLA 4 MÉTRICAS DE EVALUACIÓN

5. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Laboratorio, no planta	MIMII se grabó en laboratorio con ruido de fábrica añadido sintéticamente. No hay evidencia de rendimiento en el secadero real sin recalibrar con audio de la máquina concreta y validar con grabaciones reales.
Válvulas	AUC 0,46-0,60 y FPR 0,74-0,93 (sigue alto a +6 dB, con menos ruido). No se recomienda su uso autónomo para válvulas sin una segunda validación.
Muchas falsas alarmas	Para garantizar FNR ≤ 10 %, alrededor de la mitad de las grabaciones normales generan alerta. Es un sistema de triaje para concentrar las inspecciones.
Umbral heredado del benchmark	Los umbrales se calibraron con las anomalías de MIMII. En producción, sin fallos etiquetados, hay que derivarlos de los scores normales de la máquina real y validarlos en campo.
Contaminación del entrenamiento	El modelo asume que todo el audio de entrenamiento es normal; un fallo incipiente en esos datos invierte la detección sin aviso.
Reentrenamiento costoso	Repite el entrenamiento original desde cero: unos 10 minutos por combinación en GPU (9-10 min medidos en una RTX 2070 SUPER) y 1-1,5 h en CPU. No implementa la recalibración Mahalanobis sin reentrenar (subcomando calibrate) que la memoria recomienda para adaptar el modelo a planta.

TABLA 5 LIMITACIONES CONOCIDAS

6. Observaciones técnicas

Inferencia en CPU o GPU (en GPU, maha_score difiere hasta 1,7e-4 relativo de CPU). En GPU el reentrenamiento usa autocast bf16, como el original. Carga perezosa con caché LRU de combinaciones (las 48 ocupan unos 2 GB). Entorno del equipo de IA: torch 2.4.1, librosa 0.11.0, soundfile 0.13.1, numpy 1.24.4. maha_score varía ≤ 6e-7 entre ejecuciones porque el encoder baraja parches incluso sin enmascarar; mse_score varía un 5-6 %. Monitorización recomendada por la memoria: recalibrar y valorar reentrenamiento si la mediana o el percentil 95 de los scores sobre periodos normales se desplaza de forma sostenida, o si la tasa de alertas en periodos nominales se duplica.

7. Fichero de prueba de referencia

Nombre del fichero	22 grabaciones WAV de MIMII (data/raw/MIMII Dataset/-6_dB_fan/id_00/{normal,abnormal}/00000000-00000010.wav), puntuadas con el modelo fan/id_00/0_dB
Número de registros / muestras	22 grabaciones de unos 10 s (11 normales y 11 anómalas); valores esperados en inbox/a41/manifest.yaml (golden_cases)
Resultado esperado con este fichero	22/22 dentro de tolerancia contra el endpoint real (maha_score con diferencia ≤ 2,8e-4, etiquetas idénticas): recall 1,0 y FPR 0,818 con el umbral 6,6067 (9 falsas alarmas esperadas en 11 normales)

TABLA 6 FICHERO DE PRUEBA DE REFERENCIA