DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha técnica del modelo a47 · dairy-dnsl-pasteurization-fault-detection

Especificación técnica para integración en la plataforma DatagIA

Julio 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Información general del modelo

Nombre del modelo (model_key)	ml47-dairy-dnsl-pasteurization-fault-detection
Versión	1.0.0
Descripción	Modelo de clasificación multi-etiqueta basado en Deep Neurosymbolic Learning (DNSL): una red convolucional 1D combinada con una función de pérdida guiada por la física (conservación de energía hidráulica y calorimetría). A partir de un ciclo completo de sensores de la maquinaria de pasteurizado, diagnostica simultáneamente el estado de salud de 4 componentes (enfriador/fouling, válvula, bomba y acumulador) en 3 niveles: sano, advertencia y crítico.
Tipo de tarea (task_type)	Clasificación multi-etiqueta multiclase (4 componentes × 3 estados), sobre series temporales multivariantes
Framework	PyTorch (1D-CNN + Physics-Guided Loss) + scikit-learn (StandardScaler)
Fichero del artefacto	neurosymbolic_cnn.pth (pesos DNSL), scaler_cnn_dns.pkl (normalizador), feature_columns.pkl (orden de columnas), ts1_mean_train.pkl (baseline térmico)
Objetivo del modelo	Anticipar y clasificar fallos funcionales en la maquinaria de pasteurización láctea (incrustaciones/fouling, atascos de válvula, cavitación/fugas de bomba y pérdida de presión de gas en el acumulador) antes de que comprometan la esterilidad del producto o detengan la línea. Sustituye a los sistemas de umbral estático, que suelen alertar tarde, por un diagnóstico que además audita internamente sus predicciones contra las leyes de la termodinámica.
Caso de uso principal	Monitorización continua: el sistema consume un ciclo de trabajo de la máquina (~60 s de telemetría a 10 Hz, 600 registros por los 7 sensores) y devuelve un diagnóstico por minuto del estado de los 4 componentes con su nivel de confianza. Se ofrece en modo inline (un ciclo, sensores como arrays o CSV) y en modo batch (CSV con varios ciclos, un diagnóstico por Cycle_ID). Permite planificar paradas de mantenimiento y optimizar los ciclos de limpieza CIP.

TABLA 1 INFORMACIÓN GENERAL DEL MODELO

2. Campos de entrada (inputs)

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
PS1	list[float] (bar)	Serie temporal de presión del circuito principal / entrada	Sí	-
PS3	list[float] (bar)	Serie temporal de presión en punto secundario / retorno	Sí	-
EPS1	list[float] (W)	Potencia activa del motor eléctrico; crítica para la regla física de la bomba	Sí	-
FS1	list[float] (L/min)	Caudal volumétrico principal; crítico para las reglas termodinámica e hidráulica	Sí	-
TS1	list[float] (°C)	Serie temporal de temperatura de entrada	Sí	-
TS2	list[float] (°C)	Serie temporal de temperatura de salida	Sí	-
VS1	list[float] (mm/s)	Serie temporal de vibración mecánica	Sí	-
Time_Segundos	list[float] (s)	Marca temporal (0,0–60,0 s) para ordenar las 600 observaciones del ciclo	Sí	-
Cycle_ID	int	Identificador de ciclo; habilita el modo batch (un diagnóstico por ciclo)	No	-

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Campos de salida (outputs)

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
Enfriador_Fouling	int (0/1/2)	Estado del enfriador / incrustaciones	0=SANO, 1=WARNING, 2=CRÍTICO	2 indica fouling que degrada la transferencia de calor

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
Valvula_Switch	int (0/1/2)	Estado de la válvula de conmutación	0=SANO, 1=WARNING, 2=CRÍTICO	niveles altos indican degradación en los tiempos de conmutación
Bomba_Leakage	int (0/1/2)	Estado de la bomba / fugas internas	0=SANO, 1=WARNING, 2=CRÍTICO	niveles altos indican pérdida de eficiencia hidráulica
Acumulador_Gas	int (0/1/2)	Estado del acumulador / presión de gas	0=SANO, 1=WARNING, 2=CRÍTICO	niveles altos indican pérdida de presión de precarga
Confianza_Fouling / _Valvula / _Bomba / _Acumulador	float	Probabilidad softmax de la clase ganadora de cada componente	0–1	valores próximos a 1 indican un diagnóstico de alta certeza

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Métricas de evaluación

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
Exact Match (declarado, memoria v2.0)	98,79 %	Ciclos del test hold-out con los 4 componentes correctos a la vez (métrica más estricta)	de cada 100 ciclos, ~99 se diagnostican perfectamente en los 4 componentes
F1-Score Macro (declarado, memoria v2.0)	0,9970	Media de F1 por clase; métrica fundamental de	supera con holgura el criterio de

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
		éxito del proyecto (umbral exigido ≥ 0,95)	aceptación acordado
Recall Macro (declarado, memoria v2.0)	0,9972	Sensibilidad promedio; prioridad de negocio = minimizar falsos negativos (no dejar pasar un fallo real)	el modelo detecta casi todos los fallos presentes en el conjunto de test
Métricas por componente (artefacto entregado test_metrics_confusion.csv)	Fouling 100 % · Válvula 100 % · Bomba 99,40 % · Acumulador 99,40 %	Accuracy por componente sobre 331 ciclos de test; los únicos errores son 2 falsas alarmas (Sano→Warning) en Bomba y 2 en Acumulador	los pocos errores son sobre clases contiguas y de bajo coste (revisión innecesaria, nunca fallo no detectado)
Verificación golden tras integración (skill verification, 2026-07-16)	15/15 ciclos reproducidos exactamente	Ejecución del plugin integrado sobre 15 ciclos diversos del test split (9 combinaciones de estado); las 4 clases de componente coinciden con la predicción de referencia en los 15 casos, incluida la reproducción exacta de la única falsa alarma contigua del acumulador (ciclo 211). Evidencia distinta a las	el modelo integrado reproduce el comportamiento del código de la IA; coherente con el 98,79 % de Exact Match declarado

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
		métricas declaradas: confirma que el plugin replica fielmente el pipeline original	

TABLA 4 MÉTRICAS DE EVALUACIÓN

5. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Datos de laboratorio, no de planta láctea real	El modelo se entrenó y validó con el banco experimental UCI Condition Monitoring of Hydraulic Systems (fluido = aceite hidráulico, fallos inyectados de forma controlada), no con telemetría de un pasteurizador lácteo. Las métricas son optimistas; en producción serán netamente inferiores. Requiere validación con datos reales antes de despliegue.
Requiere reentrenamiento/calibración antes de producción	Las propiedades físicas de la leche (densidad, viscosidad, calor específico) difieren del aceite, por lo que los umbrales aprendidos no son directamente válidos. Es obligatorio recalibrar (fine-tuning por transferencia de aprendizaje, 200–500 ciclos reales) antes de usarlo en planta.
Gemelo térmico y escala de presiones	El dataset opera a alta presión (hasta 200 bar) y temperaturas de ~45 °C; un pasteurizador trabaja a baja presión (<5 bar) y 70–74 °C. En laboratorio se aplica un offset térmico (gemelo digital); en producción DEBE desactivarse (auditoría biosanitaria de la temperatura real).
Ventana fija de un ciclo	El modelo espera un ciclo de ~600 pasos (60 s a 10 Hz). Secuencias más cortas se rellenan con ceros (padding) y más largas se truncan, lo que puede degradar el diagnóstico si el muestreo no es homogéneo.
KPI de negocio no cuantificado	El objetivo original de reducir un 15 % los costes de mantenimiento no pudo medirse por falta de datos de costes de una planta real; se sustituyó por un criterio

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
	técnico (F1-Score Macro ≥ 0,95). Requiere validación económica con datos reales antes de despliegue.

TABLA 5 LIMITACIONES CONOCIDAS

6. Observaciones técnicas

Entorno de referencia: Python 3.13 / PyTorch (probado también en torch 2.1.2). Entrenamiento acelerado por GPU NVIDIA CUDA recomendado; la inferencia unitaria corre eficientemente en CPU. Mínimos: 4–8 núcleos x86-64, 16 GB de RAM, ~5 GB de disco. Artefactos ligeros (~600 KB en total). Reproducibilidad determinista con semilla global 42; el versionado de CUDA puede alterar levemente los decimales de confianza. Dependencias núcleo de producción: torch, pandas, numpy, scikit-learn, joblib, pyyaml. Monitorización recomendada: vigilar la deriva de las distribuciones de sensores y reentrenar/calibrar si decae el rendimiento.

7. Fichero de prueba de referencia

Nombre del fichero	data/splits/test_split.csv (partición de test hold-out del dataset UCI, con etiquetas Target_* por ciclo)
Número de registros / muestras	331 ciclos (15 % de los 2.205 totales), ~601 filas por ciclo a 10 Hz; split por Cycle_ID sin fuga de datos
Resultado esperado con este fichero	Diagnóstico de los 4 componentes por ciclo. En la verificación tras integración (skill verification, 15 ciclos diversos del test split), el plugin integrado reprodujo exactamente los 4 estados en los 15 casos —incluida la única falsa alarma contigua del acumulador—, confirmando la fidelidad respecto al código original y la coherencia con el 98,79 % de Exact Match declarado.

TABLA 6 FICHERO DE PRUEBA DE REFERENCIA