DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha funcional del modelo a48 · dnsl-fallas-maquinaria-pasteurizado-xai

Descripción de negocio para usuarios de la plataforma DatagIA

Octubre 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Qué hace el modelo

Descripción	Modelo que sirve modelo-47 (detección de fallos en pasteurización con XAI integrada): red convolucional 1D multitarea con pérdida físico-informada (DNSL) que diagnostica el estado de cuatro componentes de un pasteurizador (enfriador, válvula, bomba y acumulador) a partir de un ciclo de 60 s de siete sensores a 10 Hz, y añade explicabilidad integrada: ventanas temporales críticas (Grad-CAM), importancia por sensor (SHAP opcional), riesgo por componente y acciones de mantenimiento priorizadas.
Objetivo del modelo	Dotar al diagnóstico de fallos de maquinaria de pasteurizado (Entregable 47) de explicabilidad, diagnóstico causal aproximado y recomendación prescriptiva, de modo que el técnico de planta sepa no solo qué componente degrada, sino cuándo se manifiesta dentro del ciclo, qué sensor domina la decisión y qué acción priorizar.
Caso de uso principal	Modo inline: se envía un ciclo de 60 s (siete sensores a 10 Hz) y se obtiene el estado de los cuatro componentes con su confianza y su xai_result (estado del sistema, componentes alterados, variables clave y acciones, con la ventana crítica y el riesgo por componente); SHAP es opcional. Modo batch: se envía un CSV con varios ciclos (Cycle_ID) y cada fila devuelve su predicción y su propio xai_result o xai_error.

TABLA 1 DESCRIPCIÓN GENERAL DEL MODELO

No te dice cuánto tiempo falta exactamente para que falle un componente ni sustituye la inspección del técnico: te indica el estado actual de cada componente, en qué momento del ciclo aparece la anomalía y qué actuación se recomienda.

2. Qué necesito darle (entradas)

Los datos son las lecturas de siete sensores del pasteurizador durante un ciclo completo de 60 segundos (diez lecturas por segundo), que llegan del sistema de planta o de un archivo CSV con varios ciclos.

Nombre del campo	Descripción
PS1	Presión de entrada del circuito (bar). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)
PS3	Presión de salida / retorno (bar). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)
EPS1	Potencia activa del motor (W). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)
FS1	Caudal volumétrico (L/min). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)
TS1	Temperatura de entrada (°C). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)
TS2	Temperatura de salida (°C). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)
VS1	Vibración mecánica (mm/s). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)
Time_Segundos	Marca temporal de cada muestra (0,0–60,0 s); ordena la serie y se remuestrea a 10 Hz
Cycle_ID	Identificador del ciclo; en batch agrupa las filas de cada ciclo
data_path	Alternativa a los arrays: CSV (local o s3://) con las columnas anteriores; en batch es la entrada
apply_digital_twin	Desplaza TS1/TS2 al baseline de 65 °C. Solo para datos del banco de laboratorio UCI; con datos reales de planta debe ser false
include_xai	XAI de cada ciclo (xai_result / xai_error): Grad-CAM, riesgo y acciones. Inline y batch
include_shap	Añade SHAP (sensor más relevante) a la XAI. Requiere include_xai; coste alto en CPU. En batch solo se calcula en los primeros n_samples ciclos
include_cam	Inline: devuelve además la curva Grad-CAM (600 valores) por componente

Nombre del campo	Descripción
n_samples	Batch con include_shap: ciclos máximos con SHAP (el resto lleva solo Grad-CAM, siempre presente en todos los ciclos)

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Qué me devuelve (salidas)

Nombre del campo	Descripción	Cómo interpretar el resultado
Enfriador_Fouling	Estado del enfriador (ensuciamiento)	0 = Sano, 1 = Warning (inspección programada), 2 = Crítico (degradación severa)
Valvula_Switch	Estado de la válvula	0 = Sano, 1 = Warning (inspección programada), 2 = Crítico (degradación severa)
Bomba_Leakage	Estado de la bomba (fugas)	0 = Sano, 1 = Warning (inspección programada), 2 = Crítico (degradación severa)
Acumulador_Gas	Estado del acumulador (presión de gas)	0 = Sano, 1 = Warning (inspección programada), 2 = Crítico (degradación severa)
Confianza_Fouling / _Valvula / _Bomba / _Acumulador	Probabilidad softmax de la clase predicha para cada componente	valores próximos a 1 indican alta seguridad del modelo; no es una probabilidad calibrada de fallo
xai_result	XAI del ciclo (inline: en la respuesta; batch: en cada fila). Mismo contrato que modelo-43: Estado_del_sistema.Estado_int	Estado = peor estado de los 4 componentes (Normal / Warning / Crítico); Bloques = componentes

Nombre del campo	Descripción	Cómo interpretar el resultado
	erpretativo, Bloques_principales, Variables_clave, Acciones_sugeridas / Mensaje_operativo y Detalle_componentes (ventana crítica Grad-CAM, riesgo, acción, sensor SHAP)	alterados; Variables = sensores de la regla física (y el sensor SHAP si se pidió); Acciones = acciones prescriptivas por urgencia
xai_error	Motivo si la XAI de ese ciclo falló (xai_result es null); null si fue correcta	un fallo de XAI no afecta a la predicción del ciclo ni a la de los demás ciclos del lote

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Cómo leo el resultado

Si para un ciclo el estado del sistema sale «Crítico» porque el enfriador está en «Crítico» con una confianza del 96 %, la acción sugerida es «Fouling: Detener producción y ejecutar limpieza CIP inmediata», debes parar y limpiar; si válvula, bomba y acumulador salen «Sano», no requieren intervención en ese ciclo.

En las pruebas con ciclos que el modelo no había visto, acertó el estado de los cuatro componentes a la vez en cerca del 99 % de los ciclos. Los pocos errores fueron falsas alarmas (un componente sano marcado como «Warning»), no fallos reales pasados por alto.

5. Cuándo debo revisar manualmente

• Cuando un componente salga «Crítico» o «Warning» con confianza baja (por debajo del 70-80 %): confirma con una inspección antes de parar la producción.

• Cuando las temperaturas de tus datos sean de planta real y no de laboratorio: comprueba con el equipo técnico que no se está aplicando el ajuste de laboratorio (gemelo digital).

• Cuando el ciclo tenga menos de 60 s de datos o huecos en alguna lectura: el diagnóstico de ese ciclo no es fiable.

• Cuando la explicación señale un sensor o un instante que no tenga sentido físico para ti: trátala como una pista, no como una causa demostrada.

6. Qué no hace el modelo

• No sustituye el criterio del técnico de mantenimiento ni garantiza que un componente no vaya a fallar.

• No demuestra la causa física de una avería: la explicación señala dónde y qué sensor pesó más en la decisión, no por qué se estropeó.

• No está validado todavía con datos reales de una planta lechera: se ha probado con un banco de pruebas de laboratorio.

• No decide solo ni ejecuta paradas: las acciones recomendadas son una sugerencia que debe confirmar una persona.

7. Puede equivocarse

Sí. En las pruebas de laboratorio acertó el estado de los cuatro componentes a la vez en el 98,79 % de los ciclos, y los errores observados fueron falsas alarmas. En una planta real el rendimiento puede ser menor hasta que el modelo se calibre con datos propios. Es una ayuda a la decisión, no una garantía.

8. KPIs del modelo

KPI	Valor objetivo / umbral	Descripción comprensible
Acierto simultáneo de los 4 componentes	98,79 % en test	Porcentaje de ciclos en los que se diagnostican bien los cuatro componentes a la vez
Equilibrio entre detectar fallos y evitar falsas alarmas	≥ 95 % exigido · 99,70 % obtenido	Criterio de éxito del diagnóstico de fallos (F1 macro)
Fallos reales no detectados	Ninguno clasificado como «Sano» en test	Los pocos errores fueron falsas alarmas, no fallos pasados por alto
Explicación disponible por ciclo	Los 4 componentes	Para cada componente: momento crítico del ciclo,

KPI	Valor objetivo / umbral	Descripción comprensible
		riesgo y acción de mantenimiento recomendada

TABLA 4 KPIS DEL MODELO

9. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Datos de laboratorio, no de leche real	Entrenado y evaluado con el banco hidráulico UCI (aceite, fallos inyectados de forma controlada), adaptado con un gemelo térmico. Las métricas son optimistas respecto a planta; requiere calibración (transfer learning) con datos etiquetados de un pasteurizador real antes de producción. El equipo de IA no dispone aún de datos reales.
Gemelo digital según el origen de los datos	Con datos UCI hay que aplicar apply_digital_twin=true (offset de TS1/TS2 a 65 °C con ts1_mean_train); con datos reales de planta debe ser false. Aplicarlo mal desplaza las temperaturas y degrada el diagnóstico.
Explicabilidad post-hoc, no causal	Grad-CAM y SHAP explican lo que el modelo 've', no prueban causalidad física; si el modelo se equivoca, la explicación justifica una predicción incorrecta. Las acciones prescriptivas son una tabla experta configurable (maintenance_actions.yaml), no una optimización.
SHAP: coste y dependencia de versión	SHAP (GradientExplainer) cuesta ≈5–8 s por ciclo en CPU, por eso es opcional y en batch se limita a los primeros n_samples ciclos (el resto lleva solo Grad-CAM). Sus valores dependen de la versión de shap: se reproducen con shap ≥ 0,51 (verificado 0,52.0), no con 0,42.
Ventana fija de 600 pasos	Cada ciclo se procesa como 60 s a 10 Hz: con menos pasos se rellena con ceros (calidad no garantizada) y con más se trunca a los 600 primeros.
Pendiente de validación de infraestructura	/train contra un MLflow real no verificado. El reentrenamiento sí está verificado con los datos entregados (14/10/2026): calibración fine_tune (por defecto) 0,9970 de exact match en el 15 % de test; reentrenamiento full desde cero 0,9849 de exact match en GPU (94 épocas), frente al 0,9879 del modelo

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
	entregado: en GPU el entrenamiento no es bit a bit reproducible y varía ±1 ciclo de test entre ejecuciones.

TABLA 5 LIMITACIONES CONOCIDAS