



DATA GIA

Plataforma Digital
Agroalimentaria de
Castilla y León



INSTITUTO
TECNOLÓGICO
AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería
y Desarrollo Rural

Ficha técnica del modelo a48 · dnsi-fallas- maquinaria-pasteurizado- xai

Especificación técnica
para integración en la
plataforma DatagIA

Octubre 2026



Financiado por
la Unión Europea
NextGenerationEU



GOBIERNO
DE ESPAÑA

MINISTERIO
PARA LA TRANSICIÓN ECOLÓGICA
Y EL RETO DEMOGRÁFICO



Plan de Recuperación,
Transformación
y Resiliencia



Junta de
Castilla y León







1. Información general del modelo

Nombre del modelo (model_key)	m48-dns1-fallas-maquinaria-pasteurizado
Versión	1.3 (entrega IA) · plugin 1.0.0
Descripción	Red convolucional 1D multitarea con pérdida físico-informada (DNSL) que diagnostica el estado de cuatro componentes de un pasteurizador (enfriador, válvula, bomba y acumulador) a partir de un ciclo de 60 s de siete sensores a 10 Hz, y añade explicabilidad integrada: ventanas temporales críticas (Grad-CAM), importancia por sensor (SHAP opcional), puntos críticos de control (CCP) y acciones de mantenimiento priorizadas.
Tipo de tarea (task_type)	Clasificación multietiqueta (4 componentes × 3 estados) con explicabilidad y recomendación prescriptiva
Framework	PyTorch (1D-CNN CNN_Pasteurizer + PhysicsGuidedLoss) + scikit-learn (StandardScaler) + SHAP (GradientExplainer) + pandas / numpy
Fichero del artefacto	neurosymbolic_cnn.pth + scaler_cnn_dns.pkl + feature_columns.pkl + ts1_mean_train.pkl + shap_background.npy (+ shap_background_meta.json). Pesos del Entregable 47 v2.0
Objetivo del modelo	Dotar al diagnóstico de fallos de maquinaria de pasteurizado (Entregable 47) de explicabilidad, diagnóstico causal aproximado y recomendación prescriptiva, de modo que el técnico de planta sepa no solo qué componente degrada, sino cuándo se manifiesta dentro del ciclo, qué sensor domina la decisión y qué acción priorizar. La detección de puntos críticos de control (CCP) se inspira en el paradigma HACCP.
Caso de uso principal	Modo inline: se envía un ciclo de 60 s (siete sensores a 10 Hz) y se obtiene el estado de los cuatro componentes con su confianza y un informe local con la ventana crítica, el riesgo y la acción recomendada por componente; SHAP es opcional. Modo batch: se envía un CSV con varios ciclos (Cycle_ID) y, con include_xai, se obtiene además el análisis global de CCP sobre una muestra de ciclos.

TABLA 1 INFORMACIÓN GENERAL DEL MODELO

2. Campos de entrada (inputs)

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
PS1	list[float]	Presión de entrada del circuito (bar). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)	Sí (o data_path)	-
PS3	list[float]	Presión de salida / retorno (bar). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)	Sí (o data_path)	-
EPS1	list[float]	Potencia activa del motor (W). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)	Sí (o data_path)	-
FS1	list[float]	Caudal volumétrico (L/min). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)	Sí (o data_path)	-
TS1	list[float]	Temperatura de entrada (°C). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)	Sí (o data_path)	-
TS2	list[float]	Temperatura de salida (°C). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)	Sí (o data_path)	-
VS1	list[float]	Vibración mecánica (mm/s). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)	Sí (o data_path)	-
Time_Segundos	list[float]	Marca temporal de cada muestra (0,0–60,0 s); ordena la serie y se remuestrea a 10 Hz	No	0,0, 0,1, 0,2...

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
Cycle_ID	int	Identificador del ciclo; en batch agrupa las filas de cada ciclo	No (batch con varios ciclos: Sí)	-
data_path	string	Alternativa a los arrays: CSV (local o s3://) con las columnas anteriores; en batch es la entrada	No (batch: Sí)	-
apply_digital_twin	bool	Desplaza TS1/TS2 al baseline de 65 °C. Solo para datos del banco de laboratorio UCI; con datos reales de planta debe ser false	No	variable APPLY_DIGITAL_TWIN (false)
include_xai	bool	Inline: informe local por componente (ventana Grad-CAM, riesgo, acción). Batch: análisis global de puntos críticos (CCP)	No	true (inline) / false (batch)
include_shap	bool	Añade SHAP (sensor más relevante e importancias). Requiere include_xai; coste alto en CPU	No	false
include_cam	bool	Inline: devuelve además la curva Grad-CAM (600 valores) por componente	No	false
n_samples	int	Batch con XAI: ciclos máximos del CSV usados en el análisis global (muestra aleatoria, semilla 42)	No	50

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Campos de salida (outputs)

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
Enfriador_Fouling	int	Estado del enfriador (ensuciamiento)	0, 1, 2	0 = Sano, 1 = Warning (inspección programada), 2

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
				= Crítico (degradación severa)
Valvula_Switch	int	Estado de la válvula	0, 1, 2	0 = Sano, 1 = Warning (inspección programada), 2 = Crítico (degradación severa)
Bomba_Leakage	int	Estado de la bomba (fugas)	0, 1, 2	0 = Sano, 1 = Warning (inspección programada), 2 = Crítico (degradación severa)
Acumulador_Gas	int	Estado del acumulador (presión de gas)	0, 1, 2	0 = Sano, 1 = Warning (inspección programada), 2 = Crítico (degradación severa)
Confianza_Fouling / _Valvula / _Bomba / _Acumulador	float	Probabilidad softmax de la clase predicha para cada componente	0–1	valores próximos a 1 indican alta seguridad del modelo; no es una probabilidad calibrada de fallo
xai (inline)	list[object]	Por componente: ventana crítica Grad-CAM en segundos (inicio/fin), intensidad, acción, urgencia, intervalo de ciclos,	4 filas (Fouling, Válvula, Bomba, Acumulador)	riesgo_score = severidad × confianza (con bonus SHAP si se pide); NORMAL < 0,5

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
		riesgo_score/nivel y, con SHAP, sensor más relevante e importancia		$\leq \text{WARNING} < 0,8 \leq \text{CRÍTICO}$
xai (batch)	object	ccps (ventanas críticas por componente, sensor, regla física, severidad agregada), shap (importancia por componente y sensor, 28 filas) y summary (ciclos analizados)	según ciclos analizados	severidad CRÍTICO si $>10\%$ de ciclos son Crítico; WARNING si $>20\%$ son Warning

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Métricas de evaluación

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
Exact Match (4 componentes a la vez)	98,79 % (331 ciclos de test)	Declarada por el equipo de IA (memoria v1.3, models/metrics/test_metrics_confusion.csv)	En 327 de 331 ciclos de test el modelo acierta los cuatro componentes simultáneamente
F1-Score macro	99,70 %	Declarada por el equipo de IA (memoria v1.3), criterio de éxito del $E47 \geq 95\%$	Rendimiento equilibrado entre clases Sano/Warning/Crítico
Accuracy por componente	Fouling 100 % · Válvula 100 % · Bomba 99,40 % ·	Test hold-out de 331 ciclos; únicos errores: 2 ciclos Sano→Warning en	Los errores son falsas alarmas de clase contigua;

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
	Acumulador 99,40 %	Bomba y 2 en Acumulador	ningún fallo real se clasificó como Sano
Baseline (clase mayoritaria)	Exact Match 9,06 %	Referencia trivial calculada por el equipo sobre el mismo test	El modelo mejora ampliamente un predictor trivial
Verificación tras integración: golden	20/20 ciclos	20 ciclos de test (semilla 42, cubren las 12 parejas componente/clase); etiqueta real de profile.txt; plugin m48 con apply_digital_twin=true	El plugin reproduce las clases esperadas de los 20 ciclos (cableado y preprocesado correctos); no sustituye a las métricas de test
Verificación tras integración: XAI	ciclo 123: 13/13 columnas · global: 6 CCP + 28 SHAP idénticos	Plugin frente a los CSV de la v1.3 del equipo (shap 0.52.0, scikit-learn 1.5.2); diferencia máxima SHAP 0,0	La capa XAI del plugin reproduce exactamente la del equipo de IA

TABLA 4 MÉTRICAS DE EVALUACIÓN

5. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Datos de laboratorio, no de leche real	Entrenado y evaluado con el banco hidráulico UCI (aceite, fallos inyectados de forma controlada), adaptado con un gemelo térmico. Las métricas son optimistas respecto a planta; requiere calibración (transfer learning) con datos etiquetados de un pasteurizador real antes de producción. El equipo de IA no dispone aún de datos reales.

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Gemelo digital según el origen de los datos	Con datos UCI hay que aplicar <code>apply_digital_twin=true</code> (offset de TS1/TS2 a 65 °C con <code>ts1_mean_train</code>); con datos reales de planta debe ser false. Aplicarlo mal desplaza las temperaturas y degrada el diagnóstico.
Explicabilidad post-hoc, no causal	Grad-CAM y SHAP explican lo que el modelo 've', no prueban causalidad física; si el modelo se equivoca, la explicación justifica una predicción incorrecta. Las acciones prescriptivas son una tabla experta configurable (<code>maintenance_actions.yaml</code>), no una optimización.
SHAP: coste y dependencia de versión	SHAP (GradientExplainer) cuesta $\approx 5-8$ s por ciclo en CPU y ≈ 10 min en el análisis global de 50 ciclos, por eso es opcional. Sus valores dependen de la versión de shap: se reproducen con <code>shap $\geq 0,51$</code> (verificado 0,52.0), no con 0,42.
Ventana fija de 600 pasos	Cada ciclo se procesa como 60 s a 10 Hz: con menos pasos se rellena con ceros (calidad no garantizada) y con más se trunca a los 600 primeros.
Pendiente de validación de infraestructura	Reentrenamiento completo (300 épocas) y /train contra un MLflow real no verificados; el plugin reentrena con los hiperparámetros del equipo, pero sus métricas a escala completa no se han comprobado.

TABLA 5 LIMITACIONES CONOCIDAS

6. Observaciones técnicas

Python 3.12; PyTorch ≥ 2.13 (CPU suficiente, sin GPU), scikit-learn 1.5.2 (el scaler se regeneró con esta versión), `shap  $\geq 0,51$` (verificado 0,52.0), pandas / numpy. Artefactos ≈ 4 MB (pesos 592 KB + fondo SHAP 3,4 MB) en `s3://xai/artifacts/fixed/a48_dnsl_fallas_maquinaria_pasteurizado/`. Grad-CAM < 1 s por ciclo; SHAP $\approx 5-8$ s por ciclo (inline) y ≈ 10 min en el análisis global de 50 ciclos. Servicio propio MODEL=m48-dnsl-fallas-maquinaria-pasteurizado; monitorizar deriva con el detector ODD (modelo-48) y revisar umbrales y acciones al disponer de datos reales.

7. Fichero de prueba de referencia

Nombre del fichero	golden_cycles_10hz.csv (ciclos extraídos de data/processed/hydraulic_10hz_raw.csv)
Número de registros / muestras	21 ciclos × 601 filas a 10 Hz: 20 ciclos del split de test y el ciclo 123 (validación)
Resultado esperado con este fichero	predict_batch con apply_digital_twin=true reproduce las etiquetas reales de los 20 ciclos de test (20/20) y el informe local del ciclo 123 (13/13 columnas del xai_report_cycle.csv de la v1.3), con shap 0.52.0 y scikit-learn 1.5.2

TABLA 6 FICHERO DE PRUEBA DE REFERENCIA

