DATAGIA
Plataforma Digital Agroalimentaria de Castilla y León

INSTITUTO TECNOLÓGICO AGRARIO
Junta de Castilla y León
Consejería de Agricultura, Ganadería y Desarrollo Rural

Ficha técnica del modelo a48 · dnsl-fallas-maquinaria-pasteurizado-xai

Especificación técnica para integración en la plataforma DatagIA

Octubre 2026

Financiado por la Unión Europea
NextGenerationEU

Gobierno de España · Ministerio para la Transición Ecológica y el Reto Demográfico
Plan de Recuperación, Transformación y Resiliencia
Junta de Castilla y León

1. Información general del modelo

Nombre del modelo (model_key)	ml48-dairy-dnsl-critical-point-detection
Versión	1.3 (entrega IA) · plugin 1.0.0
Descripción	Modelo que sirve modelo-47 (detección de fallos en pasteurización con XAI integrada): red convolucional 1D multitarea con pérdida físico-informada (DNSL) que diagnostica el estado de cuatro componentes de un pasteurizador (enfriador, válvula, bomba y acumulador) a partir de un ciclo de 60 s de siete sensores a 10 Hz, y añade explicabilidad integrada: ventanas temporales críticas (Grad-CAM), importancia por sensor (SHAP opcional), riesgo por componente y acciones de mantenimiento priorizadas.
Tipo de tarea (task_type)	Clasificación multietiqueta (4 componentes × 3 estados) con explicabilidad y recomendación prescriptiva
Framework	PyTorch (1D-CNN CNN_Pasteurizer + PhysicsGuidedLoss) + scikit-learn (StandardScaler) + SHAP (GradientExplainer) + pandas / numpy
Fichero del artefacto	neurosymbolic_cnn.pth + scaler_cnn_dns.pkl + feature_columns.pkl + ts1_mean_train.pkl + shap_background.npy (+ shap_background_meta.json). Pesos del Entregable 47 v2.0
Objetivo del modelo	Dotar al diagnóstico de fallos de maquinaria de pasteurizado (Entregable 47) de explicabilidad, diagnóstico causal aproximado y recomendación prescriptiva, de modo que el técnico de planta sepa no solo qué componente degrada, sino cuándo se manifiesta dentro del ciclo, qué sensor domina la decisión y qué acción priorizar.
Caso de uso principal	Modo inline: se envía un ciclo de 60 s (siete sensores a 10 Hz) y se obtiene el estado de los cuatro componentes con su confianza y su xai_result (estado del sistema, componentes alterados, variables clave y acciones, con la ventana crítica y el riesgo por componente); SHAP es opcional. Modo batch: se envía un CSV con varios ciclos (Cycle_ID) y cada fila devuelve su predicción y su propio xai_result o xai_error.

TABLA 1 INFORMACIÓN GENERAL DEL MODELO

2. Campos de entrada (inputs)

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
PS1	list[float]	Presión de entrada del circuito (bar). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)	Sí (o data_path)	-
PS3	list[float]	Presión de salida / retorno (bar). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)	Sí (o data_path)	-
EPS1	list[float]	Potencia activa del motor (W). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)	Sí (o data_path)	-
FS1	list[float]	Caudal volumétrico (L/min). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)	Sí (o data_path)	-
TS1	list[float]	Temperatura de entrada (°C). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)	Sí (o data_path)	-
TS2	list[float]	Temperatura de salida (°C). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)	Sí (o data_path)	-
VS1	list[float]	Vibración mecánica (mm/s). Serie de un ciclo de 60 s a 10 Hz (600 pasos; se rellena con ceros o se trunca a 600)	Sí (o data_path)	-
Time_Segundos	list[float]	Marca temporal de cada muestra (0,0–60,0 s);	No	0,0, 0,1, 0,2…

Nombre del campo	Tipo	Descripción	Obligatorio	Valor por defecto
		ordena la serie y se remuestrea a 10 Hz		
Cycle_ID	int	Identificador del ciclo; en batch agrupa las filas de cada ciclo	No (batch con varios ciclos: Sí)	-
data_path	string	Alternativa a los arrays: CSV (local o s3://) con las columnas anteriores; en batch es la entrada	No (batch: Sí)	-
apply_digital_twin	bool	Desplaza TS1/TS2 al baseline de 65 °C. Solo para datos del banco de laboratorio UCI; con datos reales de planta debe ser false	No	variable APPLY_DIGITAL_TWIN (false)
include_xai	bool	XAI de cada ciclo (xai_result / xai_error): Grad-CAM, riesgo y acciones. Inline y batch	No	true
include_shap	bool	Añade SHAP (sensor más relevante) a la XAI. Requiere include_xai; coste alto en CPU. En batch solo se calcula en los primeros n_samples ciclos	No	false
include_cam	bool	Inline: devuelve además la curva Grad-CAM (600 valores) por componente	No	false
n_samples	int	Batch con include_shap: ciclos máximos con SHAP (el resto lleva solo Grad-CAM, siempre presente en todos los ciclos)	No	50

TABLA 2 CAMPOS DE ENTRADA (INPUTS)

3. Campos de salida (outputs)

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
Enfriador_Fouling	int	Estado del enfriador (ensuciamiento)	0, 1, 2	0 = Sano, 1 = Warning (inspección programada), 2 = Crítico (degradación severa)
Valvula_Switch	int	Estado de la válvula	0, 1, 2	0 = Sano, 1 = Warning (inspección programada), 2 = Crítico (degradación severa)
Bomba_Leakage	int	Estado de la bomba (fugas)	0, 1, 2	0 = Sano, 1 = Warning (inspección programada), 2 = Crítico (degradación severa)
Acumulador_Gas	int	Estado del acumulador (presión de gas)	0, 1, 2	0 = Sano, 1 = Warning (inspección programada), 2 = Crítico (degradación severa)
Confianza_Fouling / _Valvula / _Bomba / _Acumulador	float	Probabilidad softmax de la clase predicha para cada componente	0–1	valores próximos a 1 indican alta seguridad del modelo; no es una probabilidad calibrada de fallo
xai_result	object	XAI del ciclo (inline: en la respuesta;	una por ciclo	Estado = peor estado de los

Nombre del campo	Tipo	Descripción	Rango de valores posibles	Cómo interpretar el resultado
		batch: en cada fila). Mismo contrato que modelo-43: Estado_del_sistema. Estado_interpretativo, Bloques_principales, Variables_clave, Acciones_sugeridas / Mensaje_operativo y Detalle_componentes (ventana crítica Grad-CAM, riesgo, acción, sensor SHAP)		4 componentes (Normal / Warning / Crítico); Bloques = componentes alterados; Variables = sensores de la regla física (y el sensor SHAP si se pidió); Acciones = acciones prescriptivas por urgencia
xai_error	string	Motivo si la XAI de ese ciclo falló (xai_result es null); null si fue correcta	una por ciclo	un fallo de XAI no afecta a la predicción del ciclo ni a la de los demás ciclos del lote

TABLA 3 CAMPOS DE SALIDA (OUTPUTS)

4. Métricas de evaluación

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
Exact Match (4 componentes a la vez)	98,79 % (331 ciclos de test)	Declarada por el equipo de IA (memoria v1.3, models/metrics/test_metrics_confusion.csv)	En 327 de 331 ciclos de test el modelo acierta los cuatro componentes simultáneamente
F1-Score macro	99,70 %	Declarada por el equipo de IA	Rendimiento equilibrado entre

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
		(memoria v1.3), criterio de éxito del E47 ≥ 95 %	clases Sano/Warning/Crítico
Accuracy por componente	Fouling 100 % · Válvula 100 % · Bomba 99,40 % · Acumulador 99,40 %	Test hold-out de 331 ciclos; únicos errores: 2 ciclos Sano→Warning en Bomba y 2 en Acumulador	Los errores son falsas alarmas de clase contigua; ningún fallo real se clasificó como Sano
Baseline (clase mayoritaria)	Exact Match 9,06 %	Referencia trivial calculada por el equipo sobre el mismo test	El modelo mejora ampliamente un predictor trivial
Verificación tras integración: golden	20/20 ciclos	20 ciclos de test (semilla 42, cubren las 12 parejas componente/clase); etiqueta real de profile.txt; plugin ml48 con apply_digital_twin=true	El plugin reproduce las clases esperadas de los 20 ciclos (cableado y preprocesado correctos); no sustituye a las métricas de test
Verificación tras integración: XAI por ciclo	20/20 ciclos con xai_result · ciclo 123: informe idéntico	Plugin con artefactos reales: los 20 ciclos del golden devuelven xai_result coherente con su predicción; el detalle del ciclo 123 coincide con el informe local del equipo de IA (v1.3, shap 0.52.0); SHAP	La XAI por ciclo del plugin reproduce la referencia del equipo de IA

Métrica	Valor	Descripción	Interpretación (qué significa para el usuario)
		limitado a n_samples comprobado	

TABLA 4 MÉTRICAS DE EVALUACIÓN

5. Limitaciones conocidas

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
Datos de laboratorio, no de leche real	Entrenado y evaluado con el banco hidráulico UCI (aceite, fallos inyectados de forma controlada), adaptado con un gemelo térmico. Las métricas son optimistas respecto a planta; requiere calibración (transfer learning) con datos etiquetados de un pasteurizador real antes de producción. El equipo de IA no dispone aún de datos reales.
Gemelo digital según el origen de los datos	Con datos UCI hay que aplicar apply_digital_twin=true (offset de TS1/TS2 a 65 °C con ts1_mean_train); con datos reales de planta debe ser false. Aplicarlo mal desplaza las temperaturas y degrada el diagnóstico.
Explicabilidad post-hoc, no causal	Grad-CAM y SHAP explican lo que el modelo 've', no prueban causalidad física; si el modelo se equivoca, la explicación justifica una predicción incorrecta. Las acciones prescriptivas son una tabla experta configurable (maintenance_actions.yaml), no una optimización.
SHAP: coste y dependencia de versión	SHAP (GradientExplainer) cuesta ≈5–8 s por ciclo en CPU, por eso es opcional y en batch se limita a los primeros n_samples ciclos (el resto lleva solo Grad-CAM). Sus valores dependen de la versión de shap: se reproducen con shap ≥ 0,51 (verificado 0,52.0), no con 0,42.
Ventana fija de 600 pasos	Cada ciclo se procesa como 60 s a 10 Hz: con menos pasos se rellena con ceros (calidad no garantizada) y con más se trunca a los 600 primeros.
Pendiente de validación de infraestructura	/train contra un MLflow real no verificado. El reentrenamiento sí está verificado con los datos entregados (14/10/2026): calibración fine_tune (por

Tipo de limitación	Descripción (cuándo no usar / qué puede fallar)
	defecto) 0,9970 de exact match en el 15 % de test; reentrenamiento full desde cero 0,9849 de exact match en GPU (94 épocas), frente al 0,9879 del modelo entregado: en GPU el entrenamiento no es bit a bit reproducible y varía ±1 ciclo de test entre ejecuciones.

TABLA 5 LIMITACIONES CONOCIDAS

6. Observaciones técnicas

Python 3.12; PyTorch ≥ 2.13 (CPU suficiente, sin GPU), scikit-learn 1.5.2 (el scaler se regeneró con esta versión), shap ≥ 0,51 (verificado 0,52.0), pandas / numpy. Artefactos ≈ 4 MB (pesos 592 KB + fondo SHAP 3,4 MB) en s3://xai/artifacts/fixed/ml48_dairy_dnsl_critical_point_detection/. Grad-CAM < 0,1 s por ciclo (20 ciclos con XAI en < 1 s); SHAP ≈ 5–8 s por ciclo, opcional y limitado por n_samples en batch. El plugin se despliega con MODEL=ml48-dairy-dnsl-critical-point-detection y sirve modelo-47; monitorizar deriva con el detector ODD (modelo-47) y revisar umbrales y acciones al disponer de datos reales.

7. Fichero de prueba de referencia

Nombre del fichero	golden_cycles_10hz.csv (ciclos extraídos de data/processed/hydraulic_10hz_raw.csv)
Número de registros / muestras	21 ciclos × 601 filas a 10 Hz: 20 ciclos del split de test y el ciclo 123 (validación)
Resultado esperado con este fichero	predict_batch con apply_digital_twin=true reproduce las etiquetas reales de los 20 ciclos de test (20/20) y el informe local del ciclo 123 (13/13 columnas del xai_report_cycle.csv de la v1.3), con shap 0.52.0 y scikit-learn 1.5.2

TABLA 6 FICHERO DE PRUEBA DE REFERENCIA